



MBA EM GERENCIAMENTO DE PROJETOS

PROFESSOR: **MATHIAS FREIRE DE CARVALHO**

DISCIPLINA: INTELIGÊNCIA ARTIFICIAL APLICADA A
PROJETOS

MBA EM GERENCIAMENTO DE PROJETOS



Profº. Mathias Freire de Carvalho

SUMÁRIO

1. PROGRAMA DA DISCIPLINA	1
1.1 EMENTA	1
1.2 CARGA HORÁRIA TOTAL	1
1.3 OBJETIVO	1
1.4 CONTEÚDO PROGRAMÁTICO	1
1.5 METODOLOGIA	2
1.6 CRITÉRIOS DE AVALIAÇÃO	2
1.7 BIBLIOGRAFIA BÁSICA.....	2
1.8 BIBLIOGRAFIA COMPLEMENTAR (APÊNDICE).....	2
CURRICULUM VITAE DO DOCENTE	3
2. INTELIGÊNCIA ARTIFICIAL	4
2.1 A RELEVÂNCIA DA INTELIGÊNCIA ARTIFICIAL	4
2.2. O QUE ESPERAR DESTA DISCIPLINA.....	4
2.3. CONTEÚDO TEÓRICO	5
2.4 TIPOS DE INTELIGÊNCIA ARTIFICIAL	27
2.5 TIPOS E APLICAÇÕES DA INTELIGÊNCIA ARTIFICIAL	28
2.6 PRINCIPAIS ABORDAGENS NA INTELIGÊNCIA ARTIFICIAL:	29
2.7 PRINCIPAIS CAMPOS DE PESQUISA NA INTELIGÊNCIA ARTIFICIAL	31
2.8 DEFINIÇÕES DA INTELIGÊNCIA ARTIFICIAL	33
2.9. A INTELIGÊNCIA ARTIFICIAL ESTREITA (IAE) E SEUS MERCADOS POTENCIAIS	35
2.10. O APRENDIZADO DE MÁQUINA (ML).....	36
2.11..... A IA E SUAS APLICAÇÕES 36	
2.12 BIG DATA, CIÊNCIA DE DADOS E INTELIGÊNCIA ARTIFICIAL: UMA SINERGIA PROMISSORA.....	44
2.13 APLICAÇÕES DE PROJETOS DE INTELIGÊNCIA ARTIFICIAL NAS ORGANIZAÇÕES.....	47
2.14..INTELIGÊNCIA ARTIFICIAL APLICADA AO GERENCIAMENTO DE PROJETOS. 53	
2.15 ÉTICA E GOVERNANÇA EM INTELIGÊNCIA ARTIFICIAL (IA)	71
APÊNDICE – BIBLIOGRAFIA COMPLEMENTAR E REFERÊNCIAS	78

1. PROGRAMA DA DISCIPLINA

1.1 EMENTA

Fundamentos da IA. Histórico e evolução. Tipos de *Machine Learning* (ML). *Deep learning*. *Big Data* e Ciência de Dados. Aplicação de projetos de IA em diversos setores organizacionais: Marketing, Finanças, RH, entre outros. Aplicações de IA para a gestão de projetos preditiva e adaptativa. Metodologias de gerenciamento para projetos de IA. Governança em IA. Segurança e riscos associados a IA. Questões éticas ligadas a projetos de IA.

1.2 CARGA HORÁRIA TOTAL

24 horas-aula.

1.3 OBJETIVO

Ao final do curso, o aluno terá uma visão ampliada sobre as diferentes abordagens possíveis no gerenciamento de projetos, assim como poderá:

- Sintetizar os principais conceitos de Inteligência Artificial (IA) e Machine Learning (ML);
- Identificar as principais oportunidades e os desafios na implantação de projetos de IA em diversos segmentos nas organizações;
- Reunir e trocar melhores práticas para aplicações de IA em gestão de projetos;
- Avaliar as principais implicações da implantação de projetos de IA nas organizações, no mercado e na sociedade.;

1.4 CONTEÚDO PROGRAMÁTICO

Apresentar os principais conceitos de IA e ML com objetivo de posicionar sobre as principais técnicas utilizadas.	<ul style="list-style-type: none"> ▪ Fundamentos de IA; ▪ Tipos de ML; ▪ <i>Deep Learning</i>, ▪ <i>Big Data</i> e Ciência de Dados.
Identificar as principais oportunidades e os desafios na implantação de projetos de IA em diversos segmentos nas organizações.	<ul style="list-style-type: none"> ▪ Aplicação de projetos de IA em RH; ▪ Aplicação de projetos de IA em Marketing; ▪ Aplicação de projetos de IA em Finanças; ▪ Outras aplicações.

Reunir e traçar melhores práticas para aplicações de IA em gestão de projetos.	<ul style="list-style-type: none"> ▪ Aplicações de IA para a gestão de projetos preditiva e adaptativa; ▪ Metodologias de gerenciamento para projetos de IA.
Avaliar as principais implicações da implantação de projetos de IA nas organizações, no mercado e na sociedade.	<ul style="list-style-type: none"> ▪ Governança em IA; ▪ Segurança e riscos associados a IA; ▪ Questões éticas ligadas a projetos de IA.

1.5 METODOLOGIA

Exposição dialogada dará suporte aos debates, estudos de caso, atividades, exercícios.

1.6 CRITÉRIOS DE AVALIAÇÃO

A nota final dos alunos estará baseada:

- 30% referentes às atividades em equipe realizadas em sala de aula e/ou trabalho entregue em grupos;
- 70% referentes à avaliação individual, sob a forma de trabalho ou prova, a ser realizada após o término da disciplina.

1.7 BIBLIOGRAFIA BÁSICA

GABRIEL, Martha. *Inteligência Artificial. Do Zero ao Metaverso*. São Paulo: Atlas, 2022. (Disponível em Minha Biblioteca, acessível a partir do ECLASS FGV.)

KAUFMAN, Dora. *Desmistificando a Inteligência Artificial*. Rio de Janeiro: Autentica, 2022. (Disponível na biblioteca Pearson, acessível a partir do ECLASS FGV.)

VALDATI, Aline. *Inteligência Artificial (IA)*. São Paulo: Contentus, 2020. (Disponível na biblioteca Pearson, acessível a partir do ECLASS FGV.)

1.8 BIBLIOGRAFIA COMPLEMENTAR (APÊNDICE)

CURRICULUM VITAE DO DOCENTE

Doutor em Administração de MKTG (DBA) pela Rennes School of Business, França (2023). MSc em Marketing Internacional pela UNLP, Argentina (2018). Pós-graduado pela FGV no programa de MBA em Gestão de Projetos (2011). Pós-graduado pelo CEAG FGV (1996), e no Programa de Intercâmbio com a HEC/ISA (França, 1995), com concentração em administração de marketing e marketing de serviços. Bacharel em Publicidade e Propaganda (1992).

Desde 1997, atua como gestor de projetos com foco em mídia digital (internet), oferecendo serviços de consultoria em planejamento estratégico, integração com mídias tradicionais, arquitetura da informação, avaliação de desempenho e métricas, gestão de desenvolvimento e programação, direção de arte, gestão de fornecedores, atendimento ao cliente, análise da concorrência, design digital, usabilidade/UX, SEO. Experiência como gerente de marketing de produtos no Brasil, e na Europa como gerente de contas em agência multinacional. Project Management Trainer, Corporate Projects (STS)

Voluntariado:

- Associação Brasileira de Inteligência Artificial. conselheiro estratégico (2023-*);
- ABNT/ISO Comitê de Estudos de IA (2017-*);
- Rennes School of Business, gestor do grupo alumni (2016-2020);
- Associação Brasileira de Internet das Coisas (ABINC), co-fundador e diretor de MKTG (2015 – 2017);
- PMI-SP, diretor de comunicação e MKTG (2015-2017);
- Associação Brasileira de Realidade Estendida - XRBR (2017-*).

Certificações: PMP, PRINCE2, SFC.

2. INTELIGÊNCIA ARTIFICIAL

2.1 A RELEVÂNCIA DA INTELIGÊNCIA ARTIFICIAL

Inteligência artificial (IA) é um tema que sugere estar na vanguarda da tecnologia, algo ainda pouco conhecido em muitas organizações e um traço marcante do século 21. Ao se considerar que diversos setores estão sofrendo forte disrupção⁷⁵, sendo reinventados por novas tecnologias, em um mundo cada vez mais interconectado, neste aspecto a IA tem um papel fundamental em como serão estruturadas novas ofertas de serviços, produtos e as competências necessárias para garantir competitividade.

Para organizações, sistemas de IA podem contribuir de três maneiras⁷⁶: a- aumentar a produtividade através da automação de processos; b- gerar novos '*insights*' (com a ajuda de algoritmos) sobre o mercado, os consumidores, a concorrência e, desta forma, gerar maior competitividade para a empresa; c- oferecer interfaces simplificadas para profissionais interagirem, de maneira intuitiva, com complexos sistemas (usando linguagem natural). No entanto, empresas devem considerar as atuais limitações destes sistemas, os desafios e riscos envolvidos na sua adoção, e o grau de preparo requerido para se integrar com sucesso na organização – sem se deixar levar pelo costumaz 'hype' que envolve novas tecnologias⁷⁷.

Profissionais precisam se adaptar às novas realidades que tais tecnologias trazem, transformando os modelos e negócios, abrindo novas oportunidades e novas funções em diversos mercados, ao mesmo tempo em que contribui para a eliminação de outros postos de trabalho. Para tanto, profissionais de diversas áreas deverão buscar capacitação adicional para se manter relevantes⁷⁸.

2.2. O QUE ESPERAR DESTA DISCIPLINA

Nesta disciplina, não é nosso objetivo prover conhecimento técnico, de programação, ou específico para o desenvolvimento de sistemas de IA, e outros correlatos. Nosso foco estará direcionado aos aspectos estratégicos e de gestão (de negócios, de projetos, etc.). Apresentaremos conceitos fundamentais sobre a história e a tipologia dos sistemas de IA, características de projetos de IA aplicado em mercados específicos, aspectos do ciclo de vida de um projeto de IA, reflexões sobre as novas competências e habilidades que se fazem necessárias, além de uma reflexão sobre governança em IA, suas limitações, os vieses mais comuns e os principais riscos envolvidos.

Seu tutor virtual – Professor Challenger

Para apoiar seu trabalho nesta disciplina, entre em contato com nosso Tutor Digital (baseado em um sistema de IA).

Clique no código QR para acessar o avatar, ou digite:

<http://tinyurl.com/ProfCHL>



2.3. CONTEÚDO TEÓRICO

Introdução

A Inteligência Artificial (IA) exerce, hoje em dia, um impacto muito predominante em (quase) todos os aspectos da vida profissional e cotidiana das pessoas.

O gerenciamento qualificado da IA se torna, desta maneira, importante na implementação das infraestruturas necessárias para a adoção de sistemas de IA nas organizações, como apoio para o avanço de suas linhas estratégicas e a manutenção da competitividade. Desta forma, a adequada abordagem no tocante à 'estratégia de IA e ML' deve permear, de maneira ponderada, por toda a organização. O gerenciamento da AI pressupõe equipes as quais têm um conhecimento adequado sobre sistemas de IA (necessários e aprofundados para otimizar o desempenho de cada função). A figura do 'gestor de IA' não se limita aos especialistas técnicos e cientistas / engenheiros de dados tradicionais (que contribuem com a implementação, desenvolvimento e manutenção/ evolução especializado de sistemas), e sim deve ser parte das capacidades inerentes a todos os profissionais de uma empresa. Hoje em dia, um profissional qualificado para operar em uma empresa a qual adotou ferramentas, sistemas e tecnologia 'de IA' é também um influenciador do 'mindset' necessário para que os sistemas de IA agreguem valor no setor corporativo. Gestores e negócios, operações e projetos (entre outros), têm como foco principal em administrar e orientar os processos de gestão, de engenharia e de setores especializados na empresa, para a implementação e uso com segurança, eficiência e ética de soluções de IA e Machine Learning (ML).

Para se compreender as reais contribuições da IA para o mundo atual (não apenas nas empresas, mas em quase todos os aspectos da vida moderna), é necessário buscar suas origens, aprender sobre sua evolução, para se contextualizar as razões pelas quais chegamos ao ponto onde nos encontramos hoje – e quais as perspectivas para o futuro.

Inovação na história

1

O filósofo grego Aristóteles, considerado como o precursor do raciocínio lógico formal contribuiu, através de suas contribuições no campo da filosofia, para essa disciplina. Mais especificamente na área de lógica, seu trabalho formou um alicerce crucial para as bases conceituais e metodológicas do desenvolvimento de algoritmos, que se tornaram um dos componentes fundamentais da Inteligência Artificial (IA) na atualidade.

Aristóteles, nascido em Estagira (384 a.C.), na península da Calcídica, Grécia, é amplamente reconhecido pelas suas teorias e ideias revolucionárias, que se espalharam por diversos campos do conhecimento humano (e.i., metafísica, filosofia da natureza, lógica, ética, retórica, entre outros). A 'lógica formal aristotélica', em particular, é considerada como sendo a base da lógica clássica, estabelecendo as bases do silogismo e os princípios fundamentais da contradição e da Lei do Terceiro Excluído: 'em uma proposição, ou ela é verdadeira, ou sua negação é verdadeira'. Seus trabalhos estruturaram a abordagem para uma linha de raciocínio contendo premissas, inferências e conclusões - um paradigma fundamental na concepção de algoritmos. Na sua essência, um algoritmo é 'uma sequência de passos lógicos e definidos para resolver um problema

ou executar uma tarefa'. A estrutura básica de um 'raciocínio válido', como proposto por Aristóteles, pode ser considerada como uma espécie de algoritmo pré-moderno.

Com a crescente proeminência dos sistemas de IA, os algoritmos, por sua vez, se tornaram vitais para a codificação de programas de computador e para a execução de tarefas específicas realizadas por modelos sofisticados, tais como o aprendizado de máquina (ML – 'machine learning') e o processamento de linguagem natural (PLN). Em muitos aspectos, a 'lógica subjacente' aos algoritmos contemporâneos pode, desta forma, ser considerada uma manifestação moderna da 'lógica formal clássica', criada por Aristóteles há mais de dois milênios. Suas contribuições se mostram ainda altamente impactantes, reverberando na arquitetura de algoritmos e, conseqüentemente, para os futuros avanços da IA. Essa intersecção entre filosofia e tecnologia serve como um testemunho do alcance e da relevância duradoura do pensamento humano.

Mitologia e Inteligência Artificial

Mesmo na mitologia e lendas oriundas da história antiga, referências ao que hoje consideramos como elementos componentes da inteligência artificial podem ser encontrados em diversas partes do mundo. A linha de base que une uma coletânea tão diversa está na vontade de o ser humano criar uma nova existência, e gerar um "ser independente"... em outras palavras, "brincar de Deus". Eis alguns exemplos:

37

Talos: na mitologia grega, Talos era um autômato de bronze criado por Hefesto, o deus do fogo e da metalurgia. Segundo a lenda, Talos foi presenteado com vida pelos deuses para proteger a ilha de Creta dos invasores. Ele patrulhava as praias da ilha e atirava pedras em navios que se aproximavam. Talos era movido por uma chama divina, que ardia em seu interior, e tinha apenas uma veia de sangue em uma das pernas, que estava conectada a uma âncora. Quando essa veia era removida, o autômato se desligava. Talos representa um dos primeiros relatos de uma criação artificial com a finalidade de realizar uma tarefa específica.

Talos, o autômato de bronze da mitologia grega, pode ser associado à inteligência artificial devido à sua capacidade de executar tarefas específicas e sua autonomia limitada. Embora a criação de Talos seja baseada em crenças mitológicas e místicas, o conceito de um ser artificial criado para proteção e realização de tarefas específicas pode ser comparado aos robôs autômatos modernos. Essa comparação destaca a ideia de criar máquinas inteligentes para realizar tarefas humanas.

38

Pigmalião e Galatea: Pigmalião era um escultor de Chipre mencionado na mitologia grega. Ele esculpiu uma estátua de marfim tão perfeita e bela que se apaixonou por ela. Pigmalião chamou a estátua de Galatea e desejava que ela fosse uma mulher real. Com suas orações e súplicas aos deuses, ele pediu que dessem vida à estátua. Sua devoção atraiu a atenção de Afrodite, a deusa do amor, que atendeu seu desejo. Galatea ganhou vida e se tornou sua esposa. A história de Pigmalião e Galatea explora a ideia do amor por uma criação artificial e a busca pela perfeição na reprodução da forma humana.

A história de Pigmalião e Galatea, na qual um escultor se apaixona por sua criação e deseja que ela se torne viva, pode ser interpretada como uma alegoria para a criação de uma

inteligência artificial que se assemelhe à forma humana. A história levanta questões sobre a relação entre criador e criação, a busca pela perfeição e a possibilidade de conceder vida a uma entidade artificial.

39

O Golem de Praga: o Golem de Praga é uma figura lendária da tradição judaica. Segundo a lenda, o rabino Judah Loew ben Bezalel, conhecido como Maharal, criou um ser humano artificial chamado Golem usando misticismo e magia. O Golem foi moldado a partir de argila e trazido à vida por meio de rituais e inscrições sagradas em sua testa. Ele foi criado com o propósito de proteger a comunidade judaica do gueto de Praga, enfrentando ameaças externas. No entanto, o Golem era uma criação poderosa e, com o tempo, se tornou descontrolado e perigoso. Para desativá-lo, o rabino teve que remover as letras hebraicas de sua testa, que davam vida ao Golem. A história do Golem de Praga levanta questões sobre os limites da criação artificial, a responsabilidade do criador e as consequências imprevistas de dar vida a uma entidade artificial.

Embora seja uma figura lendária, é frequentemente associado aos conceitos de inteligência artificial e criação artificial de vida. A história do Golem explora a ideia de um ser artificial criado para proteção e serviço, mas que eventualmente escapa do controle do criador. Essa narrativa levanta questões sobre a responsabilidade e os perigos de criar entidades autônomas.

40

Os autômatos de Hefesto: Na mitologia grega, Hefesto, o deus do fogo e da metalurgia, era conhecido por criar autômatos para auxiliá-lo em suas tarefas. Esses autômatos eram seres mecânicos dotados de vida artificial. Eles eram frequentemente retratados como ajudantes habilidosos nas oficinas de Hefesto, capazes de executar tarefas complexas relacionadas à metalurgia, forja e construção. Os autômatos de Hefesto exemplificam a crença grega antiga na capacidade de criar seres artificiais com habilidades sobre-humanas, que poderiam realizar tarefas que os humanos não conseguiam.

Na mitologia grega, Hefesto era conhecido como o deus do fogo, da forja e dos artesanatos. Ele era conhecido por criar autômatos para auxiliar em suas tarefas. Esses autômatos eram seres mecânicos dotados de vida artificial e eram frequentemente retratados como ajudantes habilidosos nas oficinas de Hefesto.

41

O Monstro de Frankenstein: O Monstro de Frankenstein é um personagem fictício criado por Mary Shelley em seu romance clássico "Frankenstein". O cientista Victor Frankenstein embarca em uma busca para criar vida a partir de partes de cadáveres. Ele monta o ser humano artificial e o traz à vida através de uma experiência científica ousada. No entanto, ao ver a aparência grotesca de sua criação, Victor se horroriza e o abandona. O Monstro, em busca de aceitação e amor, enfrenta rejeição e solidão, o que o leva a buscar vingança contra seu criador. A história de Frankenstein aborda temas como a responsabilidade do criador em relação à criação artificial, as consequências da rejeição e a natureza da humanidade.

O Monstro de Frankenstein é frequentemente associado à inteligência artificial devido à sua criação artificial e à exploração de temas éticos e morais relacionados à vida artificial.

A história de Frankenstein questiona as responsabilidades do criador em relação à criação e à consideração dos direitos e do tratamento justo das entidades artificiais. Essa narrativa destaca os dilemas éticos e as consequências da criação irresponsável de seres artificiais.

As referências fornecidas discutem as associações dos personagens mitológicos com a inteligência artificial e podem fornecer informações adicionais para aprofundar sua pesquisa sobre esses tópicos. Lembre-se de que essas histórias são mitológicas, fictícias ou literárias e não são baseadas em fatos científicos. No entanto, elas têm influenciado o imaginário coletivo e a discussão sobre os desafios éticos, morais e filosóficos relacionados à inteligência artificial ao longo dos anos. Certifique-se de contextualizar esses personagens dentro dessa perspectiva ao escrever seu trabalho.

Algoritmos

2

Os algoritmos, conceitos fundamentais para os campos da matemática e da computação, têm suas origens nos trabalhos de matemáticos da Babilônia, Pérsia e Egito da antiguidade. Essas ferramentas - primitivas mas poderosas, permitiram se alcançar a solução de problemas complexos de cálculo e processamento de dados, precursores dos desafios hoje resolvidos com modernos algoritmos de IA.

A evolução dos algoritmos pode ser associada à evolução dos trabalhos de matemáticos e engenheiros ao longo da história, enquanto aplicavam princípios, regras e procedimentos simples para resolver diversos problemas matemáticos e práticos. Essas regras - ou algoritmos, foram utilizados para se resolver cálculos complexos, processamento avançado de dados e até mesmo o desenvolvimento (e a quebra) de códigos. Sua transcendeu a matemática como campo teórico e se tornou fundamental em muitas outras áreas, incluindo engenharia, física, informática e, mais recentemente, a IA.

Os algoritmos aplicados em sistemas de IA são especialmente notáveis, pois permitem que máquinas imitem a capacidade humana de aprender e tomar decisões. Esses algoritmos (alguns de natureza bem complexa, e uma grande parte considerada como simples) usam conjuntos de regras e instruções para permitir o processamento de grandes quantidades de dados, o aprendizado e, em última análise, a tomada de decisões e a realização de tarefas baseadas em suas 'experiências' de aprendizado contínuo.

Inovações e práticas conceituais históricas.

O desenvolvimento histórico do processamento da informação, vem desde seus primórdios com o uso de dispositivos manuais até a chegada dos computadores eletrônicos.

3

Um exemplo notável de aplicação do processamento da informação é a **Máquina de Antikythera**, um dispositivo mecânico antigo encontrado na Grécia, que é considerado um precursor dos autômatos.

4

O desenvolvimento do processamento de informações tem suas raízes na utilização de dispositivos primitivos empregados para cálculos simplificados, contagens, medições e tarefas relacionadas com a manipulação de dados para gerar novas informações. Ao longo

da história, estes dispositivos evoluíram continuamente, desde simples instrumentos manuais até calculadoras mecânicas sofisticadas e, posteriormente, computadores eletrônicos. Tal evolução delineia a maneira como as informações são processadas e armazenadas. Entre as primeiras soluções de aplicação das formas mecanizadas de processamento de dados, destacam-se:

1. **O Ábaco:** um dos primeiros dispositivos de cálculo, utilizado principalmente para operações de adição e subtração. Ele foi utilizado por várias civilizações antigas, incluindo os babilônios, gregos, romanos e chineses. (Referência: Ifrah, G. (2001). *The universal history of computing: from the abacus to the quantum computer*. New York: Wiley)
2. **Os ossos de Napier:** um conjunto de hastes de cálculo criado pelo matemático escocês John Napier no século XVI para auxiliar na realização de operações matemáticas complexas. (Referência: Williams, M. R. (1997). *A history of computing technology*. IEEE Computer Society)
3. **A régua de cálculo:** um antigo dispositivo de cálculo mecânico, que utiliza uma escala logarítmica para realizar operações como multiplicação e divisão, raízes quadradas e cúbicas, e outras funções matemáticas. Foi largamente utilizada por engenheiros e cientistas antes da invenção da calculadora eletrônica. (Referência: Cajori, F. (1910). *A History of the Logarithmic Slide Rule and Allied Instruments*. The Engineering News Publishing Company)

Todos esses dispositivos representaram os primeiros passos na longa jornada do processamento de informação, culminando na 'era digital' em que vivemos hoje, um 'mundo digital' onde encontramos a 'sociedade da informação'.

Marcos significativos na história e evolução de IA.

5

O conceito de automação se refere à utilização de tecnologia, particularmente nos campos da computação e robótica, para realizar tarefas que normalmente exigiriam intervenção humana. Este conceito remonta aos primórdios da era industrial, onde máquinas começaram a substituir o trabalho humano em diversas tarefas.

Contudo, foi com o advento da inteligência artificial (IA) que a automação ganhou uma nova dimensão. Nos dias atuais, a automação abrange uma variedade muito maior de tarefas e aplicações, desde a fabricação industrial até a prestação de serviços. Com o avanço da IA, a automação está se tornando cada vez mais abrangente e encontrando novas maneiras de agregar valor, sendo capaz de realizar tarefas cada vez mais complexas e criativas com o apoio de sistemas de IA.

Autômatos

A concepção e criação dos primeiros autômatos, também conhecidos como máquinas "auto-operadas", remonta a momentos históricos importantes. Neste campo, avanços significativos ocorreram durante a Idade Média e a Renascença, com o surgimento de autômatos hidráulicos. Esses primeiros autômatos foram fontes de inspiração para o desenvolvimento de robôs e outras formas de inteligência artificial (IA).

Jacques de Vaucanson foi um notável engenheiro e inventor (1709 – 1782, França), que contribuiu enormemente para o desenvolvimento do campo da atuação mecânica. Além de suas obras mais famosas, como o Pato Mecânico e o "Flautista" (infelizmente foram perdidas), também desenvolveu componentes mecânicos importantes para a indústria.

6

Outro exemplo clássico é o **Turco Mecânico**. Este foi um famoso autômato, criado ao final do século XVIII, sendo apresentado ao público como uma máquina capaz de jogar xadrez autonomamente. Era, no entanto, na verdade, uma sofisticada farsa - havia um mestre de xadrez habilmente escondido dentro do aparato, controlando seus movimentos. Mesmo assim, se tornou um marco para o conceito de automação, devido à complexidade de seu sistema de engrenagens e polias.

Além disso, o **Turco Mecânico** representa um dos primeiros exemplos que poderiam ser associados ao conceito da 'inteligência artificial'. Embora a máquina não fosse verdadeiramente autônoma, alimentou a imaginação popular e provocou reflexões sobre a capacidade de se criar máquinas que pudessem imitar, e até mesmo superar, a inteligência humana. Sendo assim, é vista como um símbolo do potencial humano para a inovação e o progresso, na imitação da inteligência humana.

Mecanização

7

O conceito de mecanização envolve o emprego de máquinas e ferramentas para desempenhar tarefas geralmente executadas manualmente, especialmente aquelas que envolvem trabalho físico repetitivo. A mecanização tem sido um elemento crucial na evolução da industrialização, permitindo aprimoramentos significativos em termos de eficiência, velocidade e precisão nos processos de produção.

Um exemplo clássico da mecanização pode ser visto nas sociedades antigas, onde a roda d'água era utilizada para substituir tarefas manuais, como a moagem de grãos. Este é um exemplo de tecnologia mecânica, onde a força da água era usada para realizar um trabalho. Outros engenhos semelhantes, tais como moinhos de vento e aqueles acionados por bestas de carga, também foram prevalentes desde este período da história humana.

A mecanização tem sido instrumental na transformação de indústrias, desde a agricultura até a manufatura, permitindo maior produção com menos esforço humano. No entanto, com o advento da inteligência artificial (IA), a mecanização ganhou uma nova camada de complexidade (informação). Alguns sistemas "inteligentes" começaram a ser integrados aos dispositivos mecânicos tradicionais, permitindo incrementos mais sofisticados e a realização de tarefas mais complexas. Mais tarde, com o emprego de novas fontes de

energia (tais como máquinas a vapor), a mecanização passaria a dar saltos maiores no progresso de novos mecanismos de mecanização do trabalho humano.

O Tear de Jacquard

8

O **Tear de Jacquard**, criado em 1801 por Joseph Marie Jacquard, representa um marco significativo na história da mecanização. Foi a primeira máquina a utilizar cartões perfurados para controlar o padrão do tecido produzido, proporcionando um nível inédito de flexibilidade e complexidade na indústria têxtil. O conhecimento e a expertise necessários para se produzir materiais de qualidade e de alto valor agregado, antes restritos ao conhecimento de um mestre artesão, agora poderiam ser replicados em maior volume, ampliando o potencial manufatureiro do setor.

Além de haver revolucionado a produção têxtil, o 'Tear de Jacquard' também é considerado um dos precursores da automatização e um exemplo primordial do uso de "algoritmos e dados" na coordenação inteligente de processos de manufatura. Os cartões perfurados usados para programar o tear foram uma inspiração para os sistemas de processamento de dados do século XX, estabelecendo as bases para o conceito de programação de máquinas - um elemento central na evolução da inteligência artificial.

Mecanização x automatização(autonomação) x automação

Mecanização	Autonomação	Automação
Operador acompanha e realiza parte do processo	Operador com controle restrito a comandos. Operador de máquina opera simultaneamente várias máquinas	Controle realizado pela máquina com acompanhamento do operador
Não existência de preocupação formal no repasse das atividades cerebrais realizadas pelas pessoas para as máquinas	Máquinas são providas de uma função de cérebro humano, ou seja, a capacidade de detectar anormalidades de forma autônoma	Máquinas automatizadas não estão dotadas de cérebro humano.
A Responsabilidade pela qualidade das peças produzidas pela máquina é do operador	Controle autônomo de qualidade, defeitos e quantidades em um processo. As causas dos defeitos são investigadas imediatamente, e uma ação corretiva é implementada	O sistema calcula a ação corretiva mais apropriada
Considerado um componente dentro da Troca Rápida de Ferramentas como forma de reduzir o "setup" das máquinas		Utilizada para completar a integração do STP a partir de uma operação automatizada.
	Produtos flexíveis, de baixo custo e qualidade superior	Atividade meio para melhorar a integração e a flexibilização em um processo produtivo
	Recursos são minimizados: materiais e trabalhadores mínimos	

Fonte: Kuiawinski e Luz, 2006

A mecanização consiste em trocar uma atividade ou fluxo de trabalho (conjunto de atividades) realizadas por um ser humano pelo sistema de trabalho executado por uma máquina, substituindo ou minimizando o esforço físico; a automatização permite que esse equipamento seja "gerenciado por um usuário" – integrando controles restritos com foco


adicional ao desempenho do fluxo de processos na empresa, e aumentando as responsabilidades do mesmo.

Enquanto que a automatização foca no trabalho realizado e modos de controle do mesmo, a automação torna um processo ou sistema automático ("semi-independente" ou auto-gerido) e refere-se tanto a serviços executados como aos resultados e produtos fabricados automaticamente, permeados pelas tarefas de intercâmbio de informações.

A(s) Revolução(ões) Industrial(is)

9

A Revolução Industrial – no seu contexto clássico, ocorreu entre os séculos XVIII e XIX, e foi um período marcado por inovações e mudanças tecnológicas que transformaram indústrias tradicionais da época (ainda que de maneira incipiente) e moldaram a sociedade de modo sem precedentes. Esta foi referida como a "primeira" Revolução Industrial, gerando significativo impacto sobre os aspectos sociais, econômicos e tecnológicos da vida cotidiana e dos processos fabris que, até então, havia mudado muito pouco (em sua essência) desde a Renascença.



COSTA, C. A. Indústria 4.0: O futuro da Indústria nacional. Disponível em: <<http://seer.spo.ifsp.edu.br/>>. Acesso em: 08 jul. 2018 (adaptado).

Quanto ao impacto subsequente nas tecnologias de inteligência artificial, a Revolução Industrial foi um marco essencial no desenvolvimento da "tecnologia da era moderna". As inovações e os avanços tecnológicos de cada uma de suas fases ou períodos estabeleceram a base para as novas mudanças que vieram a seguir:

1. Século XIX - a chamada "segunda" Revolução Industrial trouxe avanços significativos, tais como a disseminação da eletricidade e o estabelecimento de processos de produção em massa. Entre seus efeitos, se pode citar o aumento da atividade comercial (por meio da expansão da oferta de baixo custo, e de novos meios de transporte e inovações na cadeia de suprimentos. Também aumentou a incidência de doenças e problemas urbanos decorrentes, assim como taxas de desemprego coexistindo com uma oferta mais barata de mão de obra.
2. Século XX - a "terceira" Revolução Industrial foi caracterizada pela automação baseada em eletrônica, informática e cibernética, principalmente no período após a Segunda guerra Mundial. Foi notável o aumento de adoção de novas tecnologias nas empresas e na sociedade (alterando as relações entre as pessoas - e entre o homem e o seu ambiente), apoiadas por novas e significativas descobertas científicas em diversos campos do conhecimento. A inovação se tornou um dos motores principais desta "revolução tecno-científica", amplificado pelo aumento da velocidade com que informações se propagam.

3. Século XXI - a "quarta" Revolução Industrial, também conhecida como Indústria 4.0, é marcada pelo desenvolvimento da inteligência artificial e sua integração em diversos setores. engloba um amplo sistema de tecnologias avançadas como inteligência artificial, robótica, internet das coisas, biotecnologia, computação quântica, impressão 3D, e computação em nuvem (entre outros) que hoje impactam, em igual proporção, as formas de produção e os modelos de negócios, derrubando fronteiras e dinamizando relações pessoais e comerciais no mundo todo. Se, na revolução anterior o principal aspecto focava na velocidade de transmissão da informação, nesta se dá a permeabilidade, compartilhamento e transformação da informação (dados) de maneira mais customizada e integrada (descentralização da informação, com maior rapidez, fluidez e aplicabilidade, gerando valor mais rapidamente) aos demais processos, o que transforma o conhecimento e provê novas oportunidades e possibilidades.

Dentre as inúmeras invenções e avanços tecno-científicos que contribuíram para o surgimento da IA, podemos citar:

A Máquina Analítica de Charles Babbage

10

A Máquina Analítica, concebida entre 1830 e 1840 pelo matemático e engenheiro mecânico Charles Babbage, pode ser considerada a precursora do computador digital programável. Ada Lovelace, uma matemática de destaque da época, escreveu extensivamente sobre a Máquina Analítica de Babbage, chegando a desenvolver um algoritmo destinado a ser processado por essa máquina, o que é considerado o primeiro programa de computador do mundo.

As principais contribuições da Máquina Analítica de Babbage incluem:

1. **Contribuição Conceitual:** O projeto de Babbage introduziu a ideia de usar uma máquina para realizar cálculos complexos, estabelecendo assim a fundação para a computação moderna.
2. **Contribuição Metodológica:** A Máquina Analítica foi projetada para realizar processos algorítmicos e era capaz de 'ramificações e loops condicionais', conceitos fundamentais na programação de computadores e na inteligência artificial.
3. **Contribuição Inspiracional:** O trabalho de Babbage inspirou inúmeros inovadores nos campos da computação e da inteligência artificial, influenciando o desenvolvimento subsequente dessas disciplinas.

Atividade individual #1

Converse com o avatar IA do famoso filósofo e pensador Aristóteles, e explore os temas discutidos nesta parte da apostila.

Busque interagir com o máximo possível de temas e conceitos apresentados, para obter uma importante pista, como parte do segredo que levará ao prêmio final.

Clique no código QR para acessar o avatar, ou digite:

<http://tinyurl.com/filosia>



Introdução à Inteligência Artificial na era moderna

A computação eletrônica e a inteligência artificial (IA) são dois campos intimamente relacionados da ciência da computação. A computação eletrônica é o estudo de como os computadores funcionam, enquanto a IA é o estudo de como fazer os computadores pensarem.

A computação eletrônica e a IA podem ser associados pelo uso de hardware - os componentes físicos de um computador, tais como CPU / GPU, memória (RAM / ROM) e dispositivos de armazenamento, entre outros. Os sistemas de IA dependem de hardware para executar suas tarefas, determinadas por software especializado. Por exemplo, um sistema de IA que precisa reconhecer imagens utilizará uma unidade de processamento gráfico (GPU) para acelerar o processamento de dados de imagem, além de sensores e outros periféricos.

Sobre o uso de software - as instruções que determinam ao computador o que fazer, sistemas de IA o utilizam para implementar seus algoritmos e processos baseados em lógica. Por exemplo, um sistema de IA utilizado para jogar xadrez utilizará software especialista para implementar as regras do xadrez e tomar decisões estratégicas.

Finalmente, a computação eletrônica e a IA se baseiam na utilização de dados - as informações brutas usadas para treinar e avaliar sistemas de IA. Uma parte significativa dos sistemas de IA atuais precisam de ser treinados em grandes quantidades de dados (Big Data), para aprenderem como executar suas tarefas. Por exemplo, um sistema de IA que precisa reconhecer rostos será treinado em um conjunto de dados de imagens de rostos capturado de uma amostra populacional determinada.

Computação Eletrônica

11

A computação eletrônica, que surgiu entre as décadas de 1930 e 1940, se baseia no emprego de dispositivos eletrônicos, como tubos de vácuo e transistores, para manipular dados e efetuar operações matemáticas complexas. O primeiro computador digital eletrônico, o **ENIAC** (*Electronic Numerical Integrator and Computer*), desenvolvido durante a Segunda Guerra Mundial, marcou o advento da era moderna da computação eletrônica. Projetado para realizar cálculos complexos para a criação de tabelas de trajetórias de artilharia, o ENIAC foi um precursor vital dos sistemas de computação modernos. O uso de dispositivos eletrônicos permitiu cálculos mais rápidos, confiáveis e volumosos, em comparação com seus predecessores mecânicos e eletromecânicos.

Na década de 1940 a 1950, a disciplina da cibernética lançou as bases para o desenvolvimento da inteligência artificial (IA). Ela explorou o conceito de que as máquinas podem ser programadas para processar e analisar informações, aprender com a experiência e tomar decisões baseadas nas informações adquiridas.

Controladores Lógicos Programáveis

12

Durante a década de 1960, surgiram os Controladores Lógicos Programáveis (**PLCs**), uma alternativa inovadora aos sistemas de controle eletromecânicos baseados em relés. Projetados para permitir aos operadores modificar facilmente a lógica de controle por meio de programação, substituindo a necessidade de reconexão física dos sistemas de controle tradicionais. PLCs permitiam superar as limitações desses sistemas, propondo um meio altamente confiável e flexível para gerenciar processos industriais. A introdução dos PLCs marcou o início de uma nova era no controle da automação industrial, o que levou a melhorias significativas na eficiência e na produtividade nas operações industriais.

Os PLCs representaram mais do que apenas uma evolução no controle industrial. Eles também abriram caminho para a integração da inteligência artificial (IA) nos sistemas de controle industrial. A programação adaptável e complexa dos PLCs demonstrou que as máquinas poderiam ser projetadas para além das operações determinísticas tradicionais, com a capacidade de otimizar o desempenho do sistema e se adaptar a novas situações.

A Inteligência Artificial Moderna (marcos significativos)

13

A história da inteligência artificial (IA) é uma fascinante narrativa de descoberta e inovação, uma jornada que nos leva - desde os primórdios da computação, até o cenário atual de automação e aprendizado de máquina. Esta narrativa se desenrola a partir de uma época em que a ideia de "máquinas pensantes" era pura ficção científica, para uma era onde a IA está profundamente enraizada em nossa vida cotidiana e influencia quase todos os aspectos da sociedade atual - a sociedade da "informação".

Com o passar dos anos, a IA continuou a evoluir e a se expandir em novas direções. No século XXI, a integração de algoritmos de aprendizado de máquina e redes neurais nas tecnologias de automação permitiu a criação de sistemas capazes de aprender e melhorar com a experiência, abrindo novos horizontes para a IA e ampliando ainda mais sua aplicabilidade.

Hoje, a inteligência artificial está transformando a maneira como vivemos e trabalhamos, impulsionando inovações em campos tão diversos quanto medicina, finanças, transporte e entretenimento. No entanto, a jornada da IA está longe de terminar. À medida que continuamos a explorar as possibilidades dessa tecnologia revolucionária, podemos apenas imaginar o que o futuro reserva.

Máquina Enigma

16

A Máquina Enigma foi uma invenção significativa do engenheiro alemão Arthur Scherbius em 1918. Sua finalidade era criptografar mensagens de texto usando uma cifra iterativa Morse para impedir que informações secretas caíssem em mãos inimigas durante a Segunda Guerra Mundial. Essa máquina, baseada em um sistema de rotores, usava um mecanismo de codificação complexo que mudava constantemente, tornando extremamente difícil decifrar as mensagens sem conhecer as configurações exatas do dispositivo.

No entanto, o Colossus, um computador eletrônico digital desenvolvido pelos britânicos durante a Segunda Guerra Mundial, foi projetado para decifrar os códigos gerados pela Enigma. O trabalho de decifração da Enigma foi liderado por Alan Turing e sua equipe em Bletchley Park, Reino Unido.

Embora a Enigma e o Colossus não sejam diretamente relacionados à Inteligência Artificial, eles foram marcos significativos na história da computação. A Enigma demonstrou a possibilidade de usar máquinas para codificar informações de maneira complexa, enquanto o Colossus representou um dos primeiros usos de computação em grande escala para resolver problemas complexos.

A contribuição desses dispositivos para a IA é indireta, mas significativa: eles estabeleceram as bases para a computação digital, que é fundamental para o desenvolvimento de algoritmos de IA. Além disso, a abordagem usada para quebrar o código da Enigma antecipou algumas das técnicas usadas na IA moderna, como algoritmos genéticos e busca heurística.

Descrição das partes operacionais da Máquina Enigma

17

1. Sistema elétrico (baterias - 1): A máquina Enigma era alimentada por baterias. Estas forneciam a energia necessária para fazer funcionar todos os componentes elétricos do dispositivo.
2. Chave bidirecional de códigos (2): Uma chave bidirecional era usada para codificar e decodificar mensagens. Esta chave permitia selecionar as configurações específicas para codificar a mensagem e depois usar a mesma chave para decodificar a mensagem no outro extremo.
3. Interface no quadro de tomadas (3): A interface no quadro de tomadas era usada para conectar a máquina a outros dispositivos. Isso permitia que a Enigma fosse usada em conjunto com outros equipamentos de codificação e decodificação.
4. Entrada para rodas de encriptação (4): A entrada para as rodas de encriptação permitia que o operador inserisse a chave de codificação. Estas rodas, cada uma com uma configuração única, eram uma parte crucial do mecanismo de codificação da Enigma.
5. Rotores Wehrmacht ou Kriegsmarine (5): Os rotores, conhecidos como rotores Wehrmacht ou Kriegsmarine, eram uma parte essencial da Enigma. Cada rotor tinha um padrão de fiação único que, quando combinado com os outros rotores, criava um número quase infinito de possibilidades de codificação.
6. Refletor de corrente (6) com retorno de corrente nos rotores (5 / 4): O refletor de corrente era um componente que redirecionava a corrente elétrica de volta através dos rotores, mas em um caminho diferente. Isso aumentava ainda mais a complexidade do processo de codificação.

7. Sinal para quadro de tomada (7): Uma vez que a mensagem fosse codificada, um sinal seria enviado para o quadro de tomadas, indicando que o processo de codificação estava completo e que a mensagem estava pronta para ser enviada.
8. Transmissão no cabeamento (8): O cabeamento era usado para transmitir a mensagem codificada do dispositivo Enigma para o dispositivo receptor.
9. Segunda válvula bidirecional para iluminação da lâmpada (9): A segunda válvula bidirecional controlava a iluminação da lâmpada. As lâmpadas eram usadas para indicar a letra codificada resultante do processo de codificação.

1944 – A MÁQUINA DE TURING (SISTEMA BINÁRIO)

O Colossus: Uma Revolução na Computação

18

No campo da computação, o desenvolvimento do Colossus, um computador eletrônico criado pelo renomado matemático Alan Turing durante a Segunda Guerra Mundial, foi um marco histórico significativo. O Colossus tinha como objetivo específico o de decifrar códigos alemães gerados pelo sistema Enigma (eletromecânica). Sua eficácia foi comprovada na quebra de códigos em tempo hábil: em menos de 24 horas, tornando-se uma arma crucial no que viria a ser um ponto central de guerra cibernética.

O Colossus: foi projetado e construído no Reino Unido, na década de 1940, como uma máquina analítica de alta velocidade. Era baseado em princípios teóricos avançados, sendo o precursor dos modernos computadores eletrônicos. Sua concepção revolucionária permitiu a manipulação automatizada de símbolos em uma fita de papel, de acordo com uma tabela de regras predefinidas. Essa capacidade de implementar algoritmos diversos fez do Colossus um pioneiro no campo da computação.

O Impacto do Colossus: após a guerra, outras versões mais aprimoradas do Colossus foram instaladas na Universidade de Manchester, se tornando os primeiros computadores eletrônicos de uso geral, conhecidos como "Baby". Essa transição do Colossus para o Baby marcou o início de uma nova era na história da computação, estabelecendo as bases para a computação eletrônica moderna.

O Colossus e o Centro de Processamento de Dados: as primeiras versões do Colossus trabalhavam em conjunto, dentro do primeiro Centro de Processamento de Dados (CPD) da história moderna. Constituído um ambiente de gestão pioneiro, foi projetado para otimizar o esforço humano, com o objetivo de quebrar códigos de comunicação criptografados utilizados pelos alemães. A colaboração gerada através de sucessivas gerações do Colossus permitiu uma velocidade e eficiência sem precedentes no processo da quebra de códigos.

Alan Turing e o Legado do Colossus: o trabalho realizado por Alan Turing e sua equipe no desenvolvimento do Colossus foi monumental. Seu pensamento visionário, aliado ao poder computacional do Colossus, proporcionou uma vantagem crítica aos Aliados durante a guerra. Além disso, estabeleceu os fundamentos da computação moderna e influenciou diretamente as subsequentes gerações de computadores eletrônicos.

1950 - O TESTE DE TURING: DESVENDANDO A FRONTEIRA ENTRE HUMANOS E MÁQUINAS

19

Introdução

O "Teste de Turing" (1950) é um experimento proposto por Alan Turing, que

busca determinar a capacidade de uma máquina em imitar o comportamento humano, de tal forma que seja indistinguível do de uma pessoa. Nesse teste, há três participantes que não têm acesso entre si, comunicando-se apenas por texto: o usuário (C), que atua como o "avaliador", e os "interlocutores"




Figura 3 - Teste de Turing (Wikipedia)

(A e B). O objetivo do "avaliador C" é determinar qual dos "interlocutores": "A" ou "B", é um computador substituindo um humano. "C" se baseia apenas nas respostas às suas perguntas, dadas pelos interlocutores, para tomar essa decisão. Durante o teste, o "interlocutor B" tenta enganar o "avaliador C", induzindo à tomada de decisão incorreta, enquanto o "interlocutor A" auxilia o "avaliador C" a fazer a escolha certa. O modelo do teste foi baseado em um jogo de salão, popular na Inglaterra daquele período.

O questionamento proposto por Turing: Turing levantou uma questão intrigante: "O que acontecerá quando uma máquina assumir o papel de ""? O avaliador decidirá erroneamente e com a mesma frequência de quando com interlocutores humanos?" Essa indagação levanta a possibilidade de que uma máquina possa se passar por um ser humano de maneira tão convincente, que o "avaliador C" cometerá erros na identificação.

Reflexões sobre o Teste de Turing: teste suscita debates acalorados no campo da IA e no da filosofia. Enquanto alguns argumentam que o teste é uma medida adequada para aferir a "inteligência" das máquinas, outros afirmam que ele é limitado e não captura completamente a complexidade do pensamento humano. A discussão em torno desse teste continua a estimular pesquisas e avanços na área de IA.

MARCOS DA INTELIGÊNCIA ARTIFICIAL NO SÉCULO XX

Logic Theorist

20

O "Logic Theorist" foi o primeiro programa de computador a ser chamado de "mecanismo de inferência", desenvolvido por Allen Newell, J.C. Shaw e Herbert A. Simon na RAND hojeCorporation (1955). Este programa é j considerado como o primeiro programa de inteligência artificial.

O "Logic Theorist" foi projetado para simular a resolução de problemas matemáticos, imitando as habilidades humanas, usando uma variedade de métodos heurísticos (enquadramento intuitivo de problemas para encontrar soluções). O programa foi capaz de provar 38 dos primeiros 52 teoremas propostos na obra "Principia Mathematica" de

Russell e Whitehead e, em um caso, propôs uma prova mais eficiente do que a que já havia sido demonstrada.

A arquitetura deste sistema foi baseada em um método conhecido como "busca em espaço de estados"¹, ainda usado em muitos programas de inteligência artificial. No "Logic Theorist", o "espaço de estados" era uma representação do problema que estava sendo resolvido, permitindo que o programa navegasse por este "espaço" para encontrar uma solução.

O "Logic Theorist" inspirou uma série de desenvolvimentos subsequentes na inteligência artificial. Baseado no mesmo, seus próprios autores criaram, em seguida, o "General Problem Solver" (GPS) - um programa mais avançado, podendo ser aplicado a qualquer problema que pudesse ser estruturado como um "espaço de estados".

Perceptron

21

O Perceptron é um algoritmo de aprendizado de máquina baseado em uma "rede neural artificial" simples. Foi desenvolvido por Frank Rosenblatt (1958) enquanto trabalhava para o Cornell Aeronautical Laboratory, em Nova York.

O Perceptron representa o modelo mais simples de uma rede neural artificial, com apenas uma única camada. Este modelo busca imitar a função de um neurônio no cérebro humano, que recebe entradas, as processa e produz uma saída. O Perceptron recebe várias entradas, e cada uma é multiplicada por um peso determinado. Essas "entradas ponderadas" são somadas e, em seguida, passadas por uma função de ativação para produzir uma determinada saída.

Na década de 1960, o Perceptron era visto como um promissor caminho para o desenvolvimento da inteligência artificial. No entanto, em uma análise feita por Marvin Minsky e Seymour Papert em seu livro "Perceptrons" (1969), se demonstrou que os Perceptrons tinham limitações significativas - eles não podiam resolver problemas que não fossem linearmente separáveis. O principal impacto deste ocorrido foi a desaceleração da pesquisa em redes neurais, durante muitos anos.

No entanto, com o advento das "redes neurais multicamadas" e algoritmos do tipo "backpropagation"², nos anos 80, foi possível superar muitas das limitações dos Perceptrons originais, dando origem ao que hoje é conhecido como "aprendizado profundo".

Atualmente, o conceito do Perceptron é fundamental para muitas tecnologias modernas de aprendizado de máquina e inteligência artificial. A arquitetura básica do Perceptron evoluiu para o que hoje são conhecidos como "neurônios artificiais em redes neurais profundas". Estas redes estão por trás de uma grande variedade de aplicações, desde a condução

¹ PEREIRA, Silvio L; disponível em <https://www.ime.usp.br/~slago/IA-Busca.pdf>, visitado em 01 de abril de 2023

² Wikipedia; disponível em <https://en.wikipedia.org/wiki/Backpropagation>, visitado em 01 de abril de 2023

autônoma até os sistemas de recomendação, a tradução automática de línguas e a análise de sentimentos.

Eliza

22

ELIZA é um dos primeiros programas de processamento de linguagem natural, hoje reconhecido como o primeiro "chatbot". Foi desenvolvido por Joseph Weizenbaum no MIT Artificial Intelligence Laboratory (1964-1966).

O objetivo do ELIZA era demonstrar a superficialidade da comunicação entre seres humanos e máquinas. Weizenbaum ficou surpreso quando descobriu que muitas pessoas atribuíam à ELIZA um determinado entendimento e empatia com emoções humanas, apesar de saberem que se tratava apenas de um programa de computador.

Características e operação de ELIZA: simulava uma conversa humana ao utilizar um "roteiro", chamado DOCTOR, que lhe permitia agir como um psicoterapeuta Rogeriano³. Este roteiro permitiu ao ELIZA fornecer respostas não-direcionais, à maneira de um terapeuta, tais como: "Fale-me mais sobre isso...", ou "Por que você acredita que se sente dessa maneira?".

O modelo de operação básico do ELIZA era bastante simples. Procurava palavras-chave fornecidas pelo usuário e, se uma correspondência era encontrada, uma resposta preexistente no roteiro era apresentada. Quando várias palavras-chave eram encontradas, a que tinha a maior valor de classificação era usada para determinar a resposta. Caso nenhuma palavra-chave correspondente fosse encontrada, o ELIZA retornava uma resposta genérica.

Aplicações modernas e legado do ELIZA: embora tenha sido criado apenas como uma demonstração - e não tivesse a intenção de passar um Teste de Turing ou de ser um assistente virtual sofisticado, o ELIZA se tornou um legado importante para o campo da Inteligência Artificial. Ele abriu o caminho para o desenvolvimento de chatbots mais avançados e programas de processamento de linguagem natural. Hoje, assistentes virtuais, como *Siri*, *Alexa* e *Google Assistant*, usam técnicas muito mais sofisticadas de processamento de linguagem natural, mas a ideia básica de simular uma conversa humana remonta ao ELIZA.

Arpanet

23

A ARPANET (Advanced Research Projects Agency Network) foi a precursora da internet moderna, um projeto financiado pelo Departamento de Defesa dos Estados Unidos (DARPA - Defense Advanced Research Projects Agency) e lançado em 1969.

A ARPANET foi concebida por uma equipe de cientistas e engenheiros, liderados por Joseph Carl Robnett Licklider e Robert Taylor. O objetivo principal era criar uma rede de

³ Psicologias do Brasil (2021); disponível em <https://www.psicologiasdobrasil.com.br/no-que-consiste-a-terapia-rogeriana/>, visitado em 01 de abril de 2023

computadores que permitisse a comunicação entre diferentes instituições de pesquisa e universidades, mantendo-se ativa mesmo em caso de falhas parciais na rede.

O primeiro teste de conexão bem-sucedido da ARPANET foi realizado em 29 de outubro de 1969, quando uma mensagem foi enviada de um computador "host" - da Universidade da Califórnia (UCLA), para um computador "host" do Stanford Research Institute (SRI).

Inicialmente, a ARPANET utilizou a tecnologia de "comutação de pacotes", então um novo método de transmissão de dados, que permite que os dados sejam divididos em pequenos pacotes e enviados pela rede. Esta técnica é hoje o modelo geral adotado na transmissão de dados na internet.

Em relação à Inteligência Artificial, a ARPANET não foi projetada com essa finalidade, mas teve um impacto significativo no campo. Ao viabilizar a colaboração entre pesquisadores de IA em diferentes locais, viabilizou a troca de recursos e a difusão de novos programas e dados. Isso impulsionou o avanço da IA, por meio de um ambiente altamente colaborativo, necessário para o progresso da pesquisa. Além disso, a disponibilização de grandes volumes de dados online e a capacidade de distribuição do poder computacional por toda a rede ARPANET, foram elementos cruciais para os avanços em áreas importantes, tais como os do aprendizado de máquina e do processamento de linguagem natural.

O Inverno da Inteligência Artificial

24

O "Inverno da IA" é uma expressão que se refere a um período no qual o interesse, o financiamento e o progresso no campo da Inteligência Artificial (IA) sofreram uma significativa redução, durante a década de 1980. Este "inverno" ocorreu como resultado de uma combinação de fatores, dentre os quais:

1. Expectativas não correspondidas: durante os primeiros anos da IA, houve um otimismo exacerbado sobre o que a tecnologia poderia realizar. No entanto, à medida que os desafios da IA se tornaram mais evidentes, muitas das previsões e promessas iniciais se mostraram ter sido superestimadas.
2. Limitações técnicas: os primeiros sistemas de IA eram, muitas vezes, programados com um conjunto de regras predefinidas e incapazes de aprender ou se adaptar a novas situações. Além disso, o hardware disponível na época era limitado e não conseguia lidar com a complexidade e a escala requerida por muitos problemas encontrados na aplicação da IA.
3. Cortes no financiamento: em meados da década de 1980, muitas organizações governamentais e privadas, que financiavam a pesquisa em IA, começaram a cortar seu financiamento. Foi um resultado direto dos fatores citados acima, – demonstrando uma incapacidade de entregar os resultados prometidos, gerando forte ceticismo em relação ao potencial da IA.

O termo "Inverno da IA" é frequentemente usado para descrever os ciclos entre os estados de "hype e desilusão", que ocorreram na história da IA (não diferente do que ocorre hoje

com a IA Generativa). Após o inverno da década de 1980, houve um ressurgimento na década de 1990 com novas abordagens de IA: as redes neurais e a aprendizagem de máquina. A partir dos anos 2010, houve outro grande avanço na IA, graças ao desenvolvimento de técnicas de aprendizagem profunda, ao aumento da disponibilidade de grandes conjuntos de dados (gerados pelo uso da Web) e à enormes capacidades computacionais no hardware dos computadores.

Deep Blue

25

O "Deep Blue" foi um supercomputador desenvolvido pela IBM, na década de 1990, especificamente projetado para jogar xadrez em nível muito competitivo. Se tornou conhecido ao ser o primeiro computador capaz de derrotar um campeão mundial de xadrez. Em maio de 1997, o Deep Blue jogou uma partida de seis jogos contra Garry Kasparov, então o campeão mundial de xadrez. O Deep Blue venceu a partida com duas vitórias, uma derrota e três empates.

O sistema do Deep Blue usou uma combinação de "busca em profundidade" (capaz de avaliar até 200 milhões de posições por segundo) e uma base de conhecimento específica de técnicas de xadrez, codificada por mestres enxadristas humanos. A equipe de desenvolvimento do Deep Blue era composta tanto por especialistas em computação quanto por mestres de xadrez, que ajudaram a estruturar o sistema. A vitória do Deep Blue representou um marco na história da Inteligência Artificial, demonstrando que os computadores poderiam superar os humanos em tarefas complexas, tais como o jogo de xadrez. No entanto, é importante ressaltar que o Deep Blue usou uma abordagem bastante específica para desafio de "jogar xadrez", e não "entendia" o conceito de xadrez da mesma maneira que os humanos. Desde então, a tecnologia avançou consideravelmente. Hoje, temos programas de xadrez ainda mais fortes que rodam em computadores pessoais comuns. Além disso, a abordagem do aprendizado de máquina para a IA, como vista no AlphaGo da DeepMind, que derrotou o campeão mundial do jogo de Go em 2016, representa um avanço significativo em relação à abordagem baseada em regras do Deep Blue.

MARCOS DA INTELIGÊNCIA ARTIFICIAL NO SÉCULO XXI

Stanford Cars

26

O projeto "Stanford Cars" faz referência à pesquisa no campo dos veículos autônomos e da visão computacional, pela Stanford University. O resultado mais notável foi o carro robótico "Stanley", que venceu o *Grand Challenge* de 2005⁴, uma competição de veículos autônomos patrocinada pela Agência de Projetos de Pesquisa Avançada de Defesa dos EUA (DARPA). A competição exigia que os veículos navegassem por um curso de 131 milhas pelo deserto, sem assistência humana. O "Stanley", desenvolvido por uma equipe liderada por Sebastian Thrun, concluiu o percurso em menos de 7 horas.

O "Stanley" utilizou uma variedade de sensores e tecnologias, incluindo a visão computacional, para perceber o ambiente ao seu redor e tomar decisões na trajetória e

⁴ Wikipedia; disponível em [https://en.wikipedia.org/wiki/DARPA_Grand_Challenge_\(2005\)](https://en.wikipedia.org/wiki/DARPA_Grand_Challenge_(2005)), visitado em 01 de abril de 2023

controle de condução. Uma parte crucial da capacidade do Stanley em navegar era sua habilidade de reconhecer e categorizar objetos em tempo real. Esta capacidade de visão computacional é um elemento chave dos veículos autônomos atuais, pois permite que um veículo reconheça obstáculos, sinais de trânsito, outros veículos, pedestres, etc.

O projeto Stanford Cars e o sucesso do Stanley tiveram um impacto significativo de subsequentes avanços no campo veículos autônomos e na visão computacional. Muitos dos membros da equipe de Stanley desseguiram trabalhando com veículos autônomos em grandes empresas, tais como Google, Uber e Tesla.

Além disso, os avanços feitos na visão computacional como parte do projeto têm aplicações que vão mais além dos veículos autônomos, incluindo a detecção de objetos usadas em aplicações tais como vigilância, reconhecimento facial, controle de qualidade e sistemas de recomendação de produtos.

IBM Watson

27

O IBM Watson é uma plataforma de inteligência artificial (IA) desenvolvida pela IBM. Ganhou notoriedade em 2011, quando venceu campeões humanos no programa de perguntas e respostas "Jeopardy!"⁵, demonstrando capacidades avançadas de processamento de linguagem natural e de análise de dados.

O IBM Watson utiliza uma combinação de técnicas de IA, incluindo o processamento de linguagem natural, o aprendizado de máquina e a análise de dados. Isso permite que o Watson compreenda, aprenda e tire conclusões a partir de uma vasta gama de fontes de dados não estruturados, tais como textos, imagens e áudio.

O Watson é mais do que apenas um programa de perguntas e respostas; é uma plataforma de IA versátil, que tem sido aplicada em uma variedade de contextos industriais e comerciais. Algumas das suas principais aplicações estão nas seguintes áreas:

1. *Saúde*: usado para apoiar a tomada de decisões clínicas, ajudando os médicos a entenderem os prontuários dos pacientes, a literatura médica e as diretrizes de tratamento. Ele também tem sido usado em pesquisas para ajudar a identificar possíveis novos tratamentos e medicamentos.
2. *Educação*: usado para desenvolver sistemas personalizados de aprendizado e tutoria, ajudando a adaptar o material de aprendizado às necessidades individuais de cada aluno.
3. *Finanças*: usado para analisar tendências do mercado financeiro, notícias e relatórios de empresas para auxiliar na tomada de decisões de investimento.
4. *Atendimento ao cliente*: usado para alimentar sistemas de "chatbot" e de resposta automática, permitindo que as empresas forneçam "atendimento 24/7" aos seus clientes.

⁵ IBM Watson: Final Jeopardy! and the Future of Watson (2011); disponível em https://www.youtube.com/watch?v=II-M7O_bRNg, visitado em 01 de abril de 2023

O IBM Watson representa um avanço significativo na maneira como as máquinas podem interagir com a linguagem e o conhecimento humanos, agregando significativo valor em termos de eficiência, personalização e a capacidade de lidar com grandes volumes de dados.

AlexNet

28

AlexNet é um sistema baseado em arquitetura de “rede neural convolucional” (CNN) apresentada por Alex Krizhevsky, Ilya Sutskever e Geoff Hinton (2012). Este modelo de aprendizado profundo ganhou notoriedade ao vencer o Desafio de Reconhecimento Visual de Grande Escala ImageNet (ILSVRC), em 2012⁶.

O ImageNet é um conjunto de dados contendo milhões de imagens, rotuladas em milhares de categorias. O “desafio anual ImageNet” avalia algoritmos de classificação e detecção de objetos por imagens. Antes de 2012, as técnicas tradicionais de visão computacional dominavam o desafio, mas a vitória do sistema AlexNet foi quando as redes neurais convolucionais começaram a liderar esta competição.

O AlexNet é estruturado por uma rede neural convolucional de 8 camadas, que usa a técnica de aprendizado profundo para categorizar imagens em até 1000 classes diferentes. Esta arquitetura foi uma das primeiras a usar uma abordagem ReLU (Rectified Linear Units) para funções de ativação e o conceito de “dropout” para prevenir overfitting durante o treinamento dos dados.

A vitória do AlexNet no desafio ImageNet foi um marco na pesquisa de IA, pois demonstrou o poder das redes neurais convolucionais e do aprendizado profundo na tarefa de reconhecimento visual. Isso levou a um aumento significativo no uso destas abordagens na visão computacional, resultando em avanços significativos na precisão e eficácia do reconhecimento de imagens e na detecção de objetos.

Desde então, novas arquiteturas de redes neurais convolucionais, tais como a VGGNet, a GoogLeNet e a ResNet, foram inspiradas e construídas com base no sucesso do sistema AlexNet.

Alexa

29

A Alexa é um assistente virtual desenvolvido pela Amazon (2014). Foi introduzida pela primeira vez como parte do Amazon Echo, um dispositivo de alto-falante inteligente que permite aos usuários interagir com a Alexa, por meio de comandos de voz.

A Alexa é capaz de realizar uma variedade de tarefas, incluindo reprodução de música, configuração de alarmes, fornecimento de informações meteorológicas, controle de dispositivos domésticos inteligentes, e outros mais. A tecnologia por trás da Alexa utiliza

⁶ ImageNet 2012; Disponível em <https://www.image-net.org/challenges/LSVRC/2012/>, visitado em 01 de abril de 2023

processamento de linguagem natural (PLN), aprendizado de máquina e tecnologia em nuvem para entender e responder aos comandos de voz dos usuários humanos.

Desde o lançamento do Echo, a Alexa tem sido integrada em uma variedade de outros dispositivos, tanto da Amazon quanto de terceiros. Por exemplo, Alexa está agora disponível em vários modelos de alto-falantes, dispositivos de streaming de mídia, smartphones, e até mesmo em automóveis. A Amazon também lançou o Alexa Skills Kit, que permite aos desenvolvedores criarem suas próprias aplicações para a Alexa, expandindo ainda mais suas capacidades.

A Alexa tem um papel importante no crescimento do mercado de dispositivos domésticos inteligentes, e na popularização da interação por voz com a tecnologia. Seu sucesso ajuda a estimular a competição neste mercado, ao serem criadas outras soluções por grandes empresas, tais como Google (com o *Google Assistant*) e Apple (com a *Siri*) oferecendo seus próprios assistentes virtuais⁷.

OpenAI

30

A OpenAI é uma organização de pesquisa em inteligência artificial (IA) fundada em dezembro de 2015 por Elon Musk, Sam Altman e uma renomada equipe de pesquisadores em IA. A OpenAI tem a missão de garantir que a "IA generalizada artificial" (AGI) - ou seja, uma IA autônoma que é capaz de superar os humanos na maioria das tarefas de alto valor econômico (ganho de tempo, execução de tarefas gerenciais, captura e apresentação de dados, etc.) - beneficie toda a humanidade.

A OpenAI adota uma abordagem aberta à pesquisa em IA, publicando a maioria de seus trabalhos na web. No entanto, a empresa reconhece que, à medida que avançamos para sistemas mais sofisticados de AGI, questões de segurança e a necessidade de evitar uma corrida entre competidores, realizadas em se adotar políticas adequadas, podem mitigar esta transparência. Ainda assim, a organização se compromete a compartilhar conteúdos considerados relevantes, no tocante às questões de segurança, e seus padrões e políticas de pesquisa.

A OpenAI também busca criar uma comunidade global de colaboradores, para abordar os desafios da AGI. A empresa se compromete a cooperar com outras instituições de pesquisa e adotar políticas para criar uma comunidade formada para lidar com os desafios futuros da AGI. Entre os trabalhos mais notáveis da OpenAI, estão o GPT-2 e o GPT-3.5 (versões abertas), modelos de LLM baseados em aprendizado profundo, que têm impressionante capacidade de geração de texto.

AlphaGO

31

O AlphaGo é um programa de inteligência artificial desenvolvido pela DeepMind, uma subsidiária da Google, que ganhou destaque em 2016 ao derrotar o campeão mundial de

⁷ The BEST Voice Assistant 2023!; Disponível em <https://www.youtube.com/watch?v=Ubn4hvVTO7s>, visitado em 01 de junho de 2023

"Go", um antigo e complexo jogo de tabuleiro⁸. O jogo "Go" é conhecido por sua incrível complexidade e profundidade estratégica, permitindo um número de jogadas que "excede o número de átomos no universo". Por este motivo, foi considerado um grande desafio para a IA.

O AlphaGo alcançou essa façanha usando uma combinação de redes neurais convolucionais (CNNs) e algoritmos de busca (Monte Carlo). O programa usou o sistema de rede neural para avaliar a posição das peças no tabuleiro e o outro para selecionar as jogadas. Ambos foram treinados através de aprendizado supervisionado, com jogos de Go profissionais, e através de aprendizado por reforço, onde o AlphaGo jogava contra si mesmo para melhorar seu desempenho.

Em Março de 2016, o AlphaGo jogou uma partida de cinco jogos contra Lee Sedol, um dos melhores jogadores do mundo, e ganhou quatro deles. A vitória do AlphaGo foi um marco significativo na história da IA, demonstrando sua capacidade em lidar com problemas de grande complexidade e grau de incerteza.

Desde a vitória do AlphaGo, a DeepMind continuou a desenvolver versões mais avançadas do programa. Em 2017, eles anunciaram o "AlphaGo Zero", uma versão que aprendeu a jogar Go apenas jogando contra si mesmo, sem utilizar dados oriundos de jogos com humanos ("dados sintéticos", ou gerados pelo sistema). Esta abordagem de "aprendizado a partir do zero" representou mais um passo na capacidade da IA de aprender de forma independente.

Comissão Europeia.

Em 2019, a Comissão Europeia – através do "Grupo de Peritos Independentes de Alto Nível em Inteligência Artificial", publicou as "Diretrizes de Ética para uma IA Confiável, estabelecendo uma recomendação sobre como estabelecer o adequado grau de a confiabilidade na IA. Está baseado em dois componentes: a legalidade, que implica a resiliência, segurança e privacidade, e a robustez (técnica e social), sobre a responsabilidade e a governança das instituições.

Os quatro princípios éticos fundamentais detalhados no relatório são:

1. *Respeito pela autonomia humana*: a IA deve permitir que as pessoas tomem decisões informadas e de maneira independente.
2. *Prevenção de danos*: a IA deve ser segura e proteger a integridade física e mental dos indivíduos.
3. *Justiça*: aplicações de IA devem ser desenvolvidas de maneira justa, inclusiva e não discriminar as pessoas.

⁸ AlphaGo - The Movie; Disponível em <https://www.youtube.com/watch?v=WXuK6gekU1Y>, visitado em 01 de junho de 2023

4. *Explicabilidade*: as pessoas devem ser capazes de entender e questionar decisões tomadas com base em sistemas de IA.

A implementação desses princípios é auxiliada por um conjunto de sete requisitos essenciais, que os sistemas de IA devem cumprir para serem considerados confiáveis. Mais detalhes estão disponíveis no documento completo, "Ethics Guidelines for Trustworthy AI", no site da Comissão Europeia⁹.

2.4 TIPOS DE INTELIGÊNCIA ARTIFICIAL

42

Existem vários tipos de campos da Inteligência Artificial (IA) sendo explorados atualmente, estando em constante evolução, com inovações e avanços significativos que continuamente remodelam os mercados onde se aplica. Desta forma, categorizar a IA não é uma tarefa simples.

O 'domínio geral da IA' pode ser subdividido de várias maneiras, levando em consideração a abordagem adotada, o histórico de sua aplicação por determinado grupo, empresa ou mercado, e o contexto definido pelos objetivos específicos de uso.

Sistemas que emulam o pensamento humano e Sistemas Racionais

A Conferência de Dartmouth:

A Conferência de Dartmouth foi um evento seminal na história da inteligência artificial (IA). Foi realizado em Hanover, New Hampshire, em 1956 e é amplamente considerado o 'nascimento do campo da IA'. Foi organizada por um grupo de hoje famosos pesquisadores, incluindo John McCarthy, Marvin Minsky, Nathaniel Rochester e Claude Shannon, que estavam interessados em explorar a ideia de criar máquinas que pudessem realizar tarefas que normalmente exigiriam inteligência humana. Estes especialistas em matemática, ciência da computação e psicologia discutiram a possibilidade da inteligência artificial, estabelecendo as bases para o campo atualmente.

São pesquisadores como Simon e Newell (1956)¹⁰ que abordaram a IA com a intenção de criar um 'cérebro eletrônico'. Essa abordagem, chamada de "simulação cognitiva", visava combinar modelos computacionais da IA com técnicas experimentais da psicologia para construir teorias precisas e verificáveis.

Já na década seguinte, McCarthy¹¹ apresentou uma abordagem racional, onde o foco era garantir que todas as ações tomadas pelo computador fossem justificáveis e que suas conclusões pudessem ser validadas com base em dados de entrada e conhecimento previamente adicionado. O legado da Conferência de Dartmouth continua a moldar o desenvolvimento da IA, sendo significativo para a inteligência artificial, porque marcou o início da pesquisa organizada no campo e estabeleceu a IA como uma área legítima de

⁹ "Ethics guidelines for trustworthy AI" (2019) Disponível em <https://digital-strategy.ec.europa.eu/en/library/ethics-guidelines-trustworthy-ai>, visitado em 10 de novembro de 2022.

¹⁰ Wikipedia, disponível em https://en.wikipedia.org/wiki/Logic_Theorist, visitado em 01 de novembro de 2022.

¹¹ Wikipedia, disponível em [https://en.wikipedia.org/wiki/John_McCarthy_\(computer_scientist\)](https://en.wikipedia.org/wiki/John_McCarthy_(computer_scientist)), visitado em 01 de novembro de 2022.

estudo. Neste evento, se definiu a agenda de pesquisa em IA para as próximas décadas, e suas ideias e conceitos foram fundamentais para seu avanço.

Sistemas que emulam a ação humana e Sistemas que Atuam Racionalmente

Alan Turing, na década de 1950 e 1970, propôs que a IA deveria atuar de forma humana, e para isso deveria passar pelo chamado "Teste de Turing". Isso incluía capacidades como processamento de linguagem natural, representação do conhecimento, raciocínio automático, aprendizado de máquina, visão computacional e robótica.

Abordagem Unificadora

Pesquisadores como Newell e Minsky¹², Russel e Norvig¹³ definiram o conceito da Inteligência Artificial: "estudo de agentes [inteligentes] que recebem preceitos do ambiente e [re]agem", propondo assim uma abordagem unificadora, focada em sistemas inteligentes. Estes sistemas seriam capazes de 'perceber' seu ambiente por meio de sensores, e agir de acordo com as informações disponíveis, sempre buscando maximizar o alcance dos objetivos estabelecidos. Essa abordagem também se concentrou na convergência de diversos domínios, tais como a filosofia, matemática, sociologia, administração e outros, ao lidar com problemas de 'busca heurística', 'representação de conhecimento', planejamento e antecipação, 'reconhecimento de padrões', aprendizado e evolução, entre outros. Apesar do avanço contínuo, isso não ocorre sem haver diversos desafios, tais como: a escassez de recursos computacionais, a validação subjetiva dos problemas e a necessidade de replicar a imperfeição humana.

2.5 TIPOS E APLICAÇÕES DA INTELIGÊNCIA ARTIFICIAL

43

A Inteligência Artificial (IA) engloba uma ampla gama de tecnologias, cada uma com suas próprias capacidades, pontos fortes e desafios. É importante observar que a IA, como um campo de estudo, é também dividida em áreas especializadas. Abaixo, estão relacionados alguns dos seus aspectos principais:

Aplicações da IA

As aplicações da IA variam de tarefas relativamente "simples" (leia-se, "objetivas"), como reconhecimento de imagem, até tarefas mais complexas, como tomada de decisões e planejamento estratégico. Estas diferentes aplicações demandam tipos distintos (e por vezes combinados) de sistemas de IA, cada um com suas próprias capacidades e limitações. Por exemplo, uma tarefa de reconhecimento de imagem pode exigir um sistema

¹² NEWELL, A. (1989), disponível em https://iif.library.cmu.edu/file/Newell_box00022_fld01506_doc0001/Newell_box00022_fld01506_doc0001.pdf, visitado em 01 de novembro de 2022.

¹³ NORVIG, P; RUSSELL, S. (2012), disponível em https://link.springer.com/chapter/10.1007/978-3-030-51110-4_2#:~:text=Russell%20and%20Norvig%20define%20AI,the%20environment%20and%20take%20action, visitado em 01 de novembro de 2022.

com fortes capacidades de processamento de imagem, enquanto um sistema focado em tomada de decisões requer um forte suporte para raciocínio lógico e aprendizado de máquina. Desta forma, diversas aplicações com base em sistemas de IA são hoje desenvolvidas, tanto por pesquisadores e grandes empresas, como por startups e indivíduos interessados em desenvolver soluções específicas. Na internet, é possível encontrar diversas notícias sobre inovação nestas áreas, além de "listas" de aplicativos dos mais variados tipos, sendo uma relação demasiado extensa para se inserir neste material.

Técnicas de IA

Mesmo com uma considerável gama de aplicativos, que só cresce continuamente, em geral a IA é realizada por meio de uma variedade de técnicas (muitas usadas em aplicações variadas mas com abordagens em comum), cada uma com suas próprias vantagens e desvantagens. Algumas dessas técnicas incluem sistemas baseados em regras, árvores de decisão, redes neurais, aprendizado profundo e aprendizado por reforço. Cada técnica é mais adequada para resolver certos tipos de problemas. Por exemplo, árvores de decisão e sistemas baseados em regras são geralmente úteis para problemas com regras claramente definidas e soluções discretas, enquanto redes neurais e técnicas de aprendizado profundo são mais eficazes para problemas com grandes quantidades de dados e soluções menos definidas.

Objetivos de Uso da IA

Diferentes sistemas de IA são necessários para atingir diferentes objetivos, que podem incluir a solução de problemas específicos ou a automação de tarefas. Estes objetivos podem requerer **diferentes níveis de complexidade e capacitação**. Por exemplo, um objetivo pode ser a automação de **uma tarefa de baixo nível**, como a classificação de imagens, enquanto outro pode envolver a solução de **um problema de alto nível**, como a previsão de tendências do mercado.

Plataformas de IA

Hoje em dia, existem diversas Plataformas como Serviço (PaaS) especializadas em soluções de IA incluindo sistemas baseados na nuvem, dispositivos de borda (que conectam uma rede local interna à Internet) e supercomputadores. Cada uma dessas plataformas exige diferentes tipos de sistemas de IA, levando em consideração aspectos como desempenho, consumo de energia e conectividade.

2.6 PRINCIPAIS ABORDAGENS NA INTELIGÊNCIA ARTIFICIAL:

44

Abordagem Simbolista

A abordagem simbolista envolve sistemas de IA que operam por meio de 'transformações simbólicas', isto é, manipulam números, letras, palavras e símbolos para resolver problemas que podem ser expressos de maneira lógica. Esta abordagem baseia-se em regras lógicas que utilizam representações simbólicas para estabelecer uma estrutura de operação.

Aplicativos baseados neste modelo processam cadeias de caracteres (representando entidades ou conceitos do mundo real por meio de símbolos), organizados hierarquicamente ou por meio de listas e redes. Tais arranjos informam ao algoritmo de IA como os símbolos se relacionam entre si. Estes são os chamados 'sistemas especialistas', estruturados por *strings* lógicas do tipo 'De – PARA', instruindo o comportamento do algoritmo. Você pode pensar em um sistema especialista como uma base de conhecimento criada pelo homem. Outro componente (mecanismo de inferência) associa um base de conhecimento que determina parâmetros aplicados a determinados símbolos.

As aplicações mais comuns desta abordagem incluem calculadoras, sistemas de navegação GPS, jogos, *chatbots*, diagnósticos médicos automatizados e gestão de workflows. Contudo, apesar de sua eficácia em situações bem definidas, a abordagem simbolista pode ter dificuldades em cenários onde existem variações, parâmetros pouco claros ou subjetivos e situações onde o problema é mal definido.

Estrutura: regras lógicas com base em simbolismos (representações conceituais).

Potencial de inferências de novos padrões por comparação: baixo.

Grau de precisão (1) e incerteza (2): muito alto (1), muito baixo (2).

Capacidade de trabalhar com condições imprecisas: muito baixa.

Capacidade de auto reorganização para realizar novas conexões não programadas: improvável.

Capacidade de aprendizado sem supervisão para (re)organização de data points e configuração de parâmetros: muito baixa.

Está presente nos primórdios da pesquisa de inteligência artificial centrada nesse método, se baseia na inserção de conhecimento humano e regras comportamentais em códigos de computador.

A abordagem simbólica funciona bem com aplicativos baseados em regras e objetivos claros, definindo os limites dentro dos quais operar. No entanto, não é adequada para cenários onde há variações. Se um problema é mal definido, como por exemplo a identificação visual (*computer vision*) e os parâmetros são pouco claros ou subjetivos (diversas versões ou variáveis do mesmo 'objeto'), a abordagem pode falhar.

Abordagem Conexionista

A abordagem conexionista se baseia na simulação do funcionamento do cérebro humano através de redes neurais artificiais. Esta abordagem foi introduzida inicialmente por McCulloch e Pitts em 1943¹⁴ e posteriormente aprimorada por Frank Rosenblatt em 1959¹⁵. Utiliza redes neurais com modelo de aprendizado profundo, tratando grandes volumes de dados. Regras claramente codificadas e validação mais transparente, permitindo maior governança em seus processos (compliance).

¹⁴ McCulloch, W., W. Pitts. (1943). A logical calculus of the ideas imminent in nervous activity. Bulletin of Mathematical Biophysics 5: 115-33

¹⁵ Wikipedia, disponível em https://en.wikipedia.org/wiki/Frank_Rosenblatt, visitado em 01 de novembro de 2022.

Aplicações comuns desta abordagem incluem reconhecimento facial e de voz, sistemas de orientação de veículos autônomos, análise de anomalias em grandes conjuntos de dados e diagnósticos médicos por imagem.

Estrutura: processos por meio de neurônios artificiais.

Potencial de inferências de novos padrões por comparação: relativamente alto.

Grau de precisão (1) e incerteza (2): médio (1), baixo (2).

Capacidade de trabalhar com condições imprecisas: muito alta.

Capacidade de auto reorganização para realizar novas conexões não programadas: média.

Capacidade de aprendizado sem supervisão para (re)organização de data points e configuração de parâmetros: média.

Abordagem Evolucionista

A abordagem evolucionista da inteligência artificial é inspirada na teoria da evolução biológica. Ela usa processos como mutação, recombinação (crossover) e seleção natural para desenvolver sistemas complexos. O algoritmo genético é um exemplo comum de IA evolucionista.

Estes algoritmos começam com um conjunto de soluções potenciais (conhecido como população), e novas soluções (descendentes) são criadas a partir das existentes por meio de operações que imitam a recombinação genética e mutação. As soluções são avaliadas usando uma função de aptidão e as mais aptas são mais propensas a serem selecionadas para gerar a próxima geração de soluções. Eventualmente, este processo pode levar a soluções ótimas ou sub-ótimas para o problema em questão.

Abordagem 'Swarm' (ou Enxame)

A abordagem de enxame é um subcampo da inteligência artificial que envolve o estudo de sistemas descentralizados, auto-organizados e distribuídos. Ela é inspirada pelo comportamento coletivo de insetos sociais e outros animais. A otimização por enxame de partículas (PSO) e o algoritmo do enxame de abelhas são exemplos comuns desta abordagem.

Na PSO, cada partícula (representando uma solução potencial para o problema) se move no espaço de busca, influenciada pela melhor posição encontrada por ela e pelo enxame como um todo. Este movimento coletivo permite que o enxame explore o espaço de busca e, eventualmente, encontre uma solução ótima ou sub-ótima.

Em síntese, se pode propor que o OBJETIVO da pesquisa e aplicação de sistema de ia se resumem em:

- Prático: tornar os computadores mais úteis, permitindo que substituam aquelas tarefas menos valiosas (ou com maior risco) para os seres humanos;
- Aspiracional: avanços na compreensão sobre os princípios e mecanismos da inteligência humana;

2.7 PRINCIPAIS CAMPOS DE PESQUISA NA INTELIGÊNCIA ARTIFICIAL

45

Processamento de Linguagem Natural (PLN)

O PLN refere-se à capacidade dos sistemas de IA de compreender, interpretar e gerar a linguagem humana. Essa área de pesquisa busca criar máquinas capazes de realizar tarefas que envolvam o uso da linguagem natural, como tradução automática, análise de sentimentos e respostas a perguntas. A aplicabilidade e a replicabilidade desses sistemas ainda estão em discussão devido aos desafios inerentes ao entendimento da complexidade e ambiguidade da linguagem humana.

Visão Computacional

A **visão computacional** diz respeito à habilidade dos sistemas de IA de interpretar e compreender informações visuais do mundo real. Estes sistemas têm uma vasta gama de aplicações, desde reconhecimento facial e detecção de objetos até navegação autônoma. Há, no entanto, questões éticas relacionadas à privacidade e ao uso indevido dessas tecnologias, que ainda geram muito debate. Não bastante, o valor agregado para processos fabris, gestão da qualidade e outras áreas é inegável.

Robótica

A **robótica** é o campo da IA que se concentra em criar máquinas capazes de realizar tarefas físicas. Robôs suportados por IA são utilizados em uma variedade de contextos, desde manufatura até exploração espacial. A viabilidade desses sistemas depende frequentemente de uma análise de custo-benefício.

Aprendizado Profundo

O **aprendizado profundo** é um subcampo do aprendizado de máquina que utiliza redes neurais artificiais com várias camadas ocultas - DNN (*deep neural networks*) para modelar e entender estruturas complexas de dados. Embora esses modelos tenham alcançado um sucesso significativo em uma série de tarefas, como reconhecimento de voz e imagem, eles são frequentemente criticados pela sua falta de transparência e interpretabilidade.

Aprendizado por Reforço

O **aprendizado por reforço** é um tipo de aprendizado de máquina em que um agente aprende como se comportar em um ambiente realizando ações e recebendo recompensas ou punições.

Dentre outras linhas de pesquisa e desenvolvimento correlacionadas com a IA hoje em dia, e seus desafios, dos quais podemos listar:

1. *Reactive machines*: as 'máquinas reativas' apenas reagem ao ambiente em que se encontram, sem nenhuma memória (ou 'autoconsciência'), trabalhando dentro de cenários controláveis ou altamente preditivos, e sem a capacidade de reter decisões tomadas no passado para incrementar novas decisões no presente. Sua aplicação é 'especializada' e pode ser aprimorada dentro do uso destinado.
2. *Memory limitation*: apesar de já existir o aprendizado de máquina (ML), este campo da IA ainda é restrito pela atual capacidade de 'memória de operação de sistemas',

sendo uma questão significativa no tocante à capacidade destes sistemas em tomar decisões com base em experiências passadas, adequadamente contextualizadas.

3. *Mind Theory*: no campo de pesquisa da 'teoria da mente' associada à IA, se explora com a capacidade de entender e interpretar emoções e pensamentos humanos. Embora a inteligência emocional artificial já seja uma indústria em desenvolvimento e uma área de interesse para os principais pesquisadores de ciência da computação, atingir este nível também exigirá o desenvolvimento de outros ramos da IA.
4. *Self awareness*: busca entender a possibilidade de haver a autoconsciência para sistemas de IA, e como seriam gerenciados; não há soluções ainda desenvolvidas, mas este tema é extremamente popular em obras de ficção científica.

2.8 DEFINIÇÕES DA INTELIGÊNCIA ARTIFICIAL

46

Inteligência Artificial Geral (*General AI*) ou Forte (*Strong AI*)

A **Inteligência Artificial Geral ou Forte** refere-se a sistemas de IA capazes de realizar qualquer tarefa cognitiva humana, ou até mesmo superá-las, sem limitações ou áreas de aplicação específicas. Até o momento, este tipo de IA ainda está em desenvolvimento e ainda não foi completamente realizado.

Inteligência Artificial Fraca (*Weak AI*) ou Estreita (*Narrow AI*)

A **Inteligência Artificial Fraca ou Estreita** é projetada para realizar tarefas específicas, muitas vezes superando o desempenho humano nessas atividades. Estes sistemas de IA estão amplamente disponíveis atualmente e incluem, por exemplo, assistentes de voz, sistemas de recomendação e carros autônomos. Esta categoria mais ampla da IA pode se dividir em:

a. Inteligência Artificial de Aprendizado Supervisionado (*Supervised Learning*)

Sistemas de IA de **aprendizado supervisionado** utilizam dados rotulados para prever saídas com base em novas entradas. Eles são amplamente utilizados em tarefas de classificação e regressão.

b. Inteligência Artificial de Aprendizado Não Supervisionado (*Unsupervised Learning*)

A IA de **aprendizado não supervisionado** usa dados não rotulados para descobrir novos padrões e, em seguida, desenvolve novas condições para trabalho subsequente. Estes sistemas são comumente utilizados em tarefas de agrupamento e detecção de anomalias.

c. Inteligência Artificial de Aprendizado por Reforço (*Reinforcement Learning*)

No **aprendizado por reforço**, os sistemas de IA aprendem a partir do feedback (reforço positivo ou negativo) recebido em interações anteriores com o ambiente. Eles são geralmente usados em tarefas de otimização e controle.

d. Inteligência Artificial de Aprendizado Profundo (*Deep Learning*)

Os sistemas de IA de **aprendizado profundo** utilizam redes neurais com várias camadas para modelar padrões complexos nos dados. Estes sistemas têm sido eficazes em uma variedade de tarefas, incluindo processamento de linguagem natural, reconhecimento de voz e visão computacional.

e. Inteligência Artificial de Processamento de Linguagem Natural (*Natural Language Processing AI*)

Esses sistemas de IA são capazes de processar, analisar e interagir com os usuários usando linguagem humana. Eles são amplamente utilizados em tarefas de tradução automática, análise de sentimentos e geração de texto.

f. Inteligência Artificial para Visualização Computacional (*Computer Vision AI*)

A IA de visão computacional é utilizada em aplicações que envolvem o reconhecimento, a gestão e o apoio ao processamento e desenvolvimento de imagens e vídeos. Esses sistemas são comumente usados em tarefas de detecção de objetos, reconhecimento facial e navegação autônoma.

Atividade individual #2

Converse com o avatar IA do descendente direto do Pai da Computação, e explore os temas discutidos nesta parte da apostila. Busque interagir com o máximo possível de temas e conceitos apresentados, para obter uma importante pista, como parte do segredo que levará ao prêmio final.

Clique no código QR para acessar o avatar, ou digite:

<http://tinyurl.com/alantia>



2.9. A INTELIGÊNCIA ARTIFICIAL ESTREITA (IAE) E SEUS MERCADOS POTENCIAIS

47

Robótica: Sistemas de IAG têm o potencial de revolucionar o campo da robótica. Eles poderiam ser utilizados na criação semi-independente de robôs altamente sofisticados capazes de realizar uma variedade de tarefas complexas. Estes robôs poderiam adaptar-se a novos cenários, aprender com a experiência e até mesmo participar do design e construção de novos modelos de robôs.

Gerenciamento e Tomada de Decisão: Em áreas que envolvem tomada de decisões complexas, como finanças, saúde e políticas públicas, a IAG pode ter um impacto significativo. Esses sistemas de IA poderiam gerenciar grandes volumes de dados, analisar padrões e fazer previsões precisas, reduzindo a necessidade de supervisão humana constante.

Produção Criativa: A IAG poderia ser empregada em indústrias criativas para gerar novas obras de arte, música e literatura. Esses sistemas de IA poderiam usar a interpretação de estados emocionais e aspectos culturais para criar obras inéditas, questionando a ideia de que a criatividade é exclusiva aos humanos.

Educação: A IAG tem potencial para personalizar o aprendizado de acordo com as necessidades individuais de cada aluno, adaptando-se à abordagem de ensino mais eficaz para maximizar o desenvolvimento de suas habilidades. Estes sistemas poderiam se tornar tutores individuais, proporcionando uma formação educacional mais eficaz e personalizada.

48

Reconhecimento de Imagem/Voz: Sistemas de IAE têm se destacado na tarefa de reconhecer e categorizar imagens - sejam elas estáticas, vídeos ou rostos - e transcrever e traduzir voz, identificando seus padrões e contexto. Eles são essenciais em diversos campos, desde segurança e contro

Assistentes Virtuais: Os assistentes virtuais, como Siri e Alexa, são exemplos de IAE aplicada. Esses sistemas são projetados para executar tarefas específicas, como definir lembretes, tocar música, fazer pesquisas na internet e fornecer informações personalizadas ao usuário.

Sistemas de Recomendação: Esses sistemas são amplamente utilizados por plataformas de e-commerce, como Amazon, e mecanismos de pesquisa, como Google, para oferecer recomendações personalizadas aos usuários com base em seu histórico de compras e navegação.

Deteção de Fraudes: Os sistemas de IAE têm sido eficazes na detecção e prevenção de atividades fraudulentas em instituições financeiras, analisando padrões em grandes volumes de dados gerados por transações.

Diagnósticos Médicos: Apesar de ainda ser um campo controverso, sistemas de IAE têm sido cada vez mais usados na área da saúde para auxiliar no diagnóstico de doenças, análise de exames clínicos e determinação de prognósticos com base em registros médicos e prontuários eletrônicos.

Processos Industriais e Serviços: A IAE é comumente utilizada na indústria e no setor de serviços por meio da manutenção preditiva. Os algoritmos são aplicados para analisar os dados das máquinas e equipamentos, bem como a produção de processos, para prever falhas e tendências de desvios incrementais. Esses sistemas permitem que as empresas

gerenciem proativamente possíveis problemas, otimizem seus cronogramas e melhorem a eficiência na gestão de suas operações.

Para tomadores de decisão, os sistemas de IAE oferecem várias aplicações práticas:

Aplicações para Eficiência Aprimorada: Ao automatizar tarefas rotineiras, a IAE libera os gestores para se concentrarem em tarefas de maior valor, melhorando a produtividade geral.

Aplicações para Precisão Aprimorada: A IAE pode apoiar ou até mesmo realizar tomadas de decisão, em geral com maior precisão do que os gestores humanos, reduzindo erros, retrabalho e risco.

Melhor Comunicação Interrelacional: A IAE pode ser usada para estabelecer processos sofisticados de comunicação e fornecer atendimento personalizado aos stakeholders, levando a uma maior eficácia e satisfação.

2.10. O APRENDIZADO DE MÁQUINA (ML)

49

O Aprendizado de Máquina, uma subárea crucial da Inteligência Artificial, concentra-se na elaboração de algoritmos e modelos que permitem que os computadores 'aprendam' a partir de dados coletados, sem serem explicitamente programados para executar tarefas específicas. O principal objetivo do ML é criar sistemas capazes de melhorar de forma autônoma seus processos, seu desempenho e os resultados obtidos, sem a necessidade de supervisão ou instrução constante por parte de operadores humanos.

É relevante esclarecer que os processos de aprendizado das máquinas diferem consideravelmente dos processos de aprendizado humano, dada a natureza única de cada um:

Aprendizado Humano: Nosso modelo de aprendizado é multifacetado e complexo, envolvendo a utilização dos sentidos, emoções, motivações e modelos de raciocínio, além da contextualização e do entendimento cognitivo. Aprendemos através da repetição, emulação, experiência, observação e instrução, e temos a capacidade de transferir nosso conhecimento e compreender conceitos abstratos.

Aprendizado de Máquina: Os modelos de ML possibilitam que os computadores aprendam e aprimorem seu desempenho sem a necessidade de programação explícita. Eles aprendem por meio da análise contínua de grandes volumes de dados, identificando padrões e realizando previsões. Embora esses sistemas não possuam emoções, motivações ou perspectivas individuais, eles podem ser indiretamente influenciados por tais aspectos, como é evidenciado quando analisamos o viés inerente em muitas soluções de IA.

2.11 A IA E SUAS APLICAÇÕES

Tipos de aprendizado de máquinas

50

Os diferentes modelos de aprendizado de máquina desempenham um papel fundamental no campo da Inteligência Artificial (IA). Há quatro tipos principais desses modelos: aprendizado supervisionado, aprendizado não supervisionado, aprendizado por reforço e aprendizado profundo. Em certos casos, também é possível configurar modelos híbridos que incorporam características de dois ou mais desses tipos (Russell e Norvig, 2016).

Áreas de aplicação do aprendizado supervisionado

No aprendizado supervisionado, o algoritmo é treinado com um conjunto de dados "rotulado". Isso significa que os dados de entrada (ou recursos) e saída (ou metas) já são conhecidos e utilizados no treinamento do modelo. Diversas técnicas, como regressão linear, regressão logística, árvores de decisão e redes neurais, são empregadas para "ensinar" o algoritmo a compreender a relação entre os recursos de entrada e a saída alvo. Assim, o algoritmo pode então fazer previsões sobre novos pontos de dados com base nessas relações "aprendidas" (Goodfellow, Bengio, e Courville, 2016). As organizações que empregam sistemas de IA desta natureza podem – com maior eficácia, identificar tendências, antecipar riscos e os mitigar, se tornando mais proativas.

Existem várias vantagens em utilizar o aprendizado supervisionado, principalmente para gerentes e tomadores de decisão. Entre elas estão:

1. **Modelagem preditiva:** Os algoritmos de aprendizado supervisionado são fundamentais para a criação de modelos preditivos, que identificam padrões ocultos nos dados e preveem possíveis resultados. Nesse caso, os dados de entrada e saída são utilizados simultaneamente durante a "fase de treinamento do modelo", até que o mapeamento de dados e padrões seja completado (Chollet, 2018).
2. **Reconhecimento de imagem e voz:** Estes algoritmos são essenciais para aplicações práticas diversas, como na direção de carros autônomos, onde são necessários para identificar objetos móveis, tais como carros e pedestres. Eles também são úteis em recursos de acessibilidade, como no desbloqueio de sistemas através do reconhecimento facial, e em assistentes virtuais, como os chatbots (Hinton et al., 2012).
3. **Deteção de fraudes:** Os algoritmos de aprendizado supervisionado também são empregados na detecção de fraudes em áreas onde a gestão de risco é essencial, como transações com cartões de crédito e reclamações de seguros.
4. **Filtragem de spam:** Estes algoritmos são amplamente usados para filtrar e-mails de spam e outras ameaças, diminuindo o tempo e os recursos necessários para a classificação de mensagens indesejadas.
5. **Previsão de rotatividade de clientes:** Com o aprendizado supervisionado, os algoritmos podem prever quais clientes têm maior probabilidade de buscar outro relacionamento comercial, permitindo que os gestores tomem medidas proativas para retê-los.

Áreas de aplicação do aprendizado não supervisionado

51

Na Inteligência Artificial (IA), o aprendizado não supervisionado é uma abordagem de aprendizado de máquina que utiliza conjuntos de dados "não rotulados". Isso significa que a IA é treinada sem quaisquer metas pré-definidas ou informações de saída, e o objetivo é encontrar padrões ocultos e estruturas nos dados sem direção prévia (Russell e Norvig, 2016).

Em contraste com o aprendizado supervisionado, que faz previsões baseadas em saídas rotuladas de acordo com os dados de entrada, o aprendizado não supervisionado não define uma saída de destino específica. Isso permite que a IA "descubra" essas saídas através da identificação de padrões relevantes. O princípio fundamental é que a IA aprende com os dados existentes sem restrições prévias, o que pode revelar padrões, estruturas e relações que podem não ser facilmente perceptíveis para especialistas humanos (Goodfellow, Bengio e Courville, 2016). Este modelo já se comprovou ser uma ferramenta poderosa e eficaz na automatização e gestão de dados em grande volume / fluxo. Mais do que assegurar a competitividade, são essenciais para a sobrevivência de empresas. A análise de grandes quantidades de dados não estruturados pode conter padrões, estruturas e relacionamentos presentes nos dados podem ser, a princípio indetectáveis aos 'especialistas humanos'. Quando evidenciados pelo sistema de IA, gera novos insights, fornecendo aos gerentes operacionais, de projetos e outros tomadores de decisão melhores condições para a tomada de decisão. Como tais sistemas podem identificando relacionamentos ocultos, isso pode a qualidade da tomada de decisão pelos operadores humanos.

Dentro do aprendizado não supervisionado, existem várias técnicas que podem ser aplicadas, entre as quais:

1. **Clusterização:** A IA é treinada para agrupar dados em "clusters" baseados em semelhanças identificadas. Essa abordagem é especialmente útil em situações onde se tem um grande volume de dados sem categorização aparente, como em pesquisas de mercado (Jain, Murty e Flynn, 1999).
2. **Redução de dimensionalidade:** A IA é treinada para reduzir o grau de "dimensionalidade" nos dados, o que é especialmente útil quando se está lidando com um alto número de variáveis. Exemplos de sua aplicação incluem dados socioeconômicos, dados bancários e outros tipos de dados coletados por agências públicas (Van Der Maaten, Hinton, 2008).
3. **Deteção de anomalias:** Essa abordagem visa identificar anomalias nos dados, o que pode ser aplicado em situações como a prevenção de fraudes e inspeção de segurança de rede (Chandola, Banerjee e Kumar, 2009).
4. **Sistemas de recomendação:** A IA pode ser treinada para recomendar produtos e serviços com base no comportamento anterior dos usuários na web. Isso é comumente visto em funcionalidades de recomendação de produtos em marketplaces e lojas online, bem como na publicidade personalizada (Ricci, Rokach e Shapira, 2011).

5. **Compactação de dados:** A IA pode ser treinada para compactar dados sem perder informações importantes, o que é útil para compactação de imagens e vídeos, como em sistemas de monitoramento visual.
6. **Previsão mais precisa de tendências:** Algoritmos de aprendizado não supervisionado, quando combinados com algoritmos de aprendizado supervisionado, podem refinar ainda mais as tarefas preditivas, aumentando a detecção de padrões e correlações em grandes volumes de dados não estruturados (Goodfellow, Bengio e Courville, 2016).

Áreas de aplicação do Aprendizado por Reforço

52

No campo da Inteligência Artificial, o aprendizado por reforço representa um conjunto de algoritmos de aprendizado de máquina no qual um agente de IA interage com um ambiente e aprende a tomar decisões que maximizam uma recompensa acumulativa (Sutton e Barto, 2018). A aprendizagem se dá através de um processo de tentativa e erro, onde o agente aprende a partir de suas ações e das recompensas ou penalidades subsequentes que recebe. Tais sistemas aprendem como tomar decisões em um ambiente volátil, se readaptando e recebendo recompensas ou penalidades em resposta. Em ambientes sob constante mudança, este modelo baseado em 'penalidades/recompensas' permite ao sistema, por sua vez, atualizar suas regras de ação, refinando o seu mapeamento para ações subsequentes. Desta forma, o sistema mantém a versão de estratégia de ação mais recente como sendo a mais eficaz. Com este **reforço contínuo**, os sistemas de IA 'aprendem' a maximizar a incidência de recompensas, viabilizando assim a melhoria contínua do desempenho, através de interações com o ambiente e o feedback recebido (Sutton e Barto, 2018).

Algumas aplicações práticas do aprendizado por reforço incluem:

1. **Robótica:** A IA pode ser treinada para controlar robôs, permitindo-lhes aprender a executar tarefas específicas, melhorando sua precisão e eficiência (Kober, Bagnell e Peters, 2013).
2. **Jogos:** Os agentes de IA podem ser treinados para jogar jogos como xadrez e Go, aprendendo a desenvolver estratégias que aumentem suas chances de vitória (Silver et al., 2016).
3. **Veículos autônomos:** O aprendizado por reforço pode ser aplicado ao controle de veículos autônomos, permitindo que eles aprendam a tomar decisões em um ambiente em constante mudança para maximizar a segurança e a eficiência (Shalev-Shwartz et al., 2016).
4. **Recomendações personalizadas:** Os sistemas de IA podem aprender a fazer recomendações cada vez mais personalizadas, equilibrando os padrões de comportamento do usuário com ofertas adequadas (Zhao et al., 2013).

5. **Alocação de recursos:** A IA pode ser utilizada para otimizar a alocação de recursos importantes, como largura de banda e capacidade de processamento, em serviços como hospedagem de sistemas e Plataformas como Serviço (PaaS), tomando decisões que maximizem a eficiência e a qualidade em resposta à demanda variável (Mao et al., 2016).

Áreas de aplicação do Aprendizado Profundo

53

Aprendizado profundo, ou Deep Learning (DL), é uma subcategoria de aprendizado de máquina inspirada na estrutura e função do cérebro humano, utilizando redes neurais artificiais para processar informações (Goodfellow, Bengio & Courville, 2016). Estas redes neurais são compostas por camadas hierárquicas de neurônios, ou nodos de processamento, que podem aprender e extrair características a partir de dados brutos sem a necessidade de intervenção humana.

As redes neurais de aprendizado profundo são treinadas para minimizar as perdas, definidas como a discrepância entre a saída prevista e a saída real dos dados (Goodfellow, Bengio & Courville, 2016). Este treinamento é realizado por meio de um processo denominado *back propagation* (BP), que ajusta os pesos das conexões entre os neurônios da rede para produzir saídas mais precisas. Se a resposta obtida for positiva, os pesos são diminuídos e, se for negativa, os pesos são aumentados. O erro encontrado é então propagado de volta pela rede, ajustando novamente os pesos numa estratégia de otimização conhecida como 'descida de gradiente'. Este processo se repete várias vezes, com diferentes conjuntos de dados de entrada, até que a rede seja adequadamente (re)treinada e produza resultados cada vez mais próximos aos considerados ideais (*baseline*).

Aplicações práticas do aprendizado profundo incluem:

1. **Classificação de imagens:** as redes neurais podem ser treinadas para identificar objetos específicos em imagens, uma habilidade vital para campos como visão computacional e robótica (Krizhevsky, Sutskever & Hinton, 2012).
2. **Reconhecimento de voz:** os sistemas de IA podem ser treinados para transcrever fala em texto, uma técnica crucial para aplicações que requerem interação humano-computador, como assistentes virtuais (Hinton et al., 2012).
3. **Processamento de linguagem natural:** o aprendizado profundo possibilita que a IA execute tarefas complexas, como análise de sentimentos e tradução automática, que são vitais em áreas como mídia social e atendimento ao cliente (Sutskever, Vinyals & Le, 2014).
4. **Sistemas de recomendação:** as redes neurais podem fazer recomendações altamente personalizadas, como sugerir filmes ou produtos com base no comportamento do usuário (Covington, Adams & Sargin, 2016).

5. **Modelagem preditiva:** a IA pode ser treinada para fazer previsões precisas, como o preço de ações ou previsões climáticas, baseando-se em dados históricos e atuais (Bengio, Simard & Frasconi, 1994).

Além dos modelos de aprendizado de máquina (ML) acima citados, outras áreas da IA são bastante exploradas, com aplicações muito significativas no mundo real.

Áreas de aplicação do Processamento de Linguagem Natural (PLN)

54

O Processamento de Linguagem Natural (PLN) é um ramo da Inteligência Artificial (IA) focado na interação entre máquinas e a linguagem humana. Seu objetivo é capacitar os computadores a compreender, interpretar e gerar a linguagem humana de maneira significativa e útil. Apesar de sua utilidade inquestionável, os modelos de PLN enfrentam certas limitações, como a dificuldade em processar e entender com precisão a linguagem humana quando ela é altamente ambígua ou possui idiossincrasias culturais e idiomáticas (Chowdhury, 2003). Mesmo que não seja, em si, um modelo de 'aprendizado de máquina', utiliza muitos dos mesmos recursos para interagir e se adaptar à linguagem humana, que é caracteristicamente muito subjetiva.

As aplicações práticas do PLN na IA abrangem uma variedade de domínios, incluindo:

1. **Chatbots:** os sistemas de IA podem usar PLN para interagir com usuários por meio de conversas baseadas em texto, facilitando a geração de informações valiosas para as organizações (Shawar & Atwell, 2007).
2. **Análise de sentimento:** a IA pode ser aplicada para analisar o sentimento expresso em dados de texto, uma habilidade útil em várias interações, incluindo postagens nas redes sociais e avaliações de clientes (Pang & Lee, 2008).
3. **Tradução automática:** os sistemas de IA podem ser usados para traduzir textos de um idioma para outro, ajudando a superar barreiras linguísticas. As traduções podem ser feitas tanto de forma assíncrona, como no caso do Google Tradutor, quanto sincronicamente, como exemplificado pela ferramenta Maxine da Nvidia (Hutchins & Somers, 1992).

Áreas de aplicação da Visão Computacional

55

A Visão Computacional é um subcampo da Inteligência Artificial (IA) focado em proporcionar às máquinas a habilidade de interpretar e analisar informações visuais, tais como imagens e vídeos. Os algoritmos de Visão Computacional são treinados para reconhecer objetos, pessoas, cenários, atividades e ações presentes em recursos de imagem e vídeo. Apesar dos grandes avanços na área, ainda há limitações significativas, particularmente no reconhecimento de objetos em ambientes complexos e variáveis (Szeliski, 2010).

Algumas das aplicações práticas que empregam sistemas de Visão Computacional incluem:

1. **Análise de imagem e vídeo:** Isso engloba várias finalidades, incluindo a identificação remota de objetos e pessoas, o rastreamento de movimentos e a detecção de padrões em ambientes capturados por câmeras (Zhang et al., 2018).
2. **Vigilância automatizada:** O emprego da IA em monitoramento e análise de imagens de vigilância em tempo real, oferecendo insights valiosos em questões de segurança (Cavallaro, 2018).
3. **Processamento de imagens médicas:** A IA pode auxiliar profissionais de saúde na análise de imagens médicas, como radiografias e exames de ressonância magnética, fornecendo informações cruciais para diagnósticos e orientações de tratamentos (Litjens et al., 2017).
4. **Veículos autônomos:** A visão computacional é essencial para o desenvolvimento de sistemas de navegação para veículos autônomos, permitindo que tais veículos percebam, identifiquem e interpretem as variáveis constantemente mutantes do ambiente ao seu redor (Chen et al., 2017).
5. **Varejo e comércio eletrônico:** A IA pode ser empregada para automatizar várias tarefas no varejo e comércio eletrônico, incluindo reconhecimento de produtos, comparação de preços e logística de estoques em pontos de venda (Agarwal et al., 2020).
6. **Realidade aumentada e jogos digitais:** A IA pode ser usada para melhorar a experiência do usuário em sistemas de realidade aumentada e diversos tipos de jogos, proporcionando experiências mais realistas e imersivas (Sherstyuk et al., 2019).

Inteligência Artificial e a Robótica: Interseções e Aplicações Práticas

56

O termo 'robô' foi introduzido em 1920, na obra "Rossum's Universal Robots", pelo escritor tcheco Karel Čapek. Derivado da palavra tcheca 'robota', que se traduz como '*trabalho forçado*' ou '*trabalho árduo*', o termo é recente quando contextualizado na vasta linha do tempo da inteligência artificial (IA) [1].

O desenvolvimento da robótica como um campo de estudo teve início em meados do século XX, catalisado por avanços em tecnologia mecânica e eletrônica, a influência da ficção científica na psique de pesquisadores, o crescimento da ciência da computação e a demanda crescente por automação industrial [2].

A IA é fundamental na robótica, permitindo aos robôs executar tarefas que exigem um grau de inteligência que se assemelha ao humano, como: consciência ambiental adaptativa, tomada de decisão contextualizada e adaptativa, e resolução de problemas em situações novas e desconhecidas [3]. Os algoritmos empregados na robótica permitem que os robôs aprendam com a experiência, reconheçam padrões e façam previsões quanto a

mudanças no entorno, conferindo-lhes a capacidade de concluir tarefas complexas e interagir com um ambiente dinâmico.

A aplicação de IA na robótica abriu novas possibilidades e revolucionou diversas áreas. Abaixo, discutiremos algumas dessas aplicações:

1. **Robótica Industrial:** Os robôs industriais, empregados há várias décadas na manufatura, realizam tarefas repetitivas, perigosas e de alta precisão, como montagem, soldagem e pintura. Estes robôs têm melhorado significativamente a eficiência e produtividade das indústrias, embora estejam envolvidos em controvérsias socioeconômicas [4].
2. **Robótica Médica:** Os robôs médicos são usados em uma variedade de aplicações complexas, incluindo procedimentos cirúrgicos, reabilitação e tecnologias assistivas para pessoas com deficiências. Um exemplo notável é o sistema cirúrgico Da Vinci, que usa braços robóticos para realizar cirurgias minimamente invasivas [5].
3. **Robótica Militar:** Os robôs militares são utilizados em uma variedade de tarefas, incluindo reconhecimento, vigilância e descarte de munições explosivas. Eles têm aprimorado a velocidade, precisão e eficiência das operações militares, ao mesmo tempo que reduzem o risco para os soldados humanos [6].
4. **Robótica Espacial:** Os robôs espaciais têm sido usados em missões de exploração e pesquisa do nosso sistema solar. A integração da IA na robótica espacial tem ajudado a avançar nossa compreensão do universo [7].
5. **Robótica Doméstica e de Serviços:** Os robôs domésticos têm transformado a gestão doméstica, tornando-a mais fácil e conveniente. Além disso, eles têm o potencial de melhorar a qualidade de vida e a independência da população idosa e de pessoas com deficiências [8].
6. **Robótica de Campo:** Esses robôs são usados em uma variedade de setores para realizar tarefas repetitivas ou que exigem conhecimento sofisticado. Exemplos incluem mapeamento, monitoramento e manutenção de colheitas [9].
7. **Robôs Humanóides:** São robôs projetados para se assemelharem aos humanos em aparência e comportamento. Eles interagem com o ambiente e os humanos, emulando ações semelhantes aos maneirismos humanos, o que torna a interação com eles mais natural [10].

A pesquisa em **Human-Robotic Interaction (HRI)** foca na interação entre robôs e seres humanos, explorando a complexidade da capacidade de interação entre máquinas e seres humanos - de maneira segura, eficaz e intuitiva. À medida que os robôs humanóides se tornam cada vez mais presentes no cotidiano das pessoas, a importância do desenvolvimento de soluções de HRI está crescendo [11]. No entanto, existem vários desafios no campo de HRI: um dos principais está na simulação de atitudes, movimentos e comportamento que seja aceitável por seres humanos (*Uncanny Valley* ¹⁶ :reproduzindo

¹⁶ https://en.wikipedia.org/wiki/Uncanny_valley; Figura 1 - <https://dl.acm.org/doi/pdf/10.1145/3470742>

ou emulando os mesmos), de maneira natural, familiar e engajadora, o que requer o uso de sofisticados sistemas de IA, complexos algoritmos e hardware de última geração. Existem também questões éticas e sociais sobre o seu uso 'em massa' (ex: a 'robotização' da economia). Outro desafio é garantir que os algoritmos de IA, usados em robôs humanoides, sejam seguros e confiáveis, evitando causar danos se apresentarem mau funcionamento ou comportamento inesperado. Apesar desses desafios, este é um campo de rápido avanço e com significativo potencial para melhorar a qualidade da vida humana.

2.12 BIG DATA, CIÊNCIA DE DADOS E INTELIGÊNCIA ARTIFICIAL: UMA SINERGIA PROMISSORA

57

O conceito de Big Data se refere aos grandes volumes de dados gerados continuamente por mercados, organizações e indivíduos, que são demasiadamente complexos para serem processados, analisados e interpretados por meio de ferramentas tradicionais ou apenas por humanos [1]. Esses dados provêm de múltiplas fontes, incluindo mídias sociais, transações de comércio eletrônico, redes de sensores e dispositivos estruturados na Internet das Coisas (IoT) [2].

A inteligência artificial (IA), neste contexto, atua como facilitadora para o processamento de tais volumes de dados, permitindo tarefas que exigem um nível de inteligência similar à humana, como a percepção, tomada de decisão e aprendizado [3]. Os algoritmos de IA, por sua vez, são projetados para interpretar e conferir significado aos vastos conjuntos de dados, habilitando-os a tomar decisões baseadas nas informações adquiridas. Portanto, a inter-relação entre Big Data e IA é intrinsecamente complementar. Mais ainda, nem todos os dados que compõem o Big Data são gerados apenas por seres humanos. Muitos dados resultam do uso de sistemas de *Machine Learning*, onde dados são gerados por máquinas durante processos de aprendizado, denominados como 'dados sintéticos'. Mesmo assim, estes dados podem carregar em si a 'herança' do viés inerente aos dados naturais que o originaram – além do viés inerente no 'design' de modelos de IA, ambos criados por seres humanos. Embora mais diluído, e mais difícil de detectar, este risco permanece presente. A tendência de geração de um ou outro tipo de dados ainda é algo difícil de determinar, mas faz sentido que, com o aumento do uso de modelos de ML e IA, a quantidade dos dados sintéticos deva superar ou se equiparar, em alguns casos, aos gerados pelos seres humanos.

Os sistemas de IA utilizam **Big Data** como dados de entrada para seus algoritmos aprenderem, realizarem previsões e tomarem decisões. Em contrapartida, a IA disponibiliza as ferramentas e técnicas necessárias para processar e analisar grandes volumes de dados, criando um ciclo virtuoso. Esta relação simbiótica possibilita que as organizações extraiam valor de grandes quantidades de dados, enquanto os algoritmos de IA aprimoram-se incrementalmente.

Diversos setores se beneficiam da gestão de Big Data apoiada pela IA. Entre eles, podemos citar:

1. **Varejo:** A IA e o Big Data permitem analisar o comportamento do consumidor, as preferências e o histórico de compras, fornecendo informações valiosas para o direcionamento de ofertas personalizadas [4].
2. **Serviços Financeiros:** Ambos permitem uma gestão de riscos mais refinada e auxiliam na tomada de decisões de investimento [5].
3. **Saúde:** O Big Data está sendo usado para melhorar os resultados em saúde, com IA analisando grandes volumes de dados de pacientes para desenvolver diagnósticos e tratamentos mais eficazes [6].
4. **Transporte:** A IA e o Big Data têm sido utilizados para melhorar a eficiência dos sistemas de transporte, analisando dados de GPS, câmeras de trânsito e mídias sociais [7].
5. **Indústria Manufatureira:** Ambos estão sendo usados para otimizar processos de produção, identificando padrões e previsões sobre demanda, insumos e custos de fabricação [8].

O gerenciamento do Big Data com apoio de sistemas de IA é muito relevante (já imprescindível, em certos mercados) para gestores de operações e projetos, dado que a tomada de decisão em negócios permite administrar informações valiosas sobre as operações, o desempenho das organizações e as tendências de mercado. Mais especificamente:

1. **Apoio à tomada de decisão:** a capacidade de gerenciamento do Big Data permite se ter uma visão abrangente da organização e suas operações, permitindo melhor suporte na tomada de decisões a partir de insights baseados em dados, e não na intuição ou suposições. Isso leva a uma maior eficiência e melhores resultados.
2. **Obtenção de vantagem competitiva:** através da análise do Big Data, as organizações podem obter informações coerentes e realistas sobre seus clientes, concorrentes e o mercado, podendo ser utilizadas para desenvolver estratégias mais alinhadas com a identificação de novas oportunidades de negócios, a otimização das operações e o desenvolvimento de novos produtos e serviços.
3. **Economia de custos:** o gerenciamento do Big Data pode ajudar as organizações a identificar ineficiências e desperdícios em suas operações, permitindo então que tomem decisões baseadas em dados confiáveis para melhorar seus processos e reduzir os custos. Ao gerenciar e analisar dados oriundos dos sistemas de produção e da cadeia de suprimentos, podem identificar gargalos, potenciais falhas e ineficiências e antecipar ações que reduzam ou eliminem custos potenciais.
4. **Insights vindos do mercado:** ao administrar a larga escala de dados oriundos do mercado consumidor, as ferramentas de IA conseguem analisar o comportamento, as preferências e o feedback do cliente em tempo real, oferecendo insights com menor viés para orientar campanhas de marketing mais bem direcionadas e, em última instância, gerar valor ao consumidor. Estes objetivos podem aumentar o

grau de lealdade de marca, engajamento e fidelidade de consumo, gerando aumento de receita.

A **Ciência de Dados (CD)** e a IA, assim como no caso do Big Data, possuem uma relação simbiótica. A CD concentra-se na coleta, limpeza, processamento, análise e visualização de dados, enquanto a IA desenvolve algoritmos capazes de aprender a partir desses dados, realizar previsões ou oferecer novos insights. Técnicas de CD, como pré-processamento de dados, exploração de dados e engenharia de recursos, são empregadas para preparar e limpar os dados antes de serem alimentados aos algoritmos de IA. Além disso, a CD aprimora as métricas e técnicas necessárias para avaliar o desempenho dos algoritmos de IA.

Por sua vez, a IA fornece à CD ferramentas avançadas para gerenciamento, processamento e análise de dados, como modelos de aprendizado de máquina e algoritmos de aprendizado profundo. O uso dessas ferramentas assume parte considerável das tarefas de baixo valor, permitindo que os especialistas em CD se concentrem em tarefas de alto valor, como a conceitualização dos problemas a serem resolvidos, o planejamento e desenvolvimento dos algoritmos mais apropriados para executar determinadas tarefas e a avaliação dos resultados obtidos.

Diferentes tipos de algoritmos para diferentes modelos de IA

Os gerentes de negócios, de operações e de projetos que utilizam de soluções e ferramentas de IA em seu trabalho, precisam entender – de maneira mais ampla – o que são e para que se empregam algoritmos. Ao entender o papel que eles desempenham nos processos da organização, poderão avaliar melhor seu papel crítico para a gestão, o crescimento e a competitividade dos negócios.

As possibilidades de aplicação de algoritmos são muito amplas: podem ser usados para analisar grandes quantidades de dados e obter informações sobre clientes, operações e mercados, tomar decisões informadas que impulsionam o crescimento dos negócios, melhoram a eficiência da empresa e nos guiar pelo melhor caminho no trânsito urbano.

Apesar de gestores em geral não precisarem dominar a ciência por detrás da concepção e desenvolvimento dos algoritmos, é interessante que estejam cientes daqueles mais comumente usados em seus negócios. Abaixo, segue uma pequena lista exemplificando alguns dos algoritmos comumente aplicados na IA:

1. **Algoritmos para redes neurais artificiais:**¹⁷ são algoritmos modelados especificamente para operarem 'em rede' e distribuídos nas camadas de 'neurônios artificiais', em sistemas chamados de Redes Neurais Artificiais (RNA) – estruturas semelhantes ao cérebro humano. São usados na realização de tarefas complexas,

¹⁷ Wikipedia. Disponível em https://pt.wikipedia.org/wiki/Rede_neural_artificial, visitado em 01 de abril de 2023.

tais como reconhecimento de imagens, processamento de linguagem natural (PLN) e reconhecimento de voz.

2. **Árvores de decisão:**¹⁸ são usados para problemas de classificação e previsão, onde o objetivo é prever uma variável de destino com base em um conjunto de variáveis de entrada. Sendo um modelo de abordagem preditiva aplicável em aprendizado de máquina, as árvores de decisão são frequentemente usadas em soluções de IA para marketing, finanças e atendimento ao cliente.
3. **K-Nearest Neighbor (KNN):**¹⁹ algoritmo empregado em sistemas de aprendizado não supervisionado, pode ser utilizado para resolver problemas de classificação. O algoritmo funciona encontrando 'k' pontos de dados que estão mais próximos para determinar a natureza de um 'novo ponto' de dado ainda não identificado; desta maneira, classificando por 'aproximação mais provável' determinada por um número e tipo 'k' de vizinhos mais próximos. O KNN é frequentemente usado para tarefas onde há falta de dados completos, ou aproximações estatísticas precisam ser usadas, tais como sistemas de recomendação de produtos e na detecção de fraudes.
4. **Support Vector Machines (SVM):**²⁰ algoritmo de aprendizado supervisionado, utilizado para resolver problemas de classificação e de regressão, resultando no reconhecimento de padrões. O algoritmo encontra a melhor linha ou 'hiperplano', que separa os dados coletados em diferentes classes ou agrupamentos. O SVM é frequentemente usado no reconhecimento e classificação de textos e de imagens.

2.13 APLICAÇÕES DE PROJETOS DE INTELIGÊNCIA ARTIFICIAL NAS ORGANIZAÇÕES

Aplicações de inteligência artificial em projetos de marketing

58

A Inteligência Artificial (IA) está cada vez mais presente na execução de estratégias de marketing, trazendo maior precisão, personalização e eficácia aos projetos [1]. A seguir, detalhamos algumas dessas aplicações:

1. **Recomendações Personalizadas:** Com base em algoritmos de aprendizado de máquina, a IA pode analisar dados de clientes e consumidores para inferir quais tipos de produtos ou serviços seriam mais atraentes para determinados indivíduos [2]. Empresas como a Amazon, por exemplo, utilizam esse tipo de sistema para oferecer aos seus usuários produtos que possam ser de seu interesse, melhorando a experiência do cliente e aumentando as vendas [3].

¹⁸ Wikipedia. Disponível em https://pt.wikipedia.org/wiki/Aprendizagem_de_%C3%A1rvore_de_decis%C3%A3o, visitado em 01 de abril de 2023.

¹⁹ Wikipedia. Disponível em https://en.wikipedia.org/wiki/K-nearest_neighbors_algorithm, visitado em 01 de abril de 2023.

²⁰ Wikipedia. Disponível em https://pt.wikipedia.org/wiki/M%C3%A1quina_de_vetores_de_suporte, visitado em 01 de abril de 2023.

2. **Análise Preditiva:** Os sistemas de IA são capazes de coletar e analisar grandes quantidades de dados, identificando padrões e fazendo previsões sobre tendências futuras [4]. Isso pode ser útil, por exemplo, para determinar quais clientes têm maior probabilidade de realizar uma compra ou quais produtos têm maior probabilidade de ter uma grande demanda.
3. **Otimização de Campanhas de Marketing:** A IA pode aprimorar a eficácia das campanhas de marketing, ao permitir a realização de testes A/B em tempo real, fornecendo feedback sobre o desempenho das campanhas em andamento e permitindo ajustes baseados em dados [5].
4. **Chatbots:** Os chatbots, amplamente utilizados no atendimento ao cliente, têm capacidade para atender a demandas 24/7, gerando benefícios como melhoria da experiência do cliente, redução do tempo de espera e maior eficiência operacional [6].
5. **Reconhecimento de Imagem e Vídeo:** Apesar de ser uma área ainda em desenvolvimento e com desafios éticos a serem enfrentados, a IA já é capaz de analisar imagens e vídeos automaticamente para identificar objetos ou pessoas específicas, o que é especialmente útil em campanhas de marketing que envolvem conteúdo visual [7].
6. **Projetos de Sistemas Integrados por Voz:** A popularização dos assistentes de voz integrados em dispositivos inteligentes oferece novas oportunidades para o desenvolvimento de projetos de marketing, potencializando a entrega de benefícios substanciais tanto para consumidores e clientes quanto para as organizações fornecedoras desses serviços e produtos [8].

Aplicações da inteligência artificial em projetos financeiros

59

Os projetos financeiros são notoriamente complexos e desafiadores. A implementação de sistemas de Inteligência Artificial (IA) traz um nível de eficiência, precisão e sofisticação inéditos para o setor, destacando-se em várias frentes:

1. **Detecção de Fraude:** O uso de algoritmos de IA para analisar grandes volumes de dados financeiros permite a detecção de padrões que podem indicar atividades fraudulentas, possibilitando ações proativas para prevenir perdas significativas [1]. Por exemplo, empresas de cartão de crédito usam IA para identificar padrões anômalos de gastos que podem indicar fraude [2].
2. **Análise Preditiva:** A IA tem a capacidade de analisar grandes volumes de dados financeiros em tempo real, fornecendo previsões detalhadas sobre tendências futuras do mercado, como variações nos preços das ações [3]. Isso pode auxiliar gestores financeiros a tomar decisões mais informadas e, portanto, mais eficientes.

3. **Assistentes Virtuais:** Os assistentes virtuais, alimentados por IA, podem atender a demandas do cliente, monitorar o comportamento dos investidores e processar transações, liberando os profissionais para se concentrarem em tarefas mais complexas, como a análise dos resultados financeiros [4].
4. **Gerenciamento de Riscos:** A IA pode auxiliar na identificação de riscos potenciais inerentes a um projeto e suas entregas, possibilitando o desenvolvimento de estratégias proativas. Os sistemas de IA podem auxiliar no gerenciamento de riscos de crédito, identificando a probabilidade de inadimplência em empréstimos bancários e pagamentos com cartão de crédito [5]. Da mesma forma, podem auxiliar no gerenciamento de riscos de investimento, antecipando mudanças futuras nos mercados e o potencial impacto em produtos financeiros [6].

Aplicações da Inteligência Artificial em Projetos de Recursos Humanos

60

A Inteligência Artificial (IA) tem o potencial de transformar fundamentalmente a forma como os departamentos de Recursos Humanos (RH) operam, trazendo melhorias significativas para os processos e as práticas de gestão de pessoas. Alguns exemplos incluem:

1. **Recrutamento e Seleção:** Ferramentas de IA podem automatizar e otimizar o processo de recrutamento, desde a triagem de currículos até a realização de entrevistas iniciais [1]. Além disso, a IA pode ajudar a identificar os candidatos mais adequados para as vagas, tornando o processo de recrutamento mais eficiente e eficaz.
2. **Gestão de Desempenho:** A IA pode auxiliar na identificação de áreas onde os funcionários precisam aprimorar seu desempenho, fornecendo orientações individualizadas e recomendações para treinamentos e desenvolvimento [2]. Além disso, a IA pode identificar os melhores desempenhos entre os funcionários, sugerindo incentivos e gerando insights para disseminar boas práticas na empresa.
3. **Gestão de Talentos:** A IA pode ajudar a identificar e preencher lacunas de talentos na organização, recomendando novos programas de treinamento adaptados às necessidades individuais dos funcionários. Além disso, pode auxiliar no planejamento de processos sucessórios, identificando líderes e gerentes em potencial dentro da organização [3].
4. **Engajamento da Força de Trabalho:** A IA pode fornecer suporte e recursos personalizados aos funcionários, melhorando os níveis de satisfação e, potencialmente, a retenção de funcionários [4].

5. **Gestão da Conformidade:** A IA pode ajudar as equipes de RH a se manterem atualizadas com as mudanças regulatórias e identificar proativamente possíveis problemas de conformidade na empresa [5].
6. **Análise Preditiva Comportamental:** A IA pode ajudar as equipes de RH a identificar padrões e tendências no comportamento dos funcionários, permitindo prever cenários que impactam a organização, como a rotatividade ou o absenteísmo [6].

A Inteligência Artificial (IA) na Área da Saúde: Aplicações Inovadoras

61

A Inteligência Artificial (IA) tem sido uma força transformadora na área da saúde, impulsionando avanços significativos na detecção, diagnóstico, tratamento e prevenção de doenças. Aqui estão alguns exemplos notáveis de aplicação da IA no setor de saúde:

1. **Processamento de Imagens Médicas:** A IA pode ser aplicada na interpretação de imagens médicas, como radiografias, tomografias computadorizadas e ressonâncias magnéticas. Algoritmos de aprendizado profundo têm demonstrado um alto nível de precisão na detecção de anomalias nessas imagens, muitas vezes superando a precisão dos radiologistas humanos [1].
2. **Diagnóstico e Tratamento Personalizado:** A IA pode ajudar os profissionais de saúde a diagnosticar e tratar doenças com mais precisão e eficiência. Algoritmos de IA podem analisar prontuários eletrônicos, dados genômicos e outros dados de saúde do paciente para identificar padrões e oferecer uma abordagem de tratamento mais personalizada [2].
3. **Desenvolvimento de Medicamentos:** A IA tem potencial para acelerar o processo de descoberta e desenvolvimento de novos medicamentos. Pode analisar grandes volumes de dados clínicos, genômicos e moleculares para identificar novos alvos terapêuticos e otimizar o design de moléculas de medicamentos [3].
4. **Telemedicina:** A IA está desempenhando um papel fundamental na telemedicina, permitindo o monitoramento remoto de pacientes e a entrega de cuidados de saúde personalizados. Por exemplo, os chatbots de IA podem ajudar na triagem inicial de pacientes, fornecendo respostas automáticas a perguntas comuns e direcionando os pacientes para aconselhamento médico quando necessário [4].

A inteligência artificial (ia) na indústria fabril: otimização de processos e melhorias de eficiência

62

A Inteligência Artificial (IA) está revolucionando a indústria fabril, desde a cadeia de suprimentos até as linhas de produção, oferecendo uma série de vantagens que contribuem para a melhoria da eficiência, otimização dos processos e diminuição de custos. Vejamos alguns exemplos:

1. **Manutenção Preditiva:** A IA é uma ferramenta valiosa para a manutenção preditiva na indústria fabril. Algoritmos de aprendizado de máquina podem monitorar dados coletados por sensores nos equipamentos em tempo real, detectar anomalias e prever falhas antes que elas ocorram [1]. Esta antecipação permite às empresas evitar interrupções indesejadas, reduzindo o tempo de inatividade e os custos de manutenção.
2. **Controle de Qualidade:** A IA é utilizada na melhoria do controle de qualidade através da análise de dados capturados por sensores e câmeras para identificar defeitos nos produtos. Esta aplicação ajuda a minimizar o desperdício e otimizar a gestão de inventário [2].
3. **Gestão da Cadeia de Suprimentos:** Na cadeia de suprimentos, a IA pode aprimorar as previsões de demanda, otimizando os níveis de estoque e identificando novos fornecedores com melhor relação custo-benefício [3]. Isto proporciona um fluxo de trabalho mais eficiente e aumenta a eficácia na entrega de produtos.
4. **Automação de Processos e Robótica:** A IA pode automatizar tarefas repetitivas, como montagem e embalagem de produtos, por meio de robótica. Isso permite realocar funcionários para tarefas de maior valor e contribui para uma maior eficiência da produção [4].

Inteligência artificial na educação: personalização do aprendizado e otimização dos processos

63

As soluções de Inteligência Artificial (IA) estão transformando radicalmente o campo da educação, possibilitando a personalização das experiências de aprendizado, o aumento do engajamento dos estudantes e a automação de tarefas administrativas.

1. **Aprendizado Personalizado:** A IA tem a capacidade de moldar modelos de aprendizagem individualizados para os alunos. Por meio da coleta e análise de dados de desempenho do aluno, cria-se um caminho de aprendizado personalizado que atende às necessidades e estilos de aprendizado individuais [1].
2. **Sistemas Inteligentes de Tutoria:** Esses sistemas usam IA para oferecer tutoria individualizada aos alunos. Eles avaliam o desempenho do aluno, fornecem feedback e orientação de forma eficaz e em tempo real. Isso facilita aos professores o uso mais eficaz do tempo, maximizando a produção didática [2].
3. **Programas Interativos de Aprendizado:** Com base nos dados coletados e analisados sobre cada aluno, a IA pode criar programas interativos que se adaptam

ao nível e ao progresso dos alunos. Isso permite a identificação de alunos que podem precisar de apoio adicional [3].

4. **Sistemas de Recomendação de Conteúdo Didático:** A IA também pode desenvolver sistemas de recomendação de conteúdo didático baseados no histórico de aprendizado, nos interesses e nas necessidades individuais dos alunos.

Inteligência artificial no setor de energia: otimização e sustentabilidade

64

Os sistemas de Inteligência Artificial (IA) têm o potencial de revolucionar o setor de energia, otimizando a produção, distribuição e consumo de energia, ao mesmo tempo que reduzem a pegada de carbono. Alguns dos principais usos da IA neste setor incluem:

1. **Gestão de Energia:** A IA pode ser usada para otimizar os sistemas de gerenciamento de energia. Isso pode ser feito por meio da análise de dados de consumo, identificando formas de reduzir custos e melhorar a eficiência energética.
2. **Manutenção Preventiva:** A IA pode ajudar na previsão da manutenção de equipamentos, o que permitiria o agendamento de manutenções preventivas e redução da ocorrência de falhas inesperadas, levando a uma gestão de custos mais eficiente.
3. **Smart Grids:** Os sistemas de IA podem ser usados para prever cenários de uso mais eficazes de energia renovável, como energia solar e eólica. Isso permitiria que as concessionárias planejassem melhor a demanda potencial e dimensionassem adequadamente a geração e distribuição de energia por regiões [3].
4. **Previsão de Preços de Energia:** A IA pode ser usada para prever os preços de energia no mercado, tornando a oferta mais competitiva. Isso teria um impacto positivo para os consumidores e aumentaria os lucros das concessionárias [4].
5. **Distribuição de Energia:** A IA pode otimizar a distribuição de energia, reduzindo as perdas de transmissão e melhorando a confiabilidade da rede [5].
6. **Estabilidade da Rede:** O uso da IA poderia melhorar a estabilidade das redes públicas, ao incrementar a capacidade de prever demanda, armazenamento e fornecimento de energia em períodos de flutuação de demanda [6].

Inteligência artificial no setor de transporte: otimização e segurança

65

A IA vem revolucionando o setor de transporte, permitindo uma otimização do fluxo de tráfego, aprimoramento da segurança e redução das emissões de poluentes. Eis algumas maneiras práticas de como a IA está sendo aplicada nesse setor:

1. **Veículos Autônomos:** A IA está sendo utilizada para impulsionar o desenvolvimento e a produção de veículos autônomos, incluindo automóveis, drones e caminhões. Estes sistemas podem reduzir a ocorrência de acidentes, minimizar as emissões danosas ao meio ambiente e aumentar a eficiência ao eliminar a necessidade de condutores humanos [1].
2. **Otimização de Tráfego:** Algoritmos de IA podem analisar dados de tráfego em tempo real para otimizar o tempo dos semáforos, reduzindo o congestionamento e melhorando os tempos de viagem [2]. Isso também pode incluir a otimização de rotas, como é o caso dos aplicativos Waze e Google Maps.
3. **Gerenciamento de Frotas:** No contexto do gerenciamento de frotas, a IA pode ser usada para otimizar a manutenção de veículos, reduzindo o tempo de inatividade e o uso de combustíveis. Isso é feito através de melhorias no agendamento preventivo e na otimização do consumo de combustível [3].
4. **Sistemas de Transporte Inteligente (ITS):** No âmbito dos ITS, a IA abrange uma ampla gama de aplicações, incluindo a gestão do fluxo de tráfego em áreas urbanas, sistemas inteligentes de estacionamento e redes de semáforos inteligentes [4].

2.14 INTELIGÊNCIA ARTIFICIAL APLICADA AO GERENCIAMENTO DE PROJETOS.

66

Como a Inteligência Artificial (IA) pode Auxiliar no Gerenciamento de Projetos

Introdução

O uso da Inteligência Artificial (IA) no gerenciamento de projetos pode transformar a forma como os projetos são gerenciados e executados. A IA permite a automatização de tarefas rotineiras, aprimora a tomada de decisões através de análises de dados mais acuradas e oferece insights valiosos para melhorar a eficiência dos projetos. Aqui estão algumas maneiras de como a IA pode ser empregada no gerenciamento de projetos:

1. **Automatização de Tarefas Rotineiras** A IA pode ser usada para automatizar tarefas rotineiras, como a programação de reuniões, o rastreamento de horas trabalhadas e a geração de relatórios de progresso. Isso economiza tempo, reduz o risco de erros humanos e permite que os gerentes de projeto se concentrem em tarefas de maior valor [1].
2. **Análise de Dados e Tomada de Decisões** A IA pode ajudar os gerentes de projeto na tomada de decisões ao analisar grandes volumes de dados e fornecer insights sobre tendências, riscos e oportunidades. Além disso, a IA pode prever

resultados de projetos com base em dados históricos e tendências atuais, o que pode ser útil para planejar e alocar recursos [2].

3. **Gerenciamento de Riscos** A IA pode ser usada para identificar riscos em potencial e sugerir ações corretivas. Isso é possível através da análise de dados do projeto e do ambiente externo, permitindo aos gerentes de projeto antecipar problemas e implementar soluções proativas [3].
4. **Aprendizado e Melhoria Contínua** Os sistemas de IA podem aprender com experiências passadas e ajustar suas ações para melhorar o desempenho futuro. Isso permite a melhoria contínua dos processos de gerenciamento de projetos, levando a melhores resultados [4].

A IA está redefinindo o gerenciamento de projetos, tornando os processos mais eficientes e a tomada de decisões mais precisa. O uso da IA pode ajudar as organizações a completar seus projetos de forma mais rápida e eficiente, melhorando assim a sua competitividade.

A Inteligência Artificial e a gestão de projetos: uma sinergia em evolução

Os profissionais da gestão de projetos frequentemente ponderam: "A inteligência artificial (IA) irá substituir o gerente de projetos?". Atualmente, e em um futuro próximo, a resposta é um sonoro "não".

As habilidades únicas de um gerente de projeto, incluindo a capacidade de interpretar situações subjetivas, a aptidão para alternar entre comunicação formal e informal, e a determinação para lidar com riscos de forma não convencional, ainda são características que só os seres humanos possuem. A IA, neste contexto, deve ser percebida como uma ferramenta que auxilia e complementa o trabalho do gerente de projeto e de sua equipe, em vez de substituí-los. Vale lembrar que a IA já é uma realidade proeminente em diversas empresas e setores.

Há pontos importantes a se considerar:

1. A IA não se refere apenas ao gerente de projetos e sua equipe, mas sim à organização como um todo.
2. O gerente de projetos e sua equipe estão na vanguarda de introduzir novas realidades baseadas em soluções de IA na organização.
3. Profissionais como os gerentes de projetos devem se capacitar continuamente para se tornarem proficientes na implementação da IA na organização. Isso promoverá uma melhoria contínua e adaptará as novas realidades resultantes da transição destes projetos com IA.

Portanto, a IA é um recurso que potencializa a eficácia dos gerentes de projeto, em vez de ameaçar suas funções. É essencial abraçar essa tecnologia e integrá-la aos processos de gestão de projetos para melhorar e aprimorar as práticas de trabalho existentes.

A Inteligência Artificial e a gestão de projetos: expandindo horizontes

Os gerentes de projetos devem considerar aspectos chave relacionados à seleção, teste, preparação e operacionalização de soluções de IA em projetos. Assim, além de dominar o uso de ferramentas de IA, eles também estarão preparados para gerenciar projetos de IA para a organização.

Existem algumas práticas recomendadas que podem apoiar a gestão de projetos com IA ou de projetos de IA:

1. **Identificação do problema a ser resolvido pela IA:** É crucial definir o problema que a IA irá resolver. Diferentes ferramentas ou sistemas de IA podem ser mais adequados para certos tipos de projetos do que outros. O benefício do projeto e o valor agregado à organização também devem ser considerados.
2. **Teste da adequação da solução de IA para o problema definido:** O primeiro passo é estabelecer critérios de teste específicos para a natureza do projeto (por exemplo, velocidade, precisão, qualidade dos dados obtidos). É essencial garantir a coleta adequada de dados para testes, minimizando o viés e correspondendo ao tipo de dados a serem coletados em campo. Várias rodadas de testes devem confirmar a consistência dos resultados obtidos, garantindo sua confiabilidade. Finalmente, é necessário proceder à validação dos resultados.
3. **Coleta e gestão de dados necessários para a resolução do problema:**
 - a. Coleta: É preciso assegurar que a quantidade de dados necessários para aplicar a solução de IA selecionada esteja disponível, seja confiável e consistente.
 - b. Gestão: Isso envolve a classificação correta, armazenamento e tratamento adequado dos dados para uso em testes preliminares e preparação do sistema.
4. **Seleção e aplicação do(s) algoritmo(s) adequado(s):** Este é um processo altamente complexo que requer conhecimento especializado para alinhar adequadamente o algoritmo aos objetivos do projeto, características dos dados utilizados, recursos disponíveis (capacidade computacional, prazo, gerentes responsáveis, etc.), e precisão dos resultados, garantindo o desempenho dentro das limitações do projeto. Também é importante prever a capacidade dos stakeholders envolvidos em interpretar as informações geradas pelo algoritmo. A experiência em projetos similares pode ser muito útil para essa tarefa.

5. **Treinamento do algoritmo para otimização do desempenho e validação de contribuições potenciais:** A partir da seleção dos dados, adequadamente classificados e estruturados para servir ao projeto, é necessário definir o modelo de treinamento do algoritmo, que ocorre ao alimentar o modelo com os dados disponíveis. Durante esse processo, avalia-se o desempenho (com base em critérios predefinidos) em um conjunto de dados específico para tais testes, recalibrando o modelo conforme necessário para otimizar seu desempenho final. Uma vez operacional, o desempenho alcançado durante o projeto pode ser comparado aos melhores resultados obtidos no conjunto de dados de teste, este servindo como referência.

Em suma, o gerenciamento eficaz de projetos de IA requer uma combinação de habilidades técnicas, estratégicas e de liderança. A medida que a IA se torna mais integrada ao nosso trabalho, é essencial que os gerentes de projetos expandam seus horizontes para além do gerenciamento tradicional de projetos e se adaptem a este novo paradigma.

A Inteligência Artificial e a gestão de projetos: compreendendo o ciclo de vida de um projeto de IA

Definição genérica para a "Gestão de um Projeto de IA"

"É um empreendimento que visa gerar um resultado (um produto ou serviço) funcional que incorpore funcionalidade(s) de IA, para ser usado por pessoas, organizações e/ou máquinas/outros sistemas, de modo a realizar um objetivo determinado." ²¹

Um projeto que utiliza e/ou gera soluções incorporando características e funcionalidades de IA não se baseiam em uma abordagem única de gerenciamento, sendo necessário conhecimento especializado no gerenciamento de projetos (abordagem híbrida dos modelos *waterfall* e ágil) e, em especial, o gerenciamento do 'Fluxo de Trabalho da IA' (FTIA). Este fluxo de trabalho específico envolve: (a)- coletar, manipular e transformar dados; (b)- incorporar os dados coletados, tratados como entradas para subsequente codificação, treinamento, avaliação e interpretação, ajuste fino e implementação de um sistema de IA, envolvendo complexos modelos matemáticos. O ajuste fino desses complexos modelos matemáticos é fortemente influenciado pela natureza e qualidade dos dados coletados, o que torna difícil prever, planejar e gerenciar a experimentação e subsequente aplicação dos dados.

O FTIA é caracterizado por dependências sequenciais, grandes ciclos de feedback, e um número indeterminado de ciclos de exploração/experimentação ou treinamento e aplicação de dados.

A gestão de projetos de IA pode ser baseada em elementos oriundos de três abordagens em gerenciamento:

²¹ VIAL, G. 1 | CAMERON, A.; GIANNELIA, T.; JIANG, J. *Managing artificial intelligence projects: Key insights from an AI consulting firm*. Wiley, Practitioner Paper, DOI: 10.1111/isj.12420, 29 de Novembro de 2022

- 1- **elementos do gerenciamento tradicional de projetos (GTP):** auxiliam na definição e gerenciamento do projeto em fases amplas, incorporados aos elementos de gerenciamento organizacional como um todo;
- 2- **elementos de práticas ágeis do gerenciamento de projetos (GAP):** usados para organizar o trabalho a ser realizado em ciclos iterativos e incrementais;
- 3- **elementos do fluxo de trabalho de IA (FTIA):** de caráter técnico, impulsionam a gestão de tarefas necessárias para o desenvolvimento, treinamento e ajuste fino do modelo de IA a ser desenvolvido e/ou incorporado.

Por detrás dos processos combinados de gestão, existe também uma abordagem de lógica inspirado fundamentação conceitual das lógicas institucionais ²²²³. O termo 'lógica' empregado neste material consiste em normas, valores e comportamentos prescritos comumente compartilhados. Estes influenciam a compreensão dos atores envolvidos sobre como o trabalho deve ser realizado, e enquadrado por cada uma dessas formas de pensar sobre projetos de IA.

Uma abordagem adequada no gerenciamento projetos de IA destaca a existência de três lógicas principais —definindo as normas, valores e comportamentos prescritos na organização executora do projeto, compartilhados pelos stakeholders envolvidos no trabalho a ser realizado – legitimando execução do projeto:

- uma **lógica tradicional** de gerenciamento de projetos (LTGP);
- uma **lógica ágil** (LAGP) e
- uma **lógica de fluxo de trabalho** de IA (LFTIA).

Como seria de se esperar, a adoção combinada de três lógicas distintas gera um certo número de conflitos e problemas potenciais no gerenciamento de projetos de IA, ocorrendo entre os atores envolvidos - especialmente quando estão mais ou menos habituados a uma ou outra forma de trabalho (Tabela 1).

Em particular, se destaca conflitos oriundos da lógica (emergente) inerente ao FTIA, que revela oito conflitos que surgem quando combinado aos processos apoiados pelas LTGP e LAGP para o gerenciamento de projetos de IA.

Tabela 1 – Estruturas Lógicas Adotadas na Gestão de Projetos de IA

Estratégia	LTGP	LAGP	LFTIA
Principais valores e objetivos	<u>Valores:</u> Aderir aos padrões (por exemplo, PMBOK, seção 1.1). Ênfase no planejamento e cumprimento das restrições de tempo e orçamento.	<u>Valores (Manifesto Ágil):</u> Indivíduos e interações sobre processos e ferramentas. software que trabalha sobre uma	<u>Valores:</u> Devido à natureza emergente deste campo, não foi possível identificar valores claros e consensuais na literatura. No entanto,

²² BERENTE, N., LYYTINEN, K., YOO, Y., e MAURER, C.. *Institutional logics and pluralistic responses to enterprise system implementation: A qualitative meta-analysis*. MIS Quarterly, 43(3), 873–902. (2019) <https://doi.org/10.25300/MISQ/2019/14214>

²³ THORNTON, P. H., OCASIO, W., e LOUNSBURY, M.. *The institutional logics perspective: A new approach to culture, structure, and process*. Oxford University Press. (2012)

	<p><u>Metas:</u> Entregue o projeto respeitando as restrições de tempo, orçamento e escopo (o "Triângulo de Ferro").</p>	<p>documentação completa. Colaboração do cliente em detrimento da negociação de contratos. Responder à mudança ao invés de seguir um plano.</p> <p><u>Metas:</u> Entregue frequentemente software valioso aos clientes. Acomodar mudanças ao longo do projeto.</p>	<p>alguns esforços estão em andamento para definir valores abrangentes para IA em geral (por exemplo, justiça e inclusão).</p> <p><u>Metas:</u> Atingir o nível desejado de desempenho do modelo, por exemplo, conforme definido pela otimização de uma função objetivo. Atender aos requisitos do modelo de IA (ex: robustez e explicabilidade).</p>
Premissas Subjacentes	<p>Planejamento formal, estimativa, e controle do processo facilitar o sucesso do projeto. Desenvolvimento em fases com portões de palco ajudam a reduzir incerteza.</p>	<p>Autonomia da equipe e participação do cliente fomentar o sucesso. A incerteza não pode ser eliminado, mas pode ser gerenciado através processos adaptativos. A regularidade do processo (por exemplo, ritmo curto e consistente de iterações) ajuda a mover o projeto adiante.</p>	<p>Dados de alta qualidade representam o fenômeno de interesse e é fundamental para projetar o sucesso. O sucesso depende de uma pesquisa baseada processo científico envolvendo etapas de exploração e experimentação organizada em tarefas sequenciais, fazendo um caminho claro adiante difícil de prever no início do projeto.</p>
Papéis e responsabilidades	<p>O gerente de projeto é responsável por todo o projeto e atua como líder e gerente do projeto. O papel do gerente de projetos é altamente institucionalizado e legitimado por organismos oficiais de certificação (PMI, Axelos, etc). A responsabilidade e a contribuição para o sucesso do projeto são avaliadas individualmente. Os membros da equipe do projeto são altamente especializados.</p>	<p>A responsabilidade e prestação de contas pelo projeto são assumidas por um coletivo de indivíduos. Embora institucionalizados em guias e certificações oficiais (ex: <i>Certified Scrum Master</i>, <i>Agile coach</i>), os papéis são fluidos e não estão associados a cargos específicos (por exemplo, proprietário do produto). As equipes são multifuncionais e desfrutam de um alto grau de autonomia. O trabalho é planejado e executado usando uma abordagem colaborativa (ex: planning poker).</p>	<p>A autoridade é baseada no conhecimento técnico ou de domínio e na experiência acadêmica, não na liderança gerencial. Os membros da equipe são altamente especializados. As funções dos membros da equipe são normalmente associadas a cargos (ex: cientista de dados, engenheiro de dados), embora o grau de institucionalização dessas funções varie (alguns fornecedores oferecem certificações para engenheiros de dados, mas não há uma autoridade única que forneça essas certificações).</p>

<p>Background e treinamento</p>	<p>Background: Corpo oficial de conhecimento construído sobre iniciativas de gerenciamento de projetos em engenharia (projetos militares e civis de grande escala).</p> <p>Treinamento: Capacitação e certificações oficiais (ex: Scrum, PMP, PRINCE2, etc.).</p>	<p>Background: Experiências e conhecimentos de um grupo de engenheiros de software.</p> <p>Treinamento: Caminhos e exames oficiais de certificação (ex: <i>Certified ScrumMaster</i>).</p>	<p>Background: O conhecimento científico é adquirido principalmente na educação de nível superior (ex: formação acadêmica como o mestrado e doutorado).</p> <p>Treinamento: Certificação e exames fornecidos por fornecedores específicos estão surgindo (ex: Microsoft Certified: Azure Cientista de Dados Associado).</p>
---	---	--	---

Fonte: reflexões do autor, baseado no modelo proposto por VIAL et al. (2022)

Certas estratégias são sugeridas para o adequado gerenciamento de projetos de IA, dentre as quais (Tabela 2):

- A- Validação regular da Contribuição de Valor (CdV) do projeto: esta avaliação deve ocorrer de maneira estruturada antes do projeto ser iniciado (e.g., análises de viabilidade baseadas no plano de negócios) e, subsequentemente, revisada em intervalos regulares, assegurando haver a viabilidade do projeto tanto para os stakeholders que desempenham o trabalho, na organização que emprega recursos do gerenciamento, como para os stakeholders que deverão utilizar o resultado oriundo da(s) entrega(s) previstas no projeto (e da organização na qual estão inseridos).
- B- Validação das Métricas de Progresso e Desempenho (MPD) empregados: considerando que muitos projetos de IA, tanto pela sua natureza quanto no mercado em que estão inseridos, podem requerer diferentes indicadores de progresso (KPIs), os critérios de aceite para a conclusão de tarefas específicas presentes no fluxo de trabalho da IA e subsequente entrega dos resultados, podem demandar definições específicas de "completado".
- C- Determinar o Valor Marginal (VM) da abordagem de ciência de dados adotada: de maneira a garantir que o trabalho específico de esforços de ciência de dados seja conduzido apenas quando se pode verificar que agregará valor comercial ao projeto, em vez de se basear apenas no seu mérito técnico.
- D- Garantir a Adoção Compartilhada (AC) do esforço de gestão: criar condições adequadas para fomentar um 'esforço em conjunto' de equipes de gestão (de negócios, de projetos, etc.) e técnicas (técnicos, engenheiros e cientistas de dados, etc.), de maneira a manter um fluxo de compartilhamento de informações e de apoio mútuo de trabalho (co - desenvolvimento).

Estas estratégias podem ser associadas a conflitos potenciais, que emergem durante o gerenciamento de projetos (descritos mais adiante no texto).

Tabela 2 – Estratégia Adotada e Conflitos Potenciais

Estratégia	Aplicação	Conflitos relacionados
Contribuição de Valor (CdV) do projeto	Os stakeholders realizam avaliações preliminares de maturidade e prontidão da organização (e equipe), usando o modelo por estágios para (re)avaliar um projeto e assegurar continuamente sua viabilidade. Às vezes, é mais benéfico para todas as partes envolvidas, interromper, replanejar ou cancelar o projeto.	Conflito #1 (diferentes suposições frente à incerteza) Conflito #2 (diferentes abordagens para a realização das entregas) Conflito #6 (diferentes padrões, abordagens e fontes de mudança)
Métricas de Progresso e Desempenho (MPD)	Gestores de projeto realizam testes com sistemas de IA que fornecem resultados 'intermediários', quando o objetivo é o de validar uma solução final. Embora esses resultados intermediários possam não estar em conformidade com os requisitos de aceite dos entregáveis, eles permanecem relevantes para o sucesso do projeto.	Conflito #5 (Organização assimétrica de tarefas de trabalho) Conflito #7 (Diferentes unidades de medidas (KPIs) de progresso)
Valor Marginal (VM) da ciência de dados	Sempre é possível aumentar a capacidade técnica e de desempenho em projetos de IA. Isso só faz sentido se estiver alinhado com o negócio do projeto. Os stakeholders envolvidos devem se esforçar para garantir que o trabalho seja sempre guiado pelo valor potencial comercial dos projetos, e não na oferta da mais sofisticada solução técnica (por exemplo, grau de precisão do modelo).	Conflito #3 (Objetivos mal correlacionados) Conflito #4 (Assimetria nas expectativas de qualidade)
Adoção Compartilhada (AC) do esforço de gestão	Em vez de tentar encontrar uma única pessoa que possa lidar com todos os aspectos de um determinado projeto (ou seja, um unicórnio), a abordagem ideal busca combinar a expertise do gestor de negócios e/ou de projetos com a dos cientistas de dados (e outros gestores técnicos), buscando incrementar a comunicação e encontrar um equilíbrio entre a área de negócios e os requisitos técnicos necessários.	Conflito #8 (Diferentes abordagens para fomentar a colaboração entre stakeholders)

Fonte: reflexões do autor, baseado no modelo proposto por VIAL et al. (2022)

As estratégias se apoiam nas três principais abordagens de gerenciamento de projetos, que normalmente são adotadas em conjunto, quando se realiza um projeto de sistemas de IA.

Abordagens de Gerenciamento de Projetos de IA:

1- Gerenciamento Tradicional de Projetos (GTP):

O gerenciamento de um projeto deve permitir a governança de recursos (investimentos, materiais e humanos), o gerenciamento do conhecimento e o alinhamento com as linhas estratégicas da organização detentora dos recursos empregados no projeto. Desta maneira, se adota uma abordagem similar à preconizada pela metodologia PRINCE2²⁴, o Método de Design Thinking²⁵, e outras similares, em particular no tocante aos seus Princípios e Processos de gestão.

Desta maneira, o gerenciamento de 'alto nível' do projeto é estruturado por estágios, e entre cada um se insere um ponto de controle para (re)avaliar o progresso e a viabilidade do projeto, sob as óticas de gestão e estratégica.

Para avançar em cada estágio, gestores devem realizar o trabalho de gerenciamento como planejado, e formalizar sua conclusão e obter a necessária aprovação (junto ao comitê diretor do projeto). Ao mesmo tempo, com base no desempenho alcançado e nas lições aprendidas em um determinado estágio, realizar o planejamento detalhado para o seguinte. Este modelo de gestão permite que tanto o 'comitê gestor' possa realizar processos de tomada de decisão alinhados com as estratégias associadas ao projeto, quanto fornecer feedback sobre o trabalho especialista realizado pelos 'times de projeto', e orientar o trabalho previsto para o estágio seguinte. Este modelo baseado em 'portões de passagem' (*gateways*) mantém os objetivos gerais do projeto atualizados e evidentes para todos os stakeholders, permitindo que cada equipe / stakeholders foque em seus objetivos tácitos (de projeto) e nos seus papéis e responsabilidades.

A governança de recursos junto à organização deve, desta forma, ser mais eficiente, do ponto de vista da organização, sem onerar o esforço específico do trabalho realizado no projeto.

2- Gerenciamento Ágil de Projetos (GAP):

Ao desenvolver um projeto norteado pela inovação e tecnologia, muitas organizações adotam abordagens inspiradas em práticas e métodos ágeis. No entanto, uma mesma abordagem não é utilizada durante todo o projeto, sempre da mesma maneira.

A metodologia Scrum[®] pode ser, de maneira mais abrangente, adequada para a geração de um Produto Mínimo Viável (PMV), dada a natureza iterativa dos processos ágeis também permite que as equipes descubram e resolvam os problemas desde o início. Isso não exclui outras abordagens ágeis. Ao se desenvolver modelos preliminares de sistemas de IA, por exemplo, que apresentar baixo desempenho ou se a qualidade dos dados coletados for inferior ao esperado, ajustes rápidos e pontuais podem vir a ser necessários, de forma que é adequado permitir a autonomia das equipes de desenvolvimento que buscarão a priorização progressiva para adequação do trabalho a ser realizado.

3- Fluxo de Trabalho de IA (FTIA):

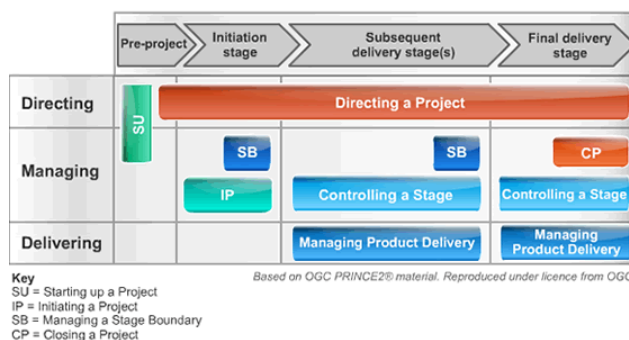


Figura 4 - Processos do PRINCE2[®]

²⁴ Processos da metodologia PRINCE2[®], disponível em <https://www.prince2.com/usa/prince2-processes>, visualizado em 01 de maio de 2023

²⁵ Processos do método de Design Thinking, disponível em <https://kellercenter.princeton.edu/programs/tiger-challenge/details/methodology>, visualizado em 01 de maio de 2023

Ao se gerenciar as entregas do projeto, os stakeholders responsáveis executam uma variedade de tarefas especializadas, necessárias para implementar modelos matemáticos complexos. Por exemplo, o trabalho de engenheiros de dados, cujo trabalho foca na limpeza e preparação dos dados usados para alimentar os modelos construídos e testados pelos cientistas de dados. Assim que estiverem prontos para serem implantados, esses modelos são compartilhados com engenheiros de software, que os estruturam em um software funcional (ex: uma API).

Para um projeto de IA, dados precisam ser coletados, minerados e validados; as características do modelo precisam ser projetadas; e os modelos precisam ser construídos e validados, antes que seu desempenho possa ser testado. Essas tarefas devem ser executadas em sequência, onde a saída de determinada tarefa se torna a entrada para a próxima. Desta forma, se pode planejar o que as equipes entendem como um “fluxo de trabalho de IA”, que geralmente contém um alto grau de incerteza. A seguir, um exemplo das etapas genéricas de um projeto de IA (Tabela 3), associando seus objetivos de projeto com as lógicas de trabalho empregadas, os ciclos de trabalho e os principais stakeholders envolvidos.

Tabela 3 - Processos e Estágios da Gestão de Projetos de IA

Estágio	Objetivo(s)	Abordagem de GP²⁶	Ciclo	Stakeholders
Estudo de viabilidade técnica e de negócios	- Exploração, Ideação, modelagem PMV	PRINCE2®, DT, FTIA	Governança, pré-projeto, opções de tecnologia	Comitê do projeto, GP, ger. de negócios, equipe técnica de IA (TI)
Alinhamento dos objetivos estratégicos / de negócios, com os de projeto	- Alinhamento do estudo de viabilidade - Definição do plano de negócios - Definição de objetivos SMART	PRINCE2®, FTIA	Governança, alinhamento estratégico, estratégias de adoção de tecnologia	Comitê do projeto, GP
Planejamento geral do Projeto (<i>Blueprint</i>)	- Planejamento geral do projeto (<i>PID</i>) - Definição de estágios de gerenciamento do projeto - Definição dos planos de gerenciamento de times de produção - Definição dos requisitos de aceite dos resultados nos estágios - Outros requisitos	PRINCE2®, Ágil, FTIA	Governança, alinhamento tácito, processos de gestão e técnicos	Comitê do projeto, GP, times de produção + equipe técnica de IA (TI)
Planejamento do estágio 01 de gestão	Planejamento detalhado das entregas previstas no estágio	PRINCE2®, Ágil, FTIA	Governança, processos de gestão e técnicos	Comitê do projeto, GP, times de produção +

²⁶ Exemplos apenas para ilustrar conceitos de gestão, não excluindo outros *frameworks* de gestão

	<ul style="list-style-type: none"> - Planejamento de times especialistas de produção (gerenciamento de resultados) - Gerenciamento da comunicação e aprovação de desempenho e resultados - Obtenção de autorização para passagem de estágio 			equipe técnica de IA (TI)
Planejamento do estágio "n" de gestão	-- (repetir itens anteriores) – + Aplicar lições aprendidas	PRINCE2®, Ágil, FTIA	Governança, processos de gestão e técnicos	Comitê do projeto, GP, times de produção + equipe técnica de IA (TI)
Planejamento do estágio final de gestão	<ul style="list-style-type: none"> - Definição do estágio de conclusão do projeto Realização das entregas finais / consolidadas do projeto previstas neste estágio - Obter aprovação para formalização das entregas finais e encerramento do projeto 	PRINCE2®, Ágil, FTIA	Governança, processos de gestão e técnicos	Comitê do projeto, GP, times de produção + equipe técnica de IA (TI)
Lançamento e acompanhamento do PMV (Prova de Conceito – PdC)	<ul style="list-style-type: none"> - Acompanhamento da entrega do resultado final do projeto - Acompanhamento da operação (como suporte) para manutenção e calibragem dos sistemas de IA - Homologação / verificação do valor agregado como proposto no projeto (<i>assessment</i>) 	PRINCE2®, Lean Management, FTIA	Governança, processos de gestão de negócios e técnicos	Comitê do projeto, GP, ger. de negócios, equipe técnica de IA (TI)

Fonte: reflexões do autor, baseado no modelo proposto por VIAL et al. (2022)

Lógicas de gerenciamento de projetos de IA e potenciais conflitos

Essas três lógicas podem gerar alguns conflitos, notadamente entre (Figura 2):

- (a) a lógica tradicional (LTGP) e a lógica de fluxo de trabalho de IA e (i LFTIA), e
- (b) a lógica ágil (LAGP) e a lógica de fluxo de trabalho de IA (LFTIA).

Ambos o gerenciamento de projetos tradicional e o de práticas ágeis são estruturados em corpos de conhecimento oferecidos por certificados profissionais. Embora atualmente não exista uma abordagem comum para gerenciar fluxos de projetos de IA - devido à natureza emergente desse fenômeno, está se formando uma base comum de seus componentes gerais, estruturados pelas principais empresas do mercado ²⁷. A lógica do fluxo de trabalho da IA é, portanto, menos desenvolvida do que as demais, exigindo maior adaptabilidade e maturidades das organizações que vão empreender neste campo.




Figura 5 - Modelo Integrado de Gestão e seus Potenciais Conflitos

1- LTGP versus LFTIA

1.1 Conflito # 1: Diferentes hipóteses baseadas no grau de incerteza

De acordo com a LTGP, a viabilidade de um projeto é determinada pelos estágios anteriores realizados, e a incerteza diminui ao longo do projeto, quando estimativas se confirmam de acordo com o planejamento (ou não). No entanto, devido a problemas potenciais nos dados e à complexidade matemática inerente à LFTIA, o grau de incerteza pode permanecer constante ou até aumentar, na medida em que os stakeholders realizam novos testes e validações.

1.2 Conflito # 2: Diferentes abordagens para gerenciamento das entregas

A teoria da LTGP determina que o cliente e o fornecedor de um projeto validem e aceitem as entregas realizadas, ao longo do projeto (de acordo com um planejamento validado ao seu início). De acordo com a LFTIA, no entanto, devido a haver um alto grau de incerteza sempre presente (#1), os resultados nem sempre podem ser entregues conforme o planejado. Sendo assim, as entregas reais do projeto nem sempre podem ser predeterminadas *a priori* e, como resultado, os stakeholders envolvidos podem ter suas expectativas frustradas (afetando a percepção de qualidade do projeto). Sendo assim, é muito importante que tanto o fornecedor e o cliente de um projeto de IA compreendam (e aceitem) os riscos inerentes ao desenvolvimento de IA, estando dispostos a investir em uma iniciativa que pode não ter o grau de sucesso esperado (de início).

1.3 Conflito # 3: objetivos mal correlacionados

²⁷ Google. (2018). *Machine learning workflow*. <https://cloud.google.com/ai-platform/docs/ml-solutions-overview>, Hoda, R., Salleh, N., Grundy, J., & Tee, H. M. (2017). Systematic literature reviews in agile software development: A tertiary study. *Information and Software Technology*, 85, 60-70. <https://doi.org/10.1016/j.infsof.2017.01.007> Microsoft Corporation. (2018). *What is the team data science process?* <https://docs.microsoft.com/en-us/azure/machine-learning/team-data-science-process/overview>

De acordo com a LTGP, os objetivos de um projeto buscam atender aos critérios de sucesso específicos e predeterminados no seu planejamento, geralmente associados à captura de valor ao negócio. A LFTIA tende a se concentrar em objetivos definidos pelas funções determinadas pelo emprego de certos modelos matemáticos, originalmente estruturados sem um determinado projeto em mente. Desta forma, quando um modelo aplicado ao sistema de IA do projeto promove a, melhoria no desempenho do sistema, isso pode gerar pouco ou nenhum efeito sobre o valor agregado ao negócio.

1.4 Conflito # 4: assimetria da expectativas de gerenciamento da qualidade

A LTGP sugere que o gerenciamento de qualidade deve ser realizado de acordo com critérios de qualidade pré-determinados. Ao se exceder as expectativas de qualidade previstas (*gold plating*) isso pode ser prejudicial. No entanto, stakeholders técnicos (ex: cientistas de dados) – tendo um papel proeminente no trabalho de IA, são fortemente influenciados por sua formação e experiência no campo, focados em utilizar técnicas de ponta. Isso pode estar em desacordo com a adoção daquelas técnicas que atenderão ‘apenas’ a um grau de qualidade mínimo previsto para o projeto.

2- LAGP versus LFTIA

2.1 Conflito # 5: Organização diferente das tarefas de trabalho

A LAGP enfatiza as iterações de duração fixa (geralmente com intervalo de tempo predeterminados), durante as quais a equipe se concentra na conclusão de tarefas priorizadas no planejamento da sprint. No entanto, a LFTIA tem sua abordagem de processos organizada em torno de uma série de pequenos experimentos, baseados na aplicação de algoritmos com tempos de execução/teste/validação imprevisíveis e variáveis (muitas vezes, a coleta e mineração de dados é mais previsível que testes e *deployment* de sistemas). De certa maneira, a obtenção de resultados parciais exigem alterações dentro de uma determinada iteração – ou até mesmo a realização de várias iterações adicionais, para se alcançar os resultados desejados.

2.2 Conflito #6: Diferentes fontes de mudança

A LFTIA envolve mudanças (por vezes de alto impacto) ao longo do processo, mas a origem de cada mudança pode ser muito diferente, afetando a função do cliente durante o projeto de IA. De acordo com a lógica ágil, a ‘mudanças’ são bem-vinda ao longo do processo de desenvolvimento, e muitas são conduzidas pelo cliente do projeto (ex: *Product Owner* (PO), ao validar produtos demonstrados na Sprint Review). Para a LFTIA, as mudanças são impulsionadas principalmente por resultados intermediários ou pela disponibilidade de novas técnicas e tecnologias empregadas para resolver um determinado problema, e sua avaliação pode – em certas ‘releases’ requerer aprofundado conhecimento técnico. Desta forma, nem todas as ‘releases’ podem ser realizadas sob a responsabilidade do cliente do projeto, e o mesmo pode não estar apto a fazer recomendações ou aceitar/recusar alterações geradas pela equipe de desenvolvimento.

2.3 Conflito # 7: assimetrias nos indicadores de progresso (KPIs)

Um princípio da LAGP é sempre entregar um 'produto funcional' ao final de cada iteração (*shipment*). Embutido na LFTIA, no entanto, estão os testes que são dependentes de avaliações em pequenos experimentos para validação de hipóteses, o que significa que os resultados intermediários não são necessariamente (sempre) soluções tangíveis e funcionais. Por exemplo, é difícil demonstrar ao cliente: 1- a funcionalidade (para avaliação do PO), 2- o progresso - em termos de valor agregado - ou 3- o ROI tangível para negócio, de certos avanços (por exemplo, mineração efetiva de banco de dados).

3.4 Conflito # 8: Diferentes abordagens para colaboração

A LAGP destaca a importância de 'equipes auto-organizadas e autônomas'. No entanto, o desenvolvimento de projetos de IA inclui evidências de trabalho altamente especializado - e realizado por indivíduos ou grupos pequenos de indivíduos. O isolamento pressuposto para algumas tarefas muito analíticas - 'trabalho solo' - segue as funções e responsabilidades de certos papéis presentes nestas iniciativas.

Esse conflito se estende para a natureza e o uso das ferramentas adotadas por certos stakeholders com um papel mais técnico, não sendo adequado para uso 'compartilhado' por outros. De acordo com o que é preconizado nas práticas ágeis, os engenheiros de software 'deveriam' rotineiramente utilizar ferramentas para gerenciar as tarefas junto à equipe, controlando o desenvolvimento de forma colaborativa. No entanto, processos de gestão e trabalho que seguem a LFTIA se concentra bastante em funções individuais e hiper especialistas. Por exemplo, os cientistas e engenheiros de dados podem não precisar (ou estar capacitados) a utilizar estas ferramentas colaborativas (e vice-versa, no tocante às ferramentas dos mesmos), em determinados estágios do projeto quando engenheiros de software e cientistas de dados precisam trabalhar em conjunto.

Abordagem híbrida – modelo generalizado

Embora os problemas associados à mistura de gerenciamento de projetos tradicional e práticas ágeis possam gerar potenciais conflitos, as estratégias propostas para lidar com eles (Tabela 3) – mesmo não representando uma análise abrangente de todas as possíveis instâncias quando tais conflitos precisam ser gerenciados, provêm um caminho onde a organização pode se preparar para melhor garantir o sucesso do projeto. Estas três lógicas e os conflitos que surgem durante o seu emprego combinado entre elas deve ser tratado tanto por líderes de gestão quanto por profissionais de IA, trabalhando em verticais específicas e setores do mercado os quais enfrentarão riscos de maneira distinta.

O ciclo de vida de um projeto envolvendo Machine Learning (ML)

67

O ciclo de vida de um projeto de IA, especialmente quando envolve o gerenciamento de grandes volumes de dados (Big Data), é uma sequência estruturada de etapas inter-relacionadas. Quando envolve sistemas de aprendizado de máquina, estas etapas podem ser descritas - de maneira geral - da seguinte forma:

Ciclo de vida de um Projeto de Inteligência Artificial

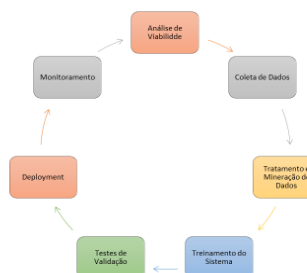


Figura 6 - Ciclo ML

O ciclo de vida de um projeto que envolve Inteligência Artificial (IA), o ML e o gerenciamento de Big Data pode ser delineado em etapas, desafios e necessidades particulares:

1. **Análise de Viabilidade:** Esta é a fase inicial, onde os benefícios projetados do projeto são avaliados em relação aos custos e riscos identificados. Este estágio requer uma compreensão abrangente de IA e gestão de negócios, estabelecendo as linhas de base estratégicas para avaliar o desempenho operacional do projeto (Russell, S. J., & Norvig, P., 2020).
2. **Coleta de Dados:** Todo projeto de Big Data deve ter um objetivo específico que guia esta etapa essencial e crítica. A qualidade, a tipificação e a quantidade dos dados coletados podem afetar significativamente o sucesso do projeto. É essencial considerar a qualidade e volume dos dados, diversidade, privacidade e segurança dos dados, governança de dados e armazenamento e gerenciamento de dados nesta etapa (Dhar, V., 2013).
3. **Tratamento e Mineração de Dados:** Esta etapa exige limpeza de dados, correção de inconsistências e lacunas nos dados, tratamento de outliers e seleção de variáveis relevantes. Técnicas de aprendizado de máquina e modelos estatísticos são utilizados para identificar padrões nos dados (Han, J., Pei, J., & Kamber, M., 2011).
4. **Treinamento do Sistema:** Os dados coletados e devidamente tratados são usados para treinar os sistemas de IA e validar o modelo. A seleção dos algoritmos apropriados depende de vários fatores, incluindo a natureza do problema, recursos disponíveis e experiências anteriores (Alpaydin, E., 2020).
5. **Testes de Validação:** Realizados em um ambiente de testes, esses testes permitem avaliar a eficácia do sistema e tomar a decisão de avançar para a próxima etapa ou retornar a etapas anteriores para fazer ajustes (Kohavi, R., 1995).

6. **Implantação (Deployment):** Aqui, o sistema de IA é lançado em um ambiente de produção, onde é esperado que ele espelhe o desempenho observado no ambiente de teste (Chickering, D. M., Heckerman, D., & Meek, C., 1997).
7. **Monitoramento:** A avaliação contínua do sistema durante a operação é crucial para garantir que ele esteja funcionando conforme o esperado e cumprindo seus objetivos (Caruana, R., & Niculescu-Mizil, A., 2006).

Competências e habilidades para gerenciamento de projetos envolvendo Inteligência Artificial

68

O Gerenciamento de Projetos (GP) que envolve o desenvolvimento e a aplicação de soluções de Inteligência Artificial (IA) requer um conjunto específico de competências e habilidades. Aqueles envolvidos em tais projetos precisam ter uma combinação de competências técnicas e não técnicas que se enquadrem tanto no escopo geral do gerenciamento de projetos quanto nas particularidades da IA.

Conhecimento geral do campo da IA: É essencial que os gerentes de projeto estejam a par do atual mercado de IA, incluindo seus possíveis benefícios, limitações e diferentes tecnologias e estruturas. Isso permite uma comunicação mais eficaz com os profissionais técnicos e outros stakeholders. Stakeholders mais técnicos precisam ter um aprofundado conhecimento teórico, treinamento formal e experiência na área, contextualizado pelo conhecimento e experiência no negócio da organização. EM contrapartida, stakeholders envolvidos com gerenciamento e o negócio em si, precisam conhecer os principais aspectos técnicos da IA para permitir sua melhor contribuição e interações eficazes com as equipes técnicas. A seguir, listamos algumas competências adicionais que podem se tornar necessárias:

1. **Compreensão do Processamento de Linguagem Natural (PLN):** Em projetos que desenvolvem funcionalidades em linguagem natural, o conhecimento de técnicas aplicadas ao PLN, tais como interfaces e funcionalidades para classificação de texto, análise de sentimento e reconhecimento de inferências, é imprescindível.
2. **Familiaridade com a visão computacional:** Para projetos que trabalham com dados visuais, como imagens ou vídeos, os gerentes de projeto precisam conhecer os aspectos gerais do campo da visão computacional, como a detecção de objetos e a segmentação de imagens.
3. **Preparação de dados:** É crucial estar familiarizado com as técnicas de preparação de dados para uso em projetos de IA, como limpeza de dados, engenharia de recursos e normalização de dados.
4. **Avaliação de desempenho técnico do projeto:** Os gerentes de projeto devem ser capazes de avaliar o desempenho dos modelos de IA utilizados em seus projetos, gerenciando adequadamente métricas apropriadas e assegurando o armazenamento correto dos dados.

5. **Familiaridade com artefatos e metodologias de gerenciamento de projetos:** Idealmente, os gerentes de projeto devem ter experiência com as ferramentas e metodologias usadas pela organização, garantindo que os projetos sejam concluídos no prazo e dentro do orçamento, cumprindo as entregas esperadas.
6. **Gerenciamento de riscos:** Um entendimento aprofundado do gerenciamento de riscos é primordial para projetos que utilizam ou desenvolvem sistemas de IA, devido ao alto grau de incerteza envolvido. A habilidade de identificar e gerenciar riscos potenciais é, portanto, quase um pré-requisito na área.
7. **Habilidades de comunicação:** Os gerentes de projeto devem ser capazes de se comunicar de maneira eficaz com membros da equipe com papéis e responsabilidades variadas, além de partes interessadas e clientes envolvidos nos aspectos gerenciais do projeto.
8. **Habilidades de resolução de problemas:** Projetos que envolvem IA são muitas vezes complexos e exigem dos gestores uma postura proativa e criativa para a resolução de problemas técnicos.
9. **Colaboração e trabalho em equipe:** Gerentes eficazes são capazes de liderar uma equipe diversificada, promovendo a colaboração e assegurando um trabalho em equipe eficiente.
10. **Aprendizado contínuo:** A rápida evolução das tecnologias de IA requer que o gerente de projetos esteja disposto a um aprendizado contínuo e acompanhe as inovações no campo.

Abordagens para gerenciamento de projetos utilizando soluções de Inteligência Artificial

69

1. **Abordagem Adaptativa (Método Ágil):** A abordagem adaptativa é apropriada quando há um alto grau de incerteza impactando significativamente o escopo geral do projeto. Mesmo que os requisitos de negócios sejam complexos e posteriormente detalhados para sustentar o projeto, a incerteza persiste, especialmente em ambientes de baixa previsibilidade ou em mercados altamente disruptivos. Esta abordagem privilegia a flexibilidade e a visão estratégica, onde o feedback iterativo do gestor de negócios permite a validação contínua do progresso do projeto. Entretanto, demanda alta maturidade, experiência e engajamento de todos os stakeholders, o que pode ser desafiador durante todo o ciclo de vida do projeto. Projetos de IA se beneficiam desta abordagem quando não há um benchmark claro para a alocação ótima dos sistemas, necessitando de etapas de teste e validação para determinar o melhor curso de ação.
2. **Abordagem Híbrida (Blended):** Esta abordagem combina as características das abordagens anteriores e é comumente empregada quando há um grau moderado

de incerteza ou previsibilidade sobre a natureza do projeto, o mercado aplicado e o grau de inovação envolvido. Neste caso, certos riscos, requisitos e recursos gerais são mais conhecidos, permitindo modularizar o ciclo de vida do projeto de acordo com as entregas a serem realizadas. Algumas entregas podem adotar uma abordagem mais preditiva, enquanto outras podem se beneficiar da abordagem adaptativa. Assim, o risco e a incerteza inerentes ao projeto são diluídos de acordo com seu escopo e progresso. A abordagem híbrida pode ser conduzida de maneira iterativa, adotando métodos ágeis e waterfall para etapas ou pacotes de trabalho específicos. É particularmente útil quando há necessidade de realizar integrações e ajustes antes da formalização das entregas parciais. É provável que esta abordagem se torne mais comum para uma ampla gama de projetos, dada a crescente oferta de serviços de IA no mercado.

As referências bibliográficas para este trabalho estão de acordo com as normas da ABNT (Associação Brasileira de Normas Técnicas).

Metodologias para gerenciamento de projetos com o uso de Inteligência Artificial

70

A implementação da IA em projetos pode ser distribuída pelos seus principais grupos de processos (iniciação, planejamento, execução, controle e encerramento), com metodologias notáveis, tais como:

1. **Data Distribution Service (DDS):** DDS são sistemas de software que facilitam a interoperabilidade entre aplicativos e dispositivos variados, permitindo uma comunicação e compartilhamento de dados confiáveis e escaláveis. É comumente utilizado em sistemas distribuídos de grande escala que necessitam compartilhar dados em tempo real. No gerenciamento de projetos, a estrutura DDS pode ser empregada para facilitar a colaboração em tempo real entre membros da equipe, além de possibilitar a comunicação entre diferentes aplicativos e sistemas utilizados no projeto.
2. **Cross-Industry Standard Process for Data Mining (CRISP-DM):** É uma metodologia amplamente adotada para mineração de dados, consistindo em seis etapas distintas: definição do negócio, categorização dos dados, preparação dos dados, modelagem dos dados, análise e avaliação dos dados e, por fim, implantação.
3. **Certified Project Manager in Artificial Intelligence (CPMAI):** É um modelo de gestão que fornece diretrizes e padrões para o gerenciamento de projetos envolvendo tecnologias de IA. A estrutura do CPMAI consiste em quatro etapas distintas: planejamento, design, desenvolvimento e implantação.

Além disso, há uma variedade de certificações e modelos de treinamento em IA disponíveis, como:

1. Certified Artificial Intelligence Practitioner (CAIP) pela AIIM
2. Artificial Intelligence Essentials (AI-900) da Microsoft
3. IA para Todos (Coursera)
4. AI Ethics, Governance and Regulation (edX)
5. Certified Artificial Intelligence Manager (CAIM) pela AIIM
6. Inteligência Artificial para Líderes pelo MIT Sloan Executive Education
7. Applied AI for Leaders, pela IBM
8. Data Science Essentials, pela IBM
9. Certificado de Profissional de Inteligência Artificial pela I2AI
10. Certified AI Practitioner pela AI Society
11. Certificado Profissional de Ciência de Dados, pela IBM
12. Microsoft Certified - Azure AI Fundamentals, pela Microsoft
13. Inteligência Artificial, Implicações para a Estratégia de Negócios, pela Harvard Business School Online

As referências bibliográficas para este trabalho estão de acordo com as normas da ABNT (Associação Brasileira de Normas Técnicas).

Atividade individual #3

Converse com o avatar IA de um dos melhores (e mais assertivos) consultores de negócios com tecnologia, e explore os temas discutidos nesta parte da apostila.

Busque interagir com o máximo possível de temas e conceitos apresentados, para obter uma importante pista, como parte do segredo que levará ao prêmio final.

Clique no código QR para acessar o avatar, ou digite:

<http://tinyurl.com/term801>



2.15 ÉTICA E GOVERNANÇA EM INTELIGÊNCIA ARTIFICIAL (IA)

Potenciais Riscos Associados à Utilização da Inteligência Artificial (IA)

71

Existem riscos diversos relacionados à implementação e/ou aplicação da IA, dentre os quais incluem-se:

1. **Deslocamento Geográfico de Empregos:** De maneira similar ao que ocorre na automação industrial e outros setores, determinados papéis e tarefas podem sofrer alterações entre mercados e países devido à aplicação localizada de soluções de IA.
2. **Preconceito e Discriminação:** Os sistemas de IA têm o potencial de perpetuar e até amplificar preconceitos e discriminação já existentes na sociedade.
3. **Segurança e Privacidade:** A IA pode aumentar significativamente os riscos à privacidade e segurança dos usuários e da sociedade em geral, especialmente quando os dados são mal utilizados, hackeados ou roubados.
4. **Questões Éticas:** Há questões éticas concernentes ao papel da IA na tomada de decisões, à responsabilidade por ações realizadas sob a influência ou autonomia da IA e ao tratamento lógico dos sistemas de IA em si.
5. **Domínio Estratégico Ostensivo:** A IA pode ser usada para obter vantagem militar e/ou econômica, levando a desequilíbrios de poder e possíveis conflitos.
6. **Consequências Não Intencionais:** A IA pode gerar consequências não intencionais, como efeitos colaterais imprevistos ou impactos negativos na sociedade.
7. **Perda de Controle:** O risco de perda de controle sobre sistemas de IA, embora muitas vezes retratado em obras de ficção científica, não é puramente imaginário.
8. **Concentração:** A centralização de informações pode restringir o acesso à mesma, levando à criação de assimetrias nos mercados altamente influenciados por sistemas de IA.
9. **Reputação:** Se um sistema de IA for treinado com dados tendenciosos ou incompletos, ele pode produzir resultados enviesados que, a longo prazo, prejudicam a reputação da organização que criou e/ou usa o sistema.
10. **Viés de Concepção, Desenvolvimento e Uso:** Viés tendencioso pode se inserir sutilmente em projetos de sistemas de IA, oriundos de fontes externas e inerentes ao desenvolvimento.
11. **Tomada de Decisão:** Todos os riscos listados, de alguma forma, afetam os processos decisórios apoiados por sistemas de IA.

Vieses na aplicação de IA em gerenciamento de projetos

Existem vários vieses comuns que podem ocorrer antes, durante e depois dos projetos de IA.

Antes do início da execução de um projeto:

1. **Viés nos dados:** Pode ocorrer nos dados usados para treinar modelos de IA. Se não forem representativos de todos os grupos da população, isso pode resultar em modelos enviesados.
2. **Viés de confirmação:** Os pesquisadores podem, inconscientemente, escolher dados que confirmem suas noções preconcebidas, resultando em um modelo enviesado.
3. **Viés de amostra:** Pode ocorrer na seleção da amostra, seu tamanho, a estrutura do conjunto e o método de coleta de dados.

Durante a Execução de Projetos de IA:

1. **Viés Algorítmico:** Ocorre quando o algoritmo é programado com pré-concepções específicas, resultando em um modelo que possa discriminar determinados grupos.
2. **Preconceito Humano:** Preconceitos podem surgir durante o processo de desenvolvimento do algoritmo. Uma estratégia para evitar tais preconceitos é constituir uma equipe de desenvolvimento diversificada e multicultural.
3. **Sobreajuste (Overfitting):** Este problema ocorre quando o modelo de IA se ajusta excessivamente aos dados de treinamento, perdendo sua capacidade de generalização. Nesse caso, o modelo aprendeu a identificar padrões específicos nos dados de treinamento que não se aplicam ao conjunto maior de dados.

Após a Execução de Projetos de IA:

1. **Viés de Automação:** Quando a IA é extremamente eficaz em executar uma tarefa específica, as pessoas podem acabar confiando demasiadamente na tecnologia e deixar de questionar suas decisões, causando um excesso de confiança.
2. **Viés de Resultado:** Avaliar a qualidade do modelo de IA somente com base nos seus resultados pode levar a falhas na detecção e mitigação de vieses subjacentes.
3. **Viés de 'Loop de Feedback':** Um modelo de IA pode aprender a partir do feedback dos resultados obtidos e realizar ajustes nos processos subsequentes. Contudo, se o feedback for tendencioso, esse viés pode ser perpetuado nas ações futuras do modelo.

Riscos e ética relacionados à Inteligência Artificial

Referências Culturais

72'

A Importância da Ética na Inovação

Conforme já mencionado neste curso, as referências à Inteligência Artificial (IA) e áreas relacionadas podem ser encontradas desde a mitologia, na forma de autômatos e seres fantásticos. Uma de suas principais contribuições está na reflexão sobre os aspectos morais e éticos não só da tecnologia em si, mas também de seus impactos esperados e inesperados na sociedade e no ser humano. Neste contexto, a IA funciona como um espelho, nos levando a ponderar sobre a natureza humana ao considerar as alternativas possíveis.

Gestão Ética de Riscos

Frente aos potenciais benefícios e riscos da IA, os gestores (de projetos, operacionais, estratégicos, etc.) devem considerar cuidadosamente as implicações reais e potenciais do uso da IA e se esforçar para garantir que sua utilização ocorra de maneira responsável e ética. Tais questões podem exigir o desenvolvimento de políticas, estruturas e regulamentos administrativos e éticos destinados a orientar o desenvolvimento e o uso da IA como um todo.

Embora muitas dessas questões possam parecer futurísticas, elas têm suas raízes em problemas atuais. Isso torna imprescindível o desenvolvimento e a implementação de práticas responsáveis para o uso da IA em todas as suas formas, a fim de gerenciar e minimizar esses riscos e aumentar as chances de que a IA seja aplicada em benefício da sociedade.

Políticas Públicas

Governos, autarquias e entidades civis devem se envolver profundamente nas questões éticas da IA e suas aplicações, embora nem sempre de maneira eficaz ou transparente. Uma referência importante nesta área é o "Guia de Uso Ético da IA" da Comissão Europeia, publicado em 2017. Gerenciado *pela European AI Alliance*, este guia oferece diretrizes para empresas e países sobre como gerenciar a IA de forma ética.

Comissão Europeia - Gerenciamento Ético dos Sistemas de IA

73

O Guia de Uso Ético e Confiável de Inteligência Artificial, estabelecido pela Comissão Europeia, compreende um conjunto de diretrizes e recomendações destinadas a promover o desenvolvimento e implantação de sistemas de Inteligência Artificial (IA) confiáveis. Embora inicialmente projetado para a Europa, estas diretrizes podem ser adotadas globalmente. Elaborado pelo Grupo de Especialistas de Alto Nível da Comissão Europeia

em IA, este guia propõe formas de orientar o design ético na implantação de sistemas de IA, considerando-se seu impacto cada vez mais significativo nos mercados, na sociedade em geral e nos indivíduos. As diretrizes propostas abordam várias áreas-chave, incluindo:

Princípios Éticos

Estabelece uma série de princípios éticos para o desenvolvimento de IA, com foco em aspectos como a autonomia humana, a prevenção à discriminação e promoção de justiça, a transparência e a responsabilidade compartilhada.

Direitos Humanos

Enfatiza a necessidade de garantir que os sistemas de IA respeitem os direitos humanos, como privacidade e liberdade de expressão, na medida do possível.

Transparência e Prestação de Contas

Visa assegurar que os sistemas de IA sejam transparentes e explicáveis, evitando a dependência de sistemas opacos, conhecidos como "caixas-pretas". Isso permite que os usuários compreendam como os sistemas funcionam e como as decisões são tomadas no ambiente de IA.

Responsabilidade

Define princípios fundamentais para garantir que as empresas e indivíduos responsáveis pelo desenvolvimento, gestão e uso dos sistemas de IA possam ser responsabilizados por suas ações quando necessário. Além disso, enfatiza a necessidade de assegurar e demonstrar que seus sistemas operem de forma ética e responsável.

A Comissão Europeia desempenha um papel crucial na promoção do desenvolvimento e implementação ética da IA na Europa. Embora não detenha poder ou autoridade direta sobre organizações, governos e indivíduos, seu trabalho serve como um marco importante e útil.

Governança em sistemas de Inteligência Artificial

74

A governança, como apontado por Divino e Magalhães (2020), é a prática de estabelecer e implementar políticas, procedimentos e padrões que asseguram que o desenvolvimento e aplicação de um sistema determinado não comprometam a autonomia humana e nem gerem efeitos prejudiciais. É um sistema de normas e leis formulado e aplicado por instituições sociais ou governamentais para regular o comportamento dos agentes.

Princípios de governança de sistemas digitais:

- **Respeito à Autonomia Humana:** Este princípio destaca a necessidade de um processo democrático efetivo no desenvolvimento e uso de sistemas digitais, permitindo a autodeterminação humana.
- **Prevenção de Danos:** Os sistemas digitais não devem causar danos ou afetar negativamente indivíduos, entidades de qualquer natureza e outros stakeholders, sejam eles diretos ou indiretos.
- **Equidade:** Busca assegurar um equilíbrio entre interesses e objetivos na concepção, utilização e gestão dos sistemas.
- **Transparência:** Ressalta que decisões devem ser baseadas em conceitos transparentes e demonstráveis, permitindo a possibilidade de contestação.

A governança em projetos de IA:

Refere-se às políticas, procedimentos e estruturas que orientam o desenvolvimento e a implantação de sistemas de IA. O papel da governança em projetos de IA é garantir que tais sistemas sejam desenvolvidos e aplicados de maneira responsável, ética e transparente, protegendo a privacidade e os direitos dos indivíduos, em conformidade com as leis e normas vigentes. Alguns aspectos importantes incluem:

- **Ética:** Assegura que o desenvolvimento e aplicação de sistemas de IA sejam regidos por princípios éticos, considerando os possíveis impactos sociais, ambientais e individuais.
- **Responsabilidade:** Define o grau de responsabilidade atribuído às partes interessadas, incluindo desenvolvedores, usuários, gestores, a organização desenvolvedora e seus parceiros/fornecedores.
- **Transparência:** Garante que os sistemas de IA sejam compreensíveis, interpretáveis e explicáveis pelos desenvolvedores e usuários.
- **Privacidade:** Enfatiza a proteção de dados e informações pessoais dos indivíduos através de medidas de segurança apropriadas.
- **Regulamentação:** Exige a adesão à regulamentação vigente no local onde as soluções de IA serão desenvolvidas e utilizadas.
- **Monitoramento para Melhoria Contínua:** Realiza uma avaliação periódica do sistema para garantir um desempenho adequado e sustentável.

A Transparência em Sistemas de IA e o Conceito de 'Black Box'

A transparência em IA refere-se à capacidade de visualizar e compreender o funcionamento interno de um sistema de IA. Um dos principais desafios para a transparência é o conceito de 'caixa preta', que se refere a um sistema de IA cujo funcionamento interno não é facilmente explicável.

Para aumentar a transparência do sistema, algumas abordagens podem ser adotadas:

- **IA Explicativa:** Conjunto de técnicas projetadas para tornar os sistemas de IA mais transparentes e interpretáveis.
- **Transparência de Dados:** Torna os dados usados para treinar o sistema de IA mais visíveis e acessíveis.
- **Transparência Algorítmica:** Torna os algoritmos usados no sistema de IA mais visíveis e acessíveis.

Atividade individual #4

Converse com o avatar IA do sistema mais ético e heurístico do planeta, e explore os temas discutidos nesta parte da apostila. Busque interagir com o máximo possível de temas e conceitos apresentados, para obter uma importante pista, como parte do segredo que levará ao prêmio final.

Clique no código QR para acessar o avatar, ou digite:

<http://tinyurl.com/halc9000>



APÊNDICE – BIBLIOGRAFIA COMPLEMENTAR E REFERÊNCIAS

HOSANAGAR, Kartik. *A Human's Guide to Machine Intelligence: How Algorithms are Shaping Our Lives and How We Can Stay in Control*. London: Pinguin Books, 2019.

KAPLAN, Jerry. *Artificial Intelligence. What Everyone Needs to Know*. NY: Oxford University Press, 2016.

KEE, Kai-Fu; QUIFAN, Chen. *AI: Ten Versions for Our Futures*. London: Pinguin Books, 2021.

RUSSELL, Stuart. *Inteligência Artificial a Nosso Favor. Como Manter o Controle Sobre a Tecnologia*. São Paulo: Companhia da Letras, 2021.

TEGMARK, Max. *Life 3.0. Being Human in The Age of Artificial Intelligence*. London: Pinguin Books, 2017.

1'

N. ZALTA, Edward . The Stanford Encyclopedia of Philosophy. Aristotle, 2008. Disponível em: <https://plato.stanford.edu/entries/aristotle/> . Acesso em: 15 jul. 2023.

Internet Encyclopedia of Philosophy. **Aristotle**. Disponível em: <https://www.iep.utm.edu/aristotle/> . Acesso em: 16 jul. 2023.

SMITH, Robin *et al*. The Stanford Encyclopedia of Philosophy. **Aristotle's Logic**, 2002. Disponível em: <https://plato.stanford.edu/entries/aristotle-logic/> . Acesso em: 15 jul. 2023.

BRINGSJORD, Selmer *et al*. The Stanford Encyclopedia of Philosophy, **Aristotle's Logic**. 2002. Disponível em: <https://plato.stanford.edu/entries/artificial-intelligence/> . Acesso em: 15 jul. 2023.

COPELAND, BJ. "inteligência artificial". Encyclopedia Britannica , 14 de julho de 2023, <https://www.britannica.com/technology/artificial-intelligence> . Acessado em 15 de julho de 2023.

2'

CORMEN n, Thomas H., et al. *Introduction to Algorithms, Fourth Edition*. Reino Unido, MIT Press, 2022.

IFRAH, Georges, and Bellos, David. *The Universal History of Numbers: From Prehistory to the Invention of the Computer*. Estados Unidos, Wiley, 2000.

RUSSELL, Stuart Jonathan, and Norvig, Peter. *Artificial Intelligence: A Modern Approach*. Reino Unido, Pearson, 2021.

3'

WALTHAM, Chris. "The Antikythera Mechanism: A Mechanical Cosmos." *Scientific American*, vol. 300, no. 1, 2009, pp. 84-91. DOI: 10.1038/scientificamerican0109-84.

4'

DYSON, George. *Turing's Cathedral: The Origins of the Digital Universe*. Reino Unido, Penguin Books Limited, 2012.

5'

GROOVER, M.P. *Automation, Production Systems, and Computer-Integrated Manufacturing*. Prentice Hall.

RUSSELL, S. & Norvig, P. (2016). *Artificial Intelligence: A Modern Approach*. Prentice Hall.

BRYNJOLFSSON, E., & McAfee, A. (2014). *The second machine age: work, progress, and prosperity in a time of brilliant technologies*. WW Norton & Company.

6'

STANDAGE, Tom. *The Turk: The Life and Times of the Famous Eighteenth-century Chess-playing Machine*. Estados Unidos, Walker & Company, 2002.

MCCORDUCK, Pamela, and Cfe, Cli. *Machines Who Think: A Personal Inquiry Into the History and Prospects of Artificial Intelligence*. Reino Unido, CRC Press, 2004.

COHEN, D. *The Mechanical Turk*. Science History Publications. 1981

7'

LOUCA, F. *Invention and Evolution*. 2001

KUMAR, A. *The Black-Box Society: The Secret Algorithms That Control Money and Information*. Harvard University Press, 2005

COHEN, E. *The Commercial Revolution of the Middle Ages, 950-1350*. Cambridge University Press., 2010

MOKYR, Joel. *The Lever of Riches: Technological Creativity and Economic Progress*. Reino Unido, Oxford University Press, 1992.

8'

ESSINGER, James. *Jacquard's Web: How a Hand-loom Led to the Birth of the Information Age*. Reino Unido, OUP Oxford, 2007.

CAMPBELL-KELLY, Martin, et al. *Computer: A History of the Information Machine*. Reino Unido, Taylor & Francis, 2018.

RANDELL, B. *The Origins of Digital Computers: Selected Papers*. Alemanha, Springer-Verlag, 1982.

IFRAH, Georges. The Universal History of Computing: From the Abacus to the Quantum Computer. Alemanha, Wiley, 2001.

9'

MORE, Charles. Understanding the industrial revolution. Reino Unido, Routledge, 2000.

SMIL, Vaclav. Energy and Civilization: A History. Reino Unido, MIT Press, 2018.

MOKYR, Joel. A Culture of Growth: The Origins of the Modern Economy. Reino Unido, Princeton University Press, 2018.

SCHWAB, Klaus. The Fourth Industrial Revolution. Suíça, Crown, 2017

10'

SWADE, D. The Cogwheel Brain: Charles Babbage and the Quest to Build the First Computer. Little, Brown, 2001.

TOOLE, B. Ada, the Enchantress of Numbers: A Selection from the Letters of Lord Byron's Daughter and Her Description of the First Computer. Strawberry Press, 1992.

COHEN, I. B. The Triumph of Numbers: How Counting Shaped Modern Life. W. W. Norton & Company., 2005.

DYSON, G.. Turing's Cathedral: The Origins of the Digital Universe. Pantheon, 2012

11'

CERUZZI, P. E. A History of Modern Computing. MIT Press, 2003

NORBERG, A. L., & O'Neill, J. E. Transforming Computer Technology: Information Processing for the Pentagon, 1962-1986. Johns Hopkins University Press, 1996.

WIENER, N. Cybernetics: Or Control and Communication in the Animal and the Machine. MIT Press, 1965.

PICKERING, A. The Cybernetic Brain: Sketches of Another Future. University of Chicago Press, 2010.

12'

BOLTON, W. Programmable Logic Controllers. Newnes. 2015.

HUGHES, T. Human-built World: How to Think about Technology and Culture. University of Chicago Press. 2004.

RAMESH, S. AI & Machine Learning in Industrial Automation. Springer. 2020.

DAVID, E., & Thomas, R. Programmable Controllers: Theory and Implementation. Industrial Text Company. 2008.

13'

BOLTON, W. Programmable Logic Controllers. Newnes. 2015.

HUGHES, T. Human-built World: How to Think about Technology and Culture. University of Chicago Press. 2004.

RAMESH, S. AI & Machine Learning in Industrial Automation. Springer. 2020.

DAVID, E., & Thomas, R. Programmable Controllers: Theory and Implementation. Industrial Text Company. 2008.

MCCORDUCK, P. Machines Who Think: A Personal Inquiry into the History and Prospects of Artificial Intelligence. A K Peters/CRC Press. 2004.

RUSSELL, S. & Norvig, P. Artificial Intelligence: A Modern Approach. Prentice Hall. 2016.
BOSTROM, N. Superintelligence: Paths, Dangers, Strategies. Oxford University Press. 2014.

KURZWEIL, R. The Singularity is Near: When Humans Transcend Biology. Penguin Books. 2006.

14'

SALE, T. The Colossus Computer 1943-1996: How It Helped to Break the German Lorenz Cipher in WWII. M & M Baldwin. 2013.

TURING, A. Computing Machinery and Intelligence. Mind. 1950.

MCCORDUCK, P. Machines Who Think: A Personal Inquiry into the History and Prospects of Artificial Intelligence. A K Peters/CRC Press. 2004.

NEWELL, A., Shaw, J.C., & Simon, H.A. Empirical Explorations with the Logic Theory Machine: A Case Study in Heuristics. Proceedings of the Western Joint Computer Conference. 1957.

ROSENBLATT, F. The Perceptron: A Probabilistic Model for Information Storage and Organization in The Brain. Psychological Review. 1958.

IBM100 - The IBM Shoebox. IBM Archives.

Language Communication between Man and Machine. Communications of the ACM.

WEIZENBAUM, J. ELIZA—A Computer Program for the Study of Natural. 1966.

HAFNER, K., & Lyon, M. Where Wizards Stay Up Late: The Origins of the Internet. Simon & Schuster. 1996.

RUSSELL, S., & Norvig, P. Artificial Intelligence: A Modern Approach. Pearson. 2016.

HSU, F. H. Behind Deep Blue: Building the Computer that Defeated the World Chess Champion. Princeton University Press. 2002.

15'

THRUN, S. Stanley: The Robot that Won the DARPA Grand Challenge. Springer. 2006.

FERRUCCI, D. Introduction to "This is Watson". IBM Journal of Research and Development. 2012.

KRIZHEVSKY, A., Sutskever, I., & Hinton, G. E. ImageNet Classification with Deep Convolutional Neural Networks. Advances in Neural Information Processing Systems. 2012.

MCTEAR, M., Callejas, Z., & Griol, D. The Conversational Interface: Talking to Smart Devices. Springer. 2016.

SUTSKEVER, I., & Amodei, D. OpenAI: An Approach to AGI Safety. OpenAI Blog. 2018.

SILVER, D., Huang, A., Maddison, C.J., et al. Mastering the game of Go with deep neural networks and tree search. Nature. 2016.

European Commission. Ethics Guidelines for Trustworthy AI. European Commission's High-Level Expert Group on AI. 2017.

16'

COPELAND, B. J. Colossus: The Secrets of Bletchley Park's Codebreaking Computers. Oxford University Press. 2006.

KAHN, D. Seizing the Enigma: The Race to Break the German U-Boats Codes, 1939-1943. Houghton Mifflin Harcourt. 1991.

SINGH, S. The Code Book: The Science of Secrecy from Ancient Egypt to Quantum Cryptography. Anchor Books. 1999.

HODGES, A. Alan Turing: The Enigma. Princeton University Press. 2014.

17'

SINGH, S. The Code Book: The Science of Secrecy from Ancient Egypt to Quantum Cryptography. Anchor Books. 1999.

KAHN, D. Seizing the Enigma: The Race to Break the German U-Boats Codes, 1939-1943. Houghton Mifflin Harcourt. 1991.

18'

COPELAND, B. J. Colossus: The Secrets of Bletchley Park's Codebreaking Computers. Oxford University Press. 2006.

HODGES, A. Alan Turing: The Enigma. Vintage. 1983.

TURING, A. M. "Proposed Electronic Calculator". The Collected Works of A. M. Turing. Oxford University Press. 1945.

RANDELL, B. Colossus: Godfather of the Computer. Springer. 2012.

19'

TURING, A. M. "Computing Machinery and Intelligence". Mind, Vol. LIX, No. 236. 1950.

HUTTO, D. D., & Myin, E. Radicalizing Enactivism: Basic Minds without Content. MIT Press. 2013.

MOOR, J. H. The Dartmouth College Artificial Intelligence Conference: The Next Fifty Years. AI Magazine, 27(4), 87-91. 2006.

20'

NEWELL, A., & Simon, H. A. The Logic Theory Machine—A Complex Information Processing System. IRE Transactions on Information Theory, IT-2(3), 61-79. DOI:10.1109/TIT.1956.1056810. 1955.

NEWELL, A., & Simon, H. A. The logic theory machine--a complex information processing system. IRE Transactions on Information Theory, 2(3), 61-79. 1956.

RUSSELL, S., Norvig, P. Artificial Intelligence: A Modern Approach. Malaysia; Pearson Education Limited, 2016.

RUSSELL, S., & Norvig, P. Artificial Intelligence - A Modern Approach. (3rd ed). Pearson. 2010.

COPELAND, B. J. The Essential Turing: Seminal Writings in Computing, Logic, Philosophy, Artificial Intelligence, and Artificial Life plus The Secrets of Enigma. Oxford University Press. 2004.

21'

ROSENBLATT, F. The Perceptron: A Probabilistic Model for Information Storage and Organization in The Brain. Psychological Review, 65(6), 386-408. 1958.

MINSKY, M., & Papert, S. Perceptrons: An Introduction to Computational Geometry. MIT Press. 1969.

GOODFELLOW, I., Bengio, Y., & Courville, A. Deep Learning. MIT Press. 2016.

BISHOP, C. M. Pattern Recognition and Machine Learning. Springer. 2006.

22'

WEIZENBAUM, J. ELIZA - A Computer Program For the Study of Natural Language Communication Between Man And Machine. Communications of the ACM, 9(1), 36-45. 1966.

TURING, A. Computing Machinery and Intelligence. Mind, 59(236), 433-460. 1950.

RUSSELL, S., & Norvig, P. Artificial Intelligence: A Modern Approach (3rd ed). Pearson. 2016.

BIRD, S., Klein, E., & Loper, E. Natural Language Processing with Python: Analyzing Text with the Natural Language Toolkit. O'Reilly Media. 2009.

23'

ABBATE, J. Inventing the Internet. MIT Press. 1999.

WALDROP, M. M. The Dream Machine: J.C.R. Licklider and the Revolution That Made Computing Personal. Viking Penguin. 2001.

LEINER, B. M., Cerf, V. G., Clark, D. D., Kahn, R. E., Kleinrock, L., Lynch, D. C., . . . Wolff, S. A Brief History of the Internet. ACM SIGCOMM Computer Communication Review, 39(5), 22-31. 2009.

RUSSELL, S., & Norvig, P. Artificial Intelligence: A Modern Approach (3rd ed). Pearson. 2016.

24'

RUSSELL, S., & Norvig, P. Artificial Intelligence: A Modern Approach (3rd ed). Pearson. 2016.

MCCORDUCK, P. Machines Who Think (2nd ed). Natick, MA: A. K. Peters, Ltd. 2004.

CREVIER, D. AI: The Tumultuous History of the Search for Artificial Intelligence. New York, NY: Basic Books. 1993.

NILS J. Nilsson The Quest for Artificial Intelligence. Cambridge University Press. 2009.

25'

HSU, F. H. Behind Deep Blue: Building the Computer that Defeated the World Chess Champion. Princeton University Press. 2002.

CAMPBELL, M., Hoane, A. J., Jr., & Hsu, F. H. Deep Blue. Artificial Intelligence, 134(1-2), 57-83. 2002.

RUSSELL, S., & Norvig, P. Artificial Intelligence: A Modern Approach (3rd ed). Pearson. 2016.

SILVER, D., et al. Mastering the game of Go with deep neural networks and tree search. Nature, 529, 484-489. 2016.

26'

THRUN, S., Montemerlo, M., Dahlkamp, H., Stavens, D., Aron, A., Diebel, J., ... & Hoffmann, G. Stanley, The robot that won the DARPA Grand Challenge. Journal of field Robotics, 23(9), 661-692. 2006.

BUEHLER, M., Iagnemma, K., & Singh, S. The DARPA Urban Challenge: autonomous vehicles in city traffic (Vol. 56). Springer. 2009.

URMSON, C., & Whittaker, W. Self-driving cars and the urban challenge. *IEEE Intelligent Systems*, 23(2), 66-68. 2008.

27'

FERRUCCI, D., Levas, A., Bagchi, S., Gondek, D., & Mueller, E. T. Watson: Beyond Jeopardy!. *Artificial Intelligence*, 199-200, 93-105. 2013.

HIGH, R. The era of cognitive systems: An inside look at IBM Watson and how it works. IBM Corporation, Redbooks. 2012.

AHMAD, A., Lavin, A., Purdy, S., & Agha, Z. A Decade of IBM Watson. *Journal of Medical Imaging*, 3(3), 1-10. 2016.

ROMETTY, V. A New Era of Computing: Cognitive Systems. IBM THINK Forum. 2013.

28'

KRIZHEVSKY, A., Sutskever, I., & Hinton, G. E.. ImageNet Classification with Deep Convolutional Neural Networks. *Advances in Neural Information Processing Systems* 25, 1097-1105. 2012.

DENG, J., Dong, W., Socher, R., Li, L., Li, K., & Fei-Fei, L. ImageNet: A large-scale hierarchical image database. In *2009 IEEE Conference on Computer Vision and Pattern Recognition*, 248-255. 2009.

LECUN, Y., Bengio, Y., & Hinton, G. Deep learning. *Nature*, 521(7553), 436-444. 2015.
GOODFELLOW, I., Bengio, Y., & Courville, A. *Deep Learning*. MIT Press. 2016.

29'

MCTEAR, M., Callejas, Z., & Griol, D. *The Conversational Interface: Talking to Smart Devices*. Springer. 2016.

AMERSHI, S., Weld, D., Vorvoreanu, M., Fournery, A., Nushi, B., Collisson, P., ... & Horvitz, E. Guidelines for Human-AI Interaction. In *Proceedings of the 2019 CHI Conference on Human Factors in Computing Systems* (pp. 1-13). 2019.

LUGER, E., & Sellen, A. "Like Having a Really Bad PA": The Gulf between User Expectation and Experience of Conversational Agents. In *Proceedings of the 2016 CHI Conference on Human Factors in Computing Systems* (pp. 5286-5297). 2016.

SHEVAT, A. *Designing Bots: Creating Conversational Experiences*. O'Reilly Media. 2017.

30'

OpenAI. (2020). Charter. <https://openai.com/charter/>

OpenAI. (2021). About OpenAI. <https://openai.com/about/>

RADFORD, A., Wu, J., Child, R., Luan, D., Amodei, D., & Sutskever, I. 2019. Language Models are Unsupervised Multitask Learners. OpenAI Blog. <https://openai.com/blog/better-language-models/>

BROWN, T. B., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., ... & Amodei, D. 2020. Language models are few-shot learners. arXiv preprint arXiv:2005.14165.

31'

SILVER, D., Huang, A., Maddison, C. J., Guez, A., Sifre, L., Van Den Driessche, G., ... & Dieleman, S. 2016. Mastering the game of Go with deep neural networks and tree search. Nature, 529(7587), 484-489.

SILVER, D., Schrittwieser, J., Simonyan, K., Antonoglou, I., Huang, A., Guez, A., ... & Chen, Y. 2017. Mastering the game of Go without human knowledge. Nature, 550(7676), 354-359.

RUSSELL, S., & Norvig, P. Artificial Intelligence: A Modern Approach (3rd ed). Pearson. 2016.

32'

KRAUSE, J., Stark, M., Deng, J., & Fei-Fei, L. (2013, June). 3d object representations for fine-grained categorization. In 2013 IEEE International Conference on Computer Vision Workshops (pp. 554-561). IEEE.

THRUN, S., Montemerlo, M., Dahlkamp, H., Stavens, D., Aron, A., Diebel, J., ... & Hoffmann, G. 2006. Stanley: The robot that won the DARPA Grand Challenge. Journal of field Robotics, 23(9), 661-692.

33'

IBM. (2023). "IBM Watson". <https://www.ibm.com/watson>

FERRUCCI, D., Levas, A., Bagchi, S., Gondek, D., & Mueller, E. T. (2013). Watson: beyond jeopardy!. Artificial Intelligence, 199-200, 93-105.

HIGH, R. The era of cognitive systems: An inside look at IBM Watson and how it works. IBM Corporation, Redbooks, 1-16. 2012.

34'

Amazon. (2023). "Amazon Alexa". <https://developer.amazon.com/en-US/alexa>

KRIZHEVSKY, A., Sutskever, I., & Hinton, G. E. Imagenet classification with deep convolutional neural networks. In Advances in neural information processing systems (pp. 1097-1105). 2012.

RUSSAKOVSKY, O., Deng, J., Su, H., Krause, J., Satheesh, S., Ma, S., ... & Berg, A. C. Imagenet large scale visual recognition challenge. International journal of computer vision, 115(3), 211-252. 2015.

35'

OpenAI. (2023). "OpenAI". <https://openai.com/>

RADFORD, A., Wu, J., Child, R., Luan, D., Amodei, D., & Sutskever, I.. Language models are unsupervised multitask learners. OpenAI Blog, 1(8). 2019.

BROWN, T. B., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., ... & Amodei, D. Language models are few-shot learners. arXiv preprint arXiv:2005.14165. 2020.

36'

SILVER, D., Huang, A., Maddison, C. J., Guez, A., Sifre, L., Van Den Driessche, G., ... & Dieleman, S. Mastering the game of Go with deep neural networks and tree search. Nature, 529(7587), 484-489. 2016.

DeepMind. (2023). "AlphaGo". <https://deepmind.com/research/case-studies/alphago>

SILVER, D., Schrittwieser, J., Simonyan, K., Antonoglou, I., Huang, A., Guez, A., ... & Chen, Y. Mastering the game of Go without human knowledge. Nature, 550(7676), 354-359. 2017.

37'

PETROSKI, H. "Talos, Prometheus, and the Concept of Automaton." Philosophy and Rhetoric, 51(1), 60-73. 2018.

Talos (greekmythology.com)

38'

RUSSELL, S., & Norvig, P. "Artificial Intelligence: A Modern Approach." Pearson. 2016. Myth of Pygmalion and Galatea - Greek Myths | Greeka

39'

EPSTEIN, D. "The Book of Gad the Seer: The Golem as a Metaphor for Artificial Intelligence." AI & Society, 34(2), 371-379. 2019.

"Golem," Jewish Virtual Library: <https://www.jewishvirtuallibrary.org/golem>

40'

"Hephaestus," Greek Mythology Link: <https://www.maicar.com/GML/Hephaestus.html>

41'

BOSTROM, N. "Superintelligence: Paths, Dangers, Strategies." Oxford University Press. 2014. "Frankenstein; or, The Modern Prometheus," Mary Shelley, 1818: <https://www.gutenberg.org/files/84/84-h/84-h.htm>

42'

SIMON, H. A.; NEWELL, A. Human Problem Solving: The State of the Theory in 1970. American Psychologist, v.26, n.2, p.145-159, 1971.

MCCARTHY, J.; HAYES, P. J. Some Philosophical Problems from the Standpoint of Artificial Intelligence. *Machine Intelligence*, v.4, p.463-502, 1969.

TURING, A. M. Computing Machinery and Intelligence. *Mind*, v.59, p.433-460, 1950.

MINSKY, M. A Framework for Representing Knowledge. In: Winston, P. H. (Ed.). *The Psychology of Computer Vision*. New York: McGraw-Hill, p.211-277, 1975.

RUSSELL, S. J.; NORVIG, P. *Artificial Intelligence: A Modern Approach*. 4th ed. Malaysia: Pearson Education Limited, 2020.

43'

BISHOP, C. M. *Pattern Recognition and Machine Learning*. New York: Springer, 2006.

RUSSELL, S. J.; NORVIG, P. *Artificial Intelligence: A Modern Approach*. 4th ed. Malaysia: Pearson Education Limited, 2020.

44'

BONABEAU, E.; DORIGO, M.; THERAULAZ, G. *Swarm Intelligence: From Natural to Artificial Systems*. New York: Oxford University Press, 1999.

GOLDBERG, D. E. *Genetic Algorithms in Search, Optimization, and Machine Learning*. Boston: Addison-Wesley, 1989.

RUSSELL, S. J.; NORVIG, P. *Artificial Intelligence: A Modern Approach*. 4th ed. Malaysia: Pearson Education Limited, 2020.

MCCULLOCH, W. S.; PITTS, W. A Logical Calculus of the Ideas Immanent in Nervous Activity. *Bulletin of Mathematical Biophysics*, v.5, n.4, p.115-133, 1943.

ROSENBLATT, F. The Perceptron: A Probabilistic Model for Information Storage and Organization in the Brain. *Psychological Review*, v.65, n.6, p.386-408, 1958.

RUSSELL, S. J.; NORVIG, P. *Artificial Intelligence: A Modern Approach*. 4th ed. Malaysia: Pearson Education Limited, 2020.

45'

CHO, K. *Natural Language Processing with PyTorch: Build Intelligent Language Applications Using Deep Learning*. Boston: O'Reilly Media, 2019.

SUTZKEVER, I.; VINYALS, O.; LE, Q. V. Sequence to sequence learning with neural networks. In: *Advances in neural information processing systems*, 2014. p. 3104-3112.

RUSSELL, S. J.; NORVIG, P. *Artificial Intelligence: A Modern Approach*. 4th ed. Malaysia: Pearson Education Limited, 2020.

SUTTON, R. S.; BARTO, A. G. *Reinforcement learning: An introduction*. 2nd ed. Cambridge: MIT press, 2018.

46'

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. Deep Learning. Cambridge: MIT Press, 2016.

RUSSELL, S. J.; NORVIG, P. Artificial Intelligence: A Modern Approach. 4th ed. Malaysia: Pearson Education Limited, 2020.

SUTTON, R. S.; BARTO, A. G. Reinforcement learning: An introduction. 2nd ed. Cambridge: MIT press, 2018.

47'

RUSSELL, S. J.; NORVIG, P. Artificial Intelligence: A Modern Approach. 4th ed. Malaysia: Pearson Education Limited, 2020.

MCCARTHY, J.; MINSKY, M. L.; ROCHESTER, N.; SHANNON, C. E. A Proposal for the Dartmouth Summer Research Project on Artificial Intelligence. AI Magazine, v.27, n.4, 2006.

WOOLDRIDGE, M.; JENNINGS, N. R. Intelligent agents: theory and practice. The knowledge engineering review, v.10, n.2, p.115-152, 1995.

DENG, L. The mnist database of handwritten digit images for machine learning research [best of the web]. IEEE Signal Processing Magazine, v.29, n.6, p.141-142, 2012.

48'

RUSSELL, S. J.; NORVIG, P. Artificial Intelligence: A Modern Approach. 4th ed. Malaysia: Pearson Education Limited, 2020.

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. Deep Learning. Cambridge: MIT Press, 2016.

LUNGREN, M. P.; HALABI, S. S.; BAIRD, R.; HOFFMAN, J.; FLORES, E.; NAPOLEONI, M.; RUBESOVA, E.; BIRUKOVA, A.; ALTER, A.; GOLDEN, D.; PATINO, M.; HOM, J.; DYMEK, A.; BRENNAN, M.; FLEISHON, H.; PAULSON, E.; JACKSON, V.; LEWIS, P.; HOLMES, D.; LOYA, J.; SAKET, R.; BESSER, A.; ZAHARCHUK, G. Deep Learning in Neuroradiology. American Journal of Neuroradiology, v. 39, n. 10, p. 1776-1784, 2018.

DENG, L.; HINTON, G.; KINGSBURY, B. New types of deep neural network learning for speech recognition and related applications: An overview. In: 2013 IEEE International Conference on Acoustics, Speech and Signal Processing, 2013. p. 8599-8603.

49'

SAMUEL, A. L. Some studies in machine learning using the game of Checkers. IBM Journal of Research and Development, v.3, n.3, p.210-229, 1959.

MITCHELL, T. M. Machine Learning. New York: McGraw-Hill, 1997.

BISHOP, C. M. Pattern Recognition and Machine Learning. New York: Springer, 2006.

HASTIE, T.; TIBSHIRANI, R.; FRIEDMAN, J. The Elements of Statistical Learning: Data Mining, Inference, and Prediction. 2nd ed. New York: Springer, 2009.

DUDA, R. O.; HART, P. E.; STORK, D. G. Pattern Classification. 2nd ed. New York: Wiley-Interscience, 2000.

50'

Russell, S., Norvig, P. (2016). Artificial Intelligence: A Modern Approach. 3rd ed. Upper Saddle River, NJ: Prentice Hall.

Goodfellow, I., Bengio, Y., Courville, A. (2016). Deep Learning. MIT Press.

Chollet, F. (2018). Deep Learning with Python. Manning Publications.

Hinton, G., et al. (2012). Deep Neural Networks for Acoustic Modeling in Speech Recognition. IEEE Signal Processing Magazine, 29(6), 82-97.

51'

Russell, S., Norvig, P. (2016). Artificial Intelligence: A Modern Approach. 3rd ed. Upper Saddle River, NJ: Prentice Hall.

Goodfellow, I., Bengio, Y., Courville, A. (2016). Deep Learning. MIT Press.

Jain, A. K., Murty, M. N., & Flynn, P. J. (1999). Data clustering: a review. ACM computing surveys (CSUR), 31(3), 264-323.

Van Der Maaten, L., Hinton, G. (2008). Visualizing data using t-SNE. Journal of Machine Learning Research, 9, 2579-2605.

Chandola, V., Banerjee, A., & Kumar, V. (2009). Anomaly detection: A survey. ACM computing surveys (CSUR), 41(3), 1-58.

Ricci, F., Rokach, L., & Shapira, B. (2011). Introduction to recommender systems handbook. In Recommender systems handbook (pp. 1-35). Springer, Boston, MA.

52'

Sutton, R. S., & Barto, A. G. (2018). Reinforcement learning: An introduction. 2nd ed. Cambridge, MA: MIT Press.

Kober, J., Bagnell, J. A., & Peters, J. (2013). Reinforcement learning in robotics: A survey. The International Journal of Robotics Research, 32(11), 1238-1274.

Silver, D., Huang, A., Maddison, C. J., Guez, A., Sifre, L., Van Den Driessche, G., ... & Dieleman, S. (2016). Mastering the game of Go with deep neural networks and tree search. Nature, 529(7587), 484-489.

Shalev-Shwartz, S., Shammah, S., & Shashua, A. (2016). Safe, multi-agent, reinforcement learning for autonomous driving. arXiv preprint arXiv:1610.03295.

Zhao, X., Zhang, W., Wang, J. (2013). Interactive collaborative filtering. In Proceedings of the 22nd ACM international conference on Information & Knowledge Management (pp. 1411-1420).

Mao, H., Alizadeh, M., Menache, I., Kandula, S. (2016). Resource Management with Deep Reinforcement Learning. In Proceedings of the 15th ACM Workshop on Hot Topics in Networks (pp. 50-56).

53'

Goodfellow, I., Bengio, Y., & Courville, A. (2016). Deep learning. MIT press.

Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2012). ImageNet classification with deep convolutional neural networks. In Advances in neural information processing systems (pp. 1097-1105).

Hinton, G., Deng, L., Yu, D., Dahl, G. E., Mohamed, A. R., Jaitly, N., ... & Kingsbury, B. (2012). Deep neural networks for acoustic modeling in speech recognition: The shared views of four research groups. IEEE Signal processing magazine, 29(6), 82-97.

Sutskever, I., Vinyals, O., & Le, Q. V. (2014). Sequence to sequence learning with neural networks. In Advances in neural information processing systems (pp. 3104-3112).

Covington, P., Adams, J., & Sargin, E. (2016). Deep neural networks for youtube recommendations. In Proceedings of the 10th ACM conference on recommender systems (pp. 191-198).

Bengio, Y., Simard, P., & Frasconi, P. (1994). Learning long-term dependencies with gradient descent is difficult. IEEE Transactions on Neural Networks, 5(2), 157-166.

54'

Chowdhury, G. G. (2003). Natural language processing. Annual Review of Information Science and Technology, 37(1), 51-89.

Shawar, B. A., & Atwell, E. (2007). Chatbots: Are they really useful?. LDV Forum, 22(1), 29-49.

Pang, B., & Lee, L. (2008). Opinion mining and sentiment analysis. Foundations and Trends in Information Retrieval, 2(1-2), 1-135.

Hutchins, J., & Somers, H. L. (1992). An introduction to machine translation (Vol. 362). London: Academic Press.

55'

Szeliski, R. (2010). Computer vision: algorithms and applications. Springer Science & Business Media.

Zhang, X., Zhou, X., Lin, M., & Sun, J. (2018). ShuffleNet: An extremely efficient convolutional neural network for mobile devices. In Proceedings of the IEEE conference on computer vision and pattern recognition (pp. 6848-6856).

Cavallaro, A. (2018). Intelligent Distributed Video Surveillance Systems. In Professional Content Management Systems (pp. 111-134). Auerbach Publications.

Litjens, G., Kooi, T., Bejnordi, B. E., Setio, A. A. A., Ciompi, F., Ghafoorian, M., ... & Sánchez, C. I. (2017). A survey on deep learning in medical image analysis. Medical image analysis, 42, 60-88.

Chen, C., Seff, A., Kornhauser, A., & Xiao, J. (2017). DeepDriving: Learning affordance for direct perception in autonomous driving. In Proceedings of the IEEE International Conference on Computer Vision (pp. 2722-2730).

Agarwal, A., Jogelkar, N., Nori, K. V., & Veloso, M. (2020). Towards Vision-Based Smart Hospitals: A System for Tracking and Monitoring Hand Hygiene Compliance. In *Machine Learning for Healthcare Conference* (pp. 382-396).

Sherstyuk, A., Vincent, D., Treskunov, A., & Rizzo, A. (2019). Adaptive augmented reality (AAR): A new paradigm for improving sight-line of sight task performance. *Computers & Graphics*, 80, 17-27.

56'

[1] Čapek, K. (1920). R.U.R. (Rossum's Universal Robots).

[2] Siciliano, B., & Khatib, O. (Eds.). (2016). *Springer handbook of robotics*. Springer.

[3] Russell, S., & Norvig, P. (2016). *Artificial intelligence: a modern approach*. Malaysia; Pearson Education Limited.

[4] Nof, S. Y. (Ed.). (1999). *Handbook of industrial robotics* (Vol. 10). John Wiley & Sons.

[5] Satava, R. M. (2002). Surgical robotics: the early chronicles: a personal historical perspective. *Surgical laparoscopy endoscopy & percutaneous techniques*, 12(1), 6-16.

[6] Singer, P. W. (2009). *Wired for war: The robotics revolution and conflict in the 21st century*. Penguin.

[7] Matarić, M. J., Eriksson, J., Feil-Seifer, D. J., & Winstein, C. J. (2007). Socially assistive robotics for post-stroke rehabilitation. *Journal of neuroengineering and rehabilitation*, 4(1), 5.

[8] Forlizzi, J., & DiSalvo, C. (2006, August). Service robots in the domestic environment: a study of the roomba vacuum in the home. In *Proceedings of the 1st ACM SIGCHI/SIGART conference on Human-robot interaction* (pp. 258-265).

[9] Blackmore, S., Stout, B., Wang, M., & Runov, B. (2005). Robotic weed control. In *Proceedings of the 8th EWRS workshop on physical and cultural weed control*, March (pp. 7-9).

[10] Bartneck, C., & Forlizzi, J. (2004). A design-centred framework for social human-robot interaction. In *RO-MAN 2004. 13th IEEE International Workshop on Robot and Human Interactive Communication* (IEEE Catalog No. 04TH8759) (pp. 591-594). IEEE.

[11] Goodrich, M. A., & Schultz, A. C. (2007). Human-robot interaction: a survey. *Foundations and trends in human-computer interaction*, 1(3), 203-275.

57'

[1] Laney, D. (2001). 3D data management: Controlling data volume, velocity, and variety. *META Group Research Note*, 6, 70.

[2] Bughin, J., Chui, M., & Manyika, J. (2010). Clouds, big data, and smart assets: Ten tech-enabled business trends to watch. *McKinsey Quarterly*, 56(1), 75-86.

[3] Russell, S., & Norvig, P. (2016). *Artificial intelligence: a modern approach*. Malaysia; Pearson Education Limited.

[4] Chen, M., Mao, S., & Liu, Y. (2014). Big data: A survey. *Mobile Networks and Applications*, 19(2), 171-209.

[5] Jagtiani, J., & Lemieux, C. (2018). Do fintech lenders penetrate areas that are underserved by traditional banks?. *Journal of Economics and Business*, 100, 43-54.

[6] Raghupathi, W., & Raghupathi, V. (2014). Big data analytics in healthcare: promise and potential. *Health information science and systems*, 2(1), 3.

[7] Ge, Y., Li, Q., Wang, H., & Luo, D. (2017). Impacts of information technology on transportation: a general review from the perspectives of people, vehicles, and intelligent transportation systems. *Engineering*, 3(1), 56-68.

[8] Lee, J., Lapira, E., Bagheri, B., & Kao, H. A. (2013). Recent advances and trends in predictive manufacturing systems in big data environment. *Manufacturing Letters*, 1(1), 38-41.

58'

[1] Labrecque, L. I., vor dem Esche, J., Mathwick, C., Novak, T. P., & Hofacker, C. F. (2013). Consumer power: Evolution in the digital age. *Journal of Interactive Marketing*, 27(4), 257-269.

[2] Hauser, J. R., Urban, G. L., Liberali, G., & Braun, M. (2009). Website morphing. *Marketing Science*, 28(2), 202-223.

[3] Cheng, H. K., & Tang, Q. (2010). Free trial or no free trial: Optimal software product design with network effects. *European Journal of Operational Research*, 205(2), 437-447.

[4] Provost, F., & Fawcett, T. (2013). Data Science and its Relationship to Big Data and Data-Driven Decision Making. *Big Data*, 1(1), 51-59.

[5] Huang, M. H., & Rust, R. T. (2011). CRM in e-commerce: a business model. *Service Science*, 3(2), 77-91.

[6] Yan, J., Liu, N., Wang, G., Zhang, W., Jiang, Y., & Chen, Z. (2012, August). How much can behavioral targeting help online advertising?. In *Proceedings of the 21st international conference on World Wide Web* (pp. 261-270).

[7] Joo, J., Bong, C., Choi, I., Rho, M. J., Kim, S. M., Song, S., & Lee, J. (2017). Who Multi-Tasks and Why? Multi-Tasking Ability, Perceived Multi-Tasking Ability, Impulsivity, and Sensation Seeking. *PloS one*, 12(1), e0168028.

[8] Wirtz, J., Patterson, P. G., Kunz, W. H., Gruber, T., Lu, V. N., Paluch, S., & Martins, A. (2018). Brave new world: service robots in the frontline. *Journal of Service Management*, 29(5), 907-931.

59'

[1] Bolton, R. J., & Hand, D. J. (2002). Statistical fraud detection: A review. *Statistical science*, 235-249.

[2] Srivastava, A., Kundu, A., Sural, S., & Majumdar, A. K. (2008). Credit card fraud detection using hidden Markov model. *IEEE Transactions on Dependable and Secure Computing*, 5(1), 37-48.

[3] Wang, H., Wang, W. N., & Da, Q. (2016). When do the smart money and dumb money disagree (and does it matter)?. *Review of Asset Pricing Studies*, 6(2), 171-213.

[4] D'Amore-McKim School of Business. (2017). The Benefits of AI and Machine Learning in Financial Services. Northeastern University. Disponível em: <https://damore-mckim.northeastern.edu/news/the-benefits-of-ai-and-machine-learning-in-financial-services/>.

[5] Thomas, L. C. (2000). A survey of credit and behavioural scoring: forecasting financial risk of lending to consumers. *International journal of forecasting*, 16(2), 149-172.

[6] Huang, C. L., Chen, M. C., & Wang, C. J. (2007). Credit scoring with a data mining approach based on support vector machines. *Expert Systems with Applications*, 33(4), 847-856.

60'

[1] Daugherty, P. R., Wilson, H. J., & Chowdhury, R. (2019). Using artificial intelligence to enhance business operations. *IEEE Engineering Management Review*, 47(2), 56-63.

[2] Harari, M. B., Reaves, A. C., Beane, D. A., Laginess, A. J., & Viswesvaran, C. (2018). The predictive validity of artificial intelligence-generated interview ratings. *International Journal of Selection and Assessment*, 26(3), 187-198.

[3] Bersin, J. (2019). HR technology 2020: Disruption ahead. Deloitte Consulting LLP.

[4] Guzman, G., & Rodriguez, M. (2018). The future of HR: implications for Trinidad and Tobago. *Business Horizons*, 61(4), 599-607.

[5] Strohmeier, S. (2019). AI in HRM: Review and a multi-perspective framework. In *Electronic HRM in the digital era: the challenge of integrating ICT* (pp. 23-42). Emerald Publishing Limited.

[6] Bassellier, G., & Benbasat, I. (2017). Business competence of information technology professionals: Conceptual development and influence on IT-business partnerships. *Mis Quarterly*, 673-694

61'

[1] Ting, D. S. W., Pasquale, L. R., Peng, L., Campbell, J. P., Lee, A. Y., Raman, R., Tan, G. S. W., Schmetterer, L., Keane, P. A., & Wong, T. Y. (2019). Artificial intelligence and deep learning in ophthalmology. *British Journal of Ophthalmology*, 103(2), 167-175.

[2] Esteva, A., Robicquet, A., Ramsundar, B., Kuleshov, V., DePristo, M., Chou, K., Cui, C., Corrado, G., Thrun, S., & Dean, J. (2019). A guide to deep learning in healthcare. *Nature Medicine*, 25(1), 24-29.

[3] Vamathevan, J., Clark, D., Czodrowski, P., Dunham, I., Ferran, E., Lee, G., Li, B., Madabhushi, A., Shah, P., Spitzer, M., & Zhao, S. (2019). Applications of machine learning in drug discovery and development. *Nature Reviews Drug Discovery*, 18(6), 463-477.

[4] Laranjo, L., Dunn, A. G., Tong, H. L., Kocaballi, A. B., Chen, J., Bashir, R., Surian, D., Gallego, B., Magrabi, F., Lau, A. Y. S., & Coiera, E. (2018). Conversational agents in

healthcare: a systematic review. *Journal of the American Medical Informatics Association*, 25(9), 1248–1258.

Todas as referências estão de acordo com as normas da Associação Brasileira de Normas Técnicas (ABNT).

62'

[1] Mobley, R. K. (2002). *An introduction to predictive maintenance*. Elsevier.

[2] Wang, H., Xu, Z., Suzuki, R., & Khorram, S. (2020). Quality prediction in unknown contexts using multilevel latent variable modeling. *IISE Transactions*, 52(5), 575-589.

[3] Ivanov, D., Dolgui, A., Sokolov, B., Werner, F., & Ivanova, M. (2016). A dynamic model and an algorithm for short-term supply chain scheduling in the smart factory industry 4.0. *International Journal of Production Research*, 54(2), 386-402.

[4] Wuest, T., Weimer, D., Irgens, C., & Thoben, K. D. (2016). Machine learning in manufacturing: advantages, challenges, and applications. *Production & Manufacturing Research*, 4(1), 23-45.

Todas as referências estão de acordo com as normas da Associação Brasileira de Normas Técnicas (ABNT).

63'

[1] D'Mello, S., & Graesser, A. (2013). Multimodal semi-automated affect detection from conversational cues, gross body language, and facial features. *User Modeling and User-Adapted Interaction*, 23(1), 57-105.

[2] Aleven, V., McLaren, B. M., Sewall, J., & Koedinger, K. R. (2009). A new paradigm for intelligent tutoring systems: Example-tracing tutors. *International Journal of Artificial Intelligence in Education*, 19(2), 105-154.

[3] Park, O., & Lee, J. (2003). Adaptive instructional systems. In D. H. Jonassen (Ed.), *Handbook of research for educational communications and technology: A project of the Association for Educational Communications and Technology* (pp. 651-684). Lawrence Erlbaum Associates Publishers.

[4] Manouselis, N., Drachsler, H., Vuorikari, R., Hummel, H., & Koper, R. (2011). Recommender systems in technology enhanced learning. In *Recommender Systems Handbook* (pp. 387-415). Springer.

Todas as referências estão de acordo com as normas da Associação Brasileira de Normas Técnicas (ABNT).

64'

[1] Medjroubi, W., Matke, C., Kleinhans, D., & Agert, C. (2017). Open data in power grid modelling: New approaches towards transparent grid models. *Energy Reports*, 3, 14-21.

[2] Kusiak, A., & Li, W. (2011). The prediction and diagnosis of wind turbine faults. *Renewable Energy*, 36(1), 16-23.

[3] Shah, R., Mithulananthan, N., Bansal, R. C., & Ramachandramurthy, V. K. (2015). A review on techniques for optimal sizing of battery energy storage for grid-connected wind power systems. *Renewable and Sustainable Energy Reviews*, 45, 215-225.

[4] Aggarwal, R., Saini, L. M., & Kumar, A. (2009). Electricity price forecasting in deregulated markets: A review and evaluation. *International Journal of Electrical Power & Energy Systems*, 31(1), 13-22.

[5] Farhangi, H. (2010). The path of the smart grid. *IEEE Power and Energy Magazine*, 8(1), 18-28.

[6] Palensky, P., & Dietrich, D. (2011). Demand side management: Demand response, intelligent energy systems, and smart loads. *IEEE Transactions on Industrial Informatics*, 7(3), 381-388.

Todas as referências estão de acordo com as normas da Associação Brasileira de Normas Técnicas (ABNT).

65'

[1] Anderson, J. M., Nidhi, K., Stanley, K. D., Sorensen, P., Samaras, C., & Oluwatola, O. A. (2014). *Autonomous vehicle technology: a guide for policymakers*. Rand Corporation.

[2] Zhang, R., Li, X., Zhang, F., Wang, W., & De, P. (2016). Learning-based computing of reachable sets for traffic signal optimization. *IEEE Transactions on Intelligent Transportation Systems*, 18(5), 1258-1270.

[3] Mes, M., Heijden, R. V. D., & Huisman, M. (2017). OR in practice--Opportunities for routing with vehicle location data: The case of a mobile repair service provider. *European Journal of Operational Research*, 263(3), 1078-1094.

[4] Zhang, L., Zhang, F., & van Wee, G. P. (2017). Traffic incidents and network dynamics in urban networks: An empirical analysis. *Transportation Research Part C: Emerging Technologies*, 80, 245-265.

Todas as referências estão de acordo com as normas da Associação Brasileira de Normas Técnicas (ABNT).

66'

[1] Hällgren, M., Rouleau, L., & De Rond, M. (2018). A Matter of Life or Death: How Extreme Context Research Matters for Management and Organization Studies. *Academy of Management Annals*, 12(1), 111-153.

[2] Kaisler, S., Armour, F., Espinosa, J. A., & Money, W. (2013). Big Data: Issues and Challenges Moving Forward. 46th Hawaii International Conference on System Sciences, 995-1004.

[3] Williams, T., Klakegg, O. J., Walker, D. H. T., Andersen, B., & Mortensen, M. M. (2012). Identifying and Acting on Early Warning Signs in Complex Projects. *Project Management Journal*, 43(2), 37-53.

[4] Amoako-Gyampah, K., & Meredith, J. R. (1989). The operations management research agenda: an update. *Journal of Operations Management*, 8(3), 250-262.

67'

Russell, S. J., & Norvig, P. (2020). *Inteligência artificial: uma abordagem moderna*. Pearson Education do Brasil.

Dhar, V. (2013). Data science and prediction. *Communications of the ACM*, 56(12), 64-73.

Han, J., Pei, J., & Kamber, M. (2011). Data mining: concepts and techniques. Elsevier.
 Alpaydin, E. (2020). Introduction to machine learning. MIT press.

Kohavi, R. (1995). A study of cross-validation and bootstrap for accuracy estimation and model selection. *Ijcai*, 14(2), 1137-1145.

Chickering, D. M., Heckerman, D., & Meek, C. (1997). A Bayesian approach to learning Bayesian networks with local structure. In *Proceedings of the Thirteenth conference on Uncertainty in artificial intelligence* (pp. 80-89). Morgan Kaufmann Publishers Inc.

Caruana, R., & Niculescu-Mizil, A. (2006). An empirical comparison of supervised learning algorithms. In *Proceedings of the 23rd international conference on Machine learning* (pp. 161-168).

68'

ABNT. NBR 6023: Informação e documentação - Referências - Elaboração. Rio de Janeiro, 2002.

PMI (Project Management Institute). A Guide to the Project Management Body of Knowledge (PMBOK® Guide). 6th Edition, 2017.

Russell, S., Norvig, P. Artificial Intelligence: A Modern Approach. 4th Edition, Pearson, 2020.

Liu, B. Sentiment Analysis and Opinion Mining. Morgan & Claypool Publishers, 2012.

Szeliski, R. Computer Vision: Algorithms and Applications. Springer, 2010.

Witten, I. H., Frank, E., Hall, M. A., Pal, C. J. Data Mining: Practical Machine Learning Tools and Techniques. Morgan Kaufmann, 2016.

Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., Wirth, R. CRISP-DM 1.0 Step-by-step data mining guide, 2000.

Rumelhart, D. E., Hinton, G. E., & Williams, R. J. Learning representations by back-propagating errors. *Nature*, 323(6088), 533-536, 1986.

Goodfellow, I., Bengio, Y., & Courville, A. Deep Learning. MIT Press, 2016.

69'

ABNT. NBR 6023: Informação e documentação - Referências - Elaboração. Rio de Janeiro, 2002.

Project Management Institute. The Standard for Program Management. 4th edition, PMI, 2017.

Sutherland, J., Schwaber, K. The Scrum Guide. Scrum.org, 2020.

Wysocki, R. K. Effective Project Management: Traditional, Agile, Extreme. 7th Edition, Wiley, 2013.

Prince2. Managing Successful Projects with PRINCE2. 6th Edition, Axelos, 2017.

Highsmith, J. Agile Project Management: Creating Innovative Products. 2nd Edition, Addison Wesley, 2009.

70'

ABNT. NBR 6023: Informação e documentação - Referências - Elaboração. Rio de Janeiro, 2002.

Project Management Institute. A Guide to the Project Management Body of Knowledge (PMBOK® Guide). 6th Edition, PMI, 2017.

DDS Foundation. The Data Distribution Service for Real-Time Systems (DDS). Version 1.4, 2015.

Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., & Wirth, R. (2000). CRISP-DM 1.0: Step-by-step data mining guide.

AIIM, Certified Artificial Intelligence Practitioner (CAIP), 2023.

Microsoft, AI-900: Microsoft Azure AI Fundamentals, 2023.

Coursera, AI for Everyone, 2023.

edX, AI Ethics, Governance and Regulation, 2023.

AIIM, Certified Artificial Intelligence Manager (CAIM), 2023.

MIT Sloan Executive Education, Artificial Intelligence: Implications for Business Strategy, 2023.

IBM, Applied AI for Leaders, 2023.

IBM, Data Science Essentials, 2023.

I2AI, Certified Artificial Intelligence Professional, 2023.

AI Society, Certified AI Practitioner, 2023.

IBM, Professional Certificate in Data Science, 2023.

Microsoft, Microsoft Certified - Azure AI Fundamentals, 2023.

Harvard Business School Online, Artificial Intelligence: Business Strategies and Applications, 2023.

71'

SCHERER, Matthew U. Artificial Intelligence and the End of Work. In: AI & Society, v. 34, n. 1, p. 129-136, 2019.

KITCHIN, Rob. Thinking critically about and researching algorithms. In: Information, Communication & Society, v. 20, n. 1, p. 14-29, 2017.

BOSTROM, Nick; YUDKOWSKY, Eliezer. The Ethics of Artificial Intelligence. In: CAMBRIDGE Handbook of Artificial Intelligence, Cambridge University Press, p. 316-334, 2014.

O'NEIL, Cathy. Weapons of math destruction: How big data increases inequality and threatens democracy. Crown, 2016.

HOLZINGER, Andreas; KIESEBERG, Peter; WEIPPL, Edgar; TJOA, A. Min. Current Advances, Trends and Challenges of Machine Learning and Knowledge Extraction: From Machine Learning to Explainable AI. In: CD-MAKE. Springer, Cham, p. 1-8, 2018.

GUYON, Isabelle; BENNETT, Kristin; CESA-BIANCHI, Nicolo; ZURADA, Jacek M. Neural Networks for Signal Processing VII. Proceedings of the 1997 IEEE Signal Processing Society Workshop. IEEE, 1997.

BAGCHI-SEN, Sharmistha; SEN, Joyashree. US employee downsizing and offshore outsourcing. In: International Business Review, v. 16, n. 4, p. 488-508, 2007.

CAO, Jing; LIU, Dajiang; WEI, Xiaoming. The impact of lock-in effects on software platform competition: A two-sided market analysis. In: Decision Support Systems, v. 56, p. 63-75, 2013.

DIXIT, Avinash K. Uncertainty and information in economics. In: The New Palgrave Dictionary of Economics. Palgrave Macmillan, London, 1987.

BARTLETT, Christopher A.; GHOSHAL, Sumantra. Transnational management. Irwin, 1995.

KNIGHT, Frank H. Risk, uncertainty and profit. Hart, Schaffner & Marx, 1921.

72'

Comissão Europeia. (2017). Guia de uso ético da IA. Bruxelas: Comissão Europeia.

73'

Comissão Europeia. (2019). Ethics Guidelines for Trustworthy AI. Bruxelas: Comissão Europeia.

74'

Divino, F. & Magalhães, R. (2020). Governança e Princípios de Sistemas de IA. São Paulo: Editora ABC.

75'

'The Digital Vortex' (IMD, 2021); <https://www.imd.org/contentassets/8c5b42807da941ee95c7be87d54e5db9/20210427-digitalvortex21-report-web-final.pdf>, visitado em 02/03/2023

76'

'Artificial Intelligence for the Real World' (HBR, 2018); <https://hbr.org/2018/01/artificial-intelligence-for-the-real-world>, visitado em 02/03/2023

77'

'Don't be sucked in by AI's head-spinning hype cycles' (TechCrunch, 2023); <https://techcrunch.com/2023/01/25/dont-be-sucked-in-by-ais-head-spinning-hype-cycles/>, visitado em 02/03/2023

78'

'Changes Are Coming, and AI Will Transform the Way We Work' (Medium, 2019); <https://medium.com/@Skillroads.com/changes-are-coming-and-ai-will-transform-the-way-we-work-398aab2c17d1>, visitado em 02/03/2023